

SVEUČILIŠTE U ZAGREBU
FAKULTET STROJARSTVA I BRODOGRADNJE

ZAVRŠNI RAD

David Mihić

ZAGREB, 2026.

SVEUČILIŠTE U ZAGREBU

FAKULTET STROJARSTVA I BRODOGRADNJE

ZAVRŠNI RAD

Mentor:

Student:

Doc. dr. sc. Bojan Šekoranja,
mag.ing.

David Mihić

ZAGREB, 2026.

Izjavljujem da sam ovaj rad izradio samostalno koristeći znanja stečena tijekom studija i navedenu literaturu.

Zahvaljujem se mentoru, doc. dr. sc. Bojanu Šekoranji na pomoći i prijedlozima, kao i kolegi Branimiru Čaranu na iznimnoj pomoći i podršci ne samo tijekom pisanja ovog rada, nego i tijekom studiranja.

Posebno hvala mojim roditeljima i sestri, kao i mojoj curi Eli na beskonačnom strpljenju i podršci tijekom godina studiranja. Hvala svim prijateljima i svima ostalima koji su me poticali i pomagali.

Također sam vrlo zahvalan kolegama i osoblju iz laboratorija CRTA na svim prilikama koje su mi pružili tijekom zadnjih godina.

David Mihić

Sveučilište u Zagrebu Fakultet strojarstva i brodogradnje	
Datum	Prilog
Klasa: 602-01/26-01/3	
Ur.broj: 15-31000-26-	

ZAVRŠNI ZADATAK

Student: **David Mihić**

JMBAG: 0035250443

Naslov rada na hrvatskom jeziku: **Razvoj i evaluacija metode upravljanja mobilnim manipulatorom u interakciji s okolinom**Naslov rada na engleskom jeziku: **Development and evaluation of a control method for a mobile manipulator in interaction with the environment**

Opis zadatka:

U ovom radu razmatra se problem autonomne interakcije mobilnog manipulatora s okolinom kroz zadatke koji uključuju uspostavu i održavanje kontakta s objektima te izvođenje koordiniranih manipulacijskih radnji. Naglasak je na integraciji percepcije, procjene stanja i upravljanja u jedinstveni sustav sposoban za izvršavanje višefaznih zadataka u nepoznatim ili djelomično poznatim uvjetima.

Cilj rada je razviti i eksperimentalno evaluirati metodologiju upravljanja koja omogućuje robotu donošenje odluka i generiranje gibanja na temelju više senzorskih podataka, uzimajući u obzir mehanička svojstva okoline i interakcijske sile.

U radu je potrebno:

- istražiti postojeće pristupe upravljanju mobilnim manipulatorima u zadacima koji uključuju fizičku interakciju s objektima
- razviti modul percepcije za detekciju relevantnih objekata te procjenu njihove pozicije i orijentacije korištenjem dostupnih senzora
- implementirati postupak procjene svojstava okoline (npr. krutost, ograničenja gibanja) na temelju mjerenja sile i momenta tijekom interakcije
- modelirati i implementirati dva različita pristupa upravljanju sustavom (klasični pristup temeljen na modelu i pristup temeljen na učenju)
- definirati i implementirati odgovarajuću reprezentaciju stanja, akcija i kriterija uspješnosti za odabrani pristup učenja
- analizirati i usporediti performanse implementiranih metoda s obzirom na učinkovitost i robusnost sustava

U radu je potrebno navesti korištenu literaturu i eventualno dobivenu pomoć.

Zadatak zadan:

22. 4. 2026.

Zadatak zadao:

doc. dr. sc. Bojan Šekoranja

Datum predaje rada:

2. rok: 15. i 16. 7. 2026.

3. rok: 16. i 17. 9. 2026.

Predviđeni datumi obrane:

2. rok: 21. - 23. 7. 2026.

3. rok: 22. - 24. 9. 2026.

Predsjednik Povjerenstva:

izv. prof. dr. sc. Petar Čurković

SADRŽAJ

SADRŽAJ	i
POPIS SLIKA	iv
POPIS TABLICA	v
POPIS OZNAKA	vi
POPIS KRATICA	viii
SAŽETAK	ix
SUMMARY	x
1. UVOD	1
1.1. Motivacija	1
1.2. Cilj rada	2
1.3. Struktura rada	3
2. PREGLED DOSADAŠNJIH ISTRAŽIVANJA	4
2.1. Klasični pristupi upravljanju u kontaktu	4
2.2. Mobilna manipulacija	5
2.3. Interakcija s artikuliranim objektima	5
2.4. Pristupi temeljeni na učenju	6
2.5. Prijenos iz simulacije na stvarnog robota	7
2.6. Položaj ovog rada	7
3. ROBOTSKI SUSTAV I SIMULACIJSKO OKRUŽENJE	8
3.1. KMR iiwa — mobilna platforma i manipulator	8
3.1.1. Mobilna platforma	8
3.1.2. Manipulator LBR iiwa 7 R800	9
3.2. Prihvatnica	10
3.3. Kamera i njezin nosač	12
3.4. Lidar	13
3.5. Modeli vrata	13
3.5.1. Otpor gibanja i njegovo nasumično variranje	15

3.6.	Model robota i pretvorba u simulacijski format	16
3.6.1.	Gibanje mobilne platforme	18
3.6.2.	Odometrija	18
3.7.	Simulacijsko okruženje	18
3.8.	Programska arhitektura	19
4.	MODUL PERCEPCIJE	22
4.1.	Odabir pristupa	22
4.2.	Raspored oznaka	22
4.3.	Detekcija oznaka	24
4.4.	Fuzija dviju oznaka na kvaki	24
4.5.	Sučelje modula i radni doseg	25
4.6.	Preciznost percepcijskog modula	25
4.7.	Ograničenja	26
5.	PROCJENA SVOJSTAVA OKOLINE	28
5.1.	Procjena sile i momenta na vrhu alata	28
5.1.1.	Svojstva i ograničenja procjene	28
5.2.	Ispitivanje ograničenja gibanja	29
5.2.1.	Mjera koja razlikuje slobodan smjer od ograničenog	29
5.2.2.	Razlikovanje tipa vrata	30
5.2.3.	Odnos prema razlikovanju iz percepcije	30
5.3.	Provjera procjena	31
5.3.1.	Procjena osi šarke i kuta vrata	31
5.3.2.	Razlikovanje tipa vrata i otpor	31
5.4.	Uloga procjene u ovom radu	32
6.	KLASIČNI PRISTUP UPRAVLJANJU	33
6.1.	Struktura zadatka	33
6.2.	Faza prilaza i hvata	33
6.2.1.	Poravnanje platforme	33
6.2.2.	Prepoznavanje tipa kvake	33
6.2.3.	Hvat	34
6.2.4.	Sidrenje cilja na oznaku	34
6.3.	Faza otvaranja	35
6.3.1.	Klizna vrata	35
6.3.2.	Zakretna vrata	35
6.3.3.	Završni zakret platforme	37

6.4.	Prolazak kroz vrata	38
6.5.	Rezultati	39
6.5.1.	Prilazak i hvat	41
6.5.2.	Zakretna vrata	41
6.5.3.	Klizna vrata	42
6.6.	Ograničenja	42
7.	PRISTUP TEMELJEN NA UČENJU	44
7.1.	Opseg	44
7.2.	Formulacija Markovljevog procesa odlučivanja	45
7.2.1.	Prostor opažanja	45
7.2.2.	Prostor akcija	45
7.2.3.	Koordinacija platforme i manipulatora	46
7.2.4.	Funkcija nagrade	47
7.2.5.	Prekidi epizode	48
7.2.6.	Nasumičnost pri početku epizode i kurikulum otpora	48
7.3.	Postupak učenja	49
7.4.	Rezultati	50
7.5.	Ograničenja	53
8.	REZULTATI SIMULACIJSKOG ISPITIVANJA I RASPRAVA	54
8.1.	Protokol usporedbe	54
8.1.1.	Što se uspoređuje	54
8.1.2.	Dvije različite mjere	54
8.2.	Uspješnost otvaranja	55
8.3.	Kontaktne sile	55
8.4.	Pouzdanost cjelovitog izvođenja	57
8.5.	Rasprava	57
8.5.1.	Različiti ulazi u isti problem	57
8.5.2.	Uspješnost naspram opterećenja	58
8.6.	Ograničenja usporedbe	58
9.	ZAKLJUČAK	60
9.1.	Glavni nalazi	60
9.2.	Ograničenja	61
9.3.	Smjernice za daljnji rad	62
	LITERATURA	63
	PRILOZI	66

POPIS SLIKA

1	Mobilni manipulator KMR iiwa u simulacijskom okruženju	8
2	Grada Mecanum kotača	9
3	Prihvatnica s četiri prsta; otvorena (lijevo) i zatvorena (desno)	11
4	Položaj vrha alata (TCP)	11
5	Kamera i nosač kamere postavljeni na robotu	12
6	Modeli zakretnih i kliznih vrata s označenim stupnjem slobode gibanja . .	14
7	Postupak izrade simulacijskog modela iz opisa robota i vrata	17
8	Programska arhitektura klasičnog pristupa	20
9	Programska arhitektura pristupa temeljenog na učenju	21
10	AprilTagovi: sredina vrata (gore), kvaka (A dolje lijevo, B dolje desno) . .	23
11	Raspored vizualnih oznaka na zakretnim (lijevo) i kliznim (desno) vratima	24
12	Ovisnost pogreške položaja i smjera kvake o udaljenosti hvatišta od robota	26
13	Slijed faza klasičnog pristupa	33
14	Konstrukcija procjene osi šarke iz poze i lokalnih osi velike oznake, tlocrt .	37
15	Faze izvođenja klasičnog pristupa na zakretnim vratima	40
16	Faze izvođenja klasičnog pristupa na kliznim vratima	41
17	Faze izvođenja naučene politike na oba tipa vrata	50
18	Tijek učenja: prosječni otvor vrata kroz epizodu, po iteraciji	51
19	Udjeli razloga prekida epizode kroz iteracije učenja	52

POPIS TABLICA

1	Tehnički podaci mobilne platforme	9
2	Tehnički podaci manipulatora LBR iiwa 7 R800	10
3	Granični momenti zglobova manipulatora	10
4	Značajke prihvatnice	11
5	Geometrija i inercijska svojstva modela vrata	14
6	Rasponi iz kojih se bira otpor vrata	15
7	Programska i sklopovska konfiguracija	19
8	Paketi radnog prostora ROS 2	19
9	Raspored vizualnih oznaka na vratima	23
10	Točnost procjene poze hvatišta, 30 mjernih točaka	26
11	Očekivani ishod ispitivanja po osima prihvatnice	30
12	Odstupanje procjene osi šarke i kuta vrata od stvarnih vrijednosti	31
13	Ishod ispitivanja ograničenja, deset pokretanja po tipu vrata	31
14	Izmjerene vrijednosti pri otvaranju zakretnih vrata	42
15	Sastav akcijskog prostora, faktori razmjera i granice	46
16	Članovi funkcije nagrade	47
17	Hiperparametri učenja	50
18	Rezultati pristupa temeljenog na učenju, 1024 okruženja, 2400 iteracija	52
19	Stopa uspjeha otvaranja, uz uspostavljen hvat na početku	55
20	Kontaktne sile pri otvaranju	56

POPIS OZNAKA

Oznaka	Jedinica	Opis
τ_{otpor}	N m, N	Ukupni otpor gibanja vrata (moment ili sila, ovisno o tipu)
τ_{tr}	N m, N	Coulombovo trenje u zglobu vrata
d	Nms/rad, Ns/m	Koeficijent viskoznog prigušenja zgloba vrata
q	rad, m	Koordinata stupnja slobode vrata (kut zakreta ili pomak krila)
$\dot{q}$	rad/s, m/s	Brzina stupnja slobode vrata
p	m	Položaj hvatišta kvake
p_A	m	Položaj oznake A na kvaki
p_B	m	Položaj oznake B na kvaki
z_A, z_B		Normale oznaka A i B
$\bar{z}$		Srednja vrijednost normala dviju oznaka
R		Matrica rotacije (hvatišta ili oznake, prema indeksu)
e_x, e_y, e_z		Vektori baze koordinatnog sustava hvatišta
τ	N m	Vektor momenata u zglobovima
q	rad	Vektor zglobnih koordinata
J		Jakobijan manipulatora
F	N	Vektor sile na vrhu alata
M	N m	Vektor momenta na vrhu alata
w		Vektor sila i momenata (engl. <i>wrench</i>)
ΔF	N	Prirast sile na vrhu alata
Δx	m	Prirast pomaka na vrhu alata
K	N/m, Nm/rad	Procijenjena krutost okoline
c	m	Procijenjeni položaj osi šarke zakretnih vrata
p_{tag}	m	Položaj velike oznake na sredini vrata
q_{tag}		Orijentacija (kvaternion) velike oznake
v_{hinge}	m	Vektor od oznake do osi šarke, u lokalnom okviru oznake
L	m	Širina krila vrata

Oznaka	Jedinica	Opis
δ	m	Odmak oznake od središnje ravnine debljine krila
w		Yoshikawin indeks manipulabilnosti
γ		Diskontni faktor (engl. <i>discount factor</i>)
λ		Faktor generalizirane procjene prednosti (engl. <i>generalized advantage estimation, GAE</i>)
ϵ		Koeficijent odsijecanja (engl. <i>clipping coefficient</i>)
$(\cdot)^T$		Transponiranje matrice ili vektora
$(\cdot)^+$		Moore-Penroseov pseudoinverz matrice
$\ \cdot\ $		Norma vektora

POPIS KRATICA

Kratika	Opis
ELU	Eksponencijalna linearna jedinica (engl. <i>exponential linear unit</i>)
KMR	KUKA Mobile Robotics
LBR	Lagani robot (njem. <i>Leichtbauroboter</i>)
PhysX	Fizikalni pogon simulatora
PPO	Proksimalna optimizacija politike (engl. <i>proximal policy optimization</i>)
RANSAC	Konzensus slučajnog uzorka (engl. <i>Random Sample Consensus</i>)
ROS	Robotski operacijski sustav (engl. <i>Robot Operating System</i>)
TCP	Vrh alata (engl. <i>tool center point</i>)
URDF	Objedinjeni opis robota (engl. <i>Unified Robot Description Format</i>)
USD	Univerzalni opis scene (engl. <i>Universal Scene Description</i>)

SAŽETAK

U radu se razmatra problem autonomne interakcije mobilnog manipulatora s okolinom, na primjeru otvaranja zakretnih i kliznih vrata. Za mobilni manipulator KUKA KMR iiwa razvijen je u simulacijskom okruženju cjelovit sustav koji objedinjuje percepciju, procjenu sile i momenta te upravljanje u kontaktu. Modul percepcije iz slike određuje položaj i orijentaciju kvake pomoću vizualnih oznaka, a sila i moment na vrhu alata procjenjuju se iz momenata u zglobovima, bez zasebnog senzora sile. Tip vrata robot ne dobiva kao zadan podatak, nego ga prepoznaje iz geometrije kvake.

Zadatak upravljanja riješen je dvama pristupima. Klasični pristup temeljen na modelu izvodi cijeli lanac, od prilaska i hvata preko otvaranja do prolaska kroz vrata, oslanjajući se na geometriju ograničenja izračunatu iz percepcije. Pristup temeljen na podržanom učenju zadatak formulira kao Markovljev proces odlučivanja s varijabilnom impedancijom u prostoru akcije, pri čemu politika u svakom koraku bira krutost regulatora po svakoj osi, a ponašanje ograničenja mora zaključiti iz vlastitih opažanja sile i pomaka.

Oba su pristupa izmjerena na istom robotu, istoj sceni i istim mjerilima uspješnosti. Oba dosežu zadani cilj na oba tipa vrata, ali uz bitno različito opterećenje. Klasični pristup otvara vrata u svakom pokretanju, dok naučena politika kao cjelovito izvođenje uspijeva u otprilike polovici epizoda; nad epizodama u kojima izvođenje krene otvara vrata u više od devedeset posto slučajeva. Kontaktne su sile pritom red veličine niže kod naučene politike, s efektivnom vrijednošću od 29 N naspram 325 N kod zakretnih te 22 N naspram 270 N kod kliznih vrata, jer politika vrata otvara silom bliskom njihovu stvarnom otporu, dok kod klasičnog pristupa veći dio sile potječe od tranzijenata u krutoj vezi između manipulatora i kvake. Usporedba pritom nije usporedba modela s učenjem općenito, nego krutog pozicijskog upravljanja s upravljanjem promjenjivom krutošću.

KLJUČNE RIJEČI: mobilni manipulator, fizička interakcija, procjena svojstava okoline, impedancijsko upravljanje, podržano učenje, simulacija.

SUMMARY

This thesis addresses the problem of autonomous interaction between a mobile manipulator and its environment, using the opening of two types of door, revolute and sliding, as the test case. A complete system integrating perception, force and torque estimation, and contact control was developed in simulation for the KUKA KMR iiwa mobile manipulator. The perception module determines the position and orientation of the door handle from camera images using visual markers, while the force and torque at the tool tip are estimated from joint torques, without a dedicated force sensor. The door type is not supplied to the robot as a parameter, but inferred from the geometry of the handle.

The control problem is solved by two approaches. The classical, model-based approach performs the entire task chain, from approach and grasp through opening to passing through the doorway, relying on the constraint geometry computed from perception. The learning-based approach formulates the task as a Markov decision process with variable impedance as the action space, so that the policy selects the controller stiffness along each axis at every step, and must infer the behaviour of the constraint from its own force and displacement observations.

Both approaches were evaluated on the same robot, the same scene and the same success criteria. Both reach the target opening on both door types, but at markedly different cost. The classical approach opens the door in every run, whereas the learned policy, taken as a complete execution, succeeds in roughly half of all episodes; restricted to episodes in which execution gets under way, it opens the door in more than ninety per cent of cases. Contact forces are an order of magnitude lower for the learned policy, with a root-mean-square value of 29 N against 325 N for revolute and 22 N against 270 N for sliding doors, because the policy opens the door with a force close to the door's actual resistance, while for the classical approach most of the force originates in transients within the rigid link between the manipulator and the handle. The comparison is therefore not one between model-based and learning-based control in general, but between rigid position control and control with variable stiffness.

Key words: mobile manipulator, physical interaction, environment property estimation, impedance control, reinforcement learning, simulation.

1. UVOD

1.1. Motivacija

Industrijska robotika od svog početka počiva na pretpostavci strukturirane okoline. Robot je ograden zaštitnom ogradom, radni komadi nalaze se na predodređenom mjestu, a zadatak se svodi na ponavljanje prethodno naučene i isprogramirane radnje. U takvim uvjetima pozicijsko upravljanje visoke krutosti daje izvrsne rezultate, robot vrlo ponovljivo i bez većih odstupanja slijedi zadanu putanju bez obzira na smetnje.

Ta se pretpostavka ruši čim robot izađe iz kaveza. Industrijska okruženja puna su ljudi koji istovremeno obavljaju svoje poslove, servise, logističke zadatke i okolnosti koje se mijenjaju između dva izvođenja istog zadatka. Odgovor na takve probleme su mobilni manipulatori — sustavi koji integriraju svestranost mobilne platforme s artikuliranošću robotske ruke i time uklanjaju ograničenje dosega koje veže nepokretni manipulator za jedno radno mjesto.

Najčešća primjena industrijskih robota je za tzv. *pick-and-place* radnje, ali postoji i veliki broj operacija za koje je potrebna uspostava i održavanje fizičkog kontakta, primjerice otvaranje vrata i ladica, umetanje predmeta, posluživanje stroja ili pomicanje objekata. Postojanje kontakta uvelike mijenja problem upravljanja. Dok se robot giba u slobodnom prostoru, greška položaja je relativno mala i nema brige da će robot oštetiti okolinu. U kontaktu s krutom okolinom ista greška položaja proizvodi silu koja raste s krutošću regulatora i može oštetiti predmet, okolinu ili samog robota. Zbog toga upravljanje u kontaktu ne može biti čisto pozicijsko, već mora regulirati odnos između položaja i sile [1].

Otvaranje vrata reprezentativan je predstavnik te klase zadataka i zbog toga se u literaturi često koristi kao referentni problem [2]. Vrata su artikulirani objekt čije je gibanje ograničeno na jedan stupanj slobode, ali robot taj stupanj slobode ne poznaje unaprijed. Drugim riječima, robot ne zna gdje je os šarke, u kojem smjeru se krilo otvara ili koliki je otpor u zglobovima. Sve to mora zaključiti iz vlastitih mjerenja tijekom interakcije [3]. Uz to, hod krila redovito premašuje doseg ruke pri nepomičnoj bazi, pa zadatak traži i koordinaciju platforme i manipulatora. Zadatak time istovremeno obuhvaća percepciju, procjenu svojstava okoline i upravljanje u kontaktu, što ga čini prikladnim ispitnim slučajem za cjelovit sustav.

Postoje dva prevladavajuća pristupa takvim zadacima. Klasični pristup temeljen na modelu oslanja se na eksplicitan opis zadatka: procijeni se geometrija ograničenja, iz nje se generira referentna putanja, a impedancijski ili hibridni silno-pozicijski regulator izvodi gibanje uz propisanu popustljivost [4]. Prednost je razumljivost i predvidljivost, svaki je

korak moguće analizirati i obrazložiti. Slabost je osjetljivost na kvalitetu procjene: pogreška u procijenjenoj geometriji ograničenja izravno se pretvara u kontaktnu silu. Pristup temeljen na učenju ne zahtijeva eksplicitan model, već strategiju upravljanja stječe kroz interakciju sa simuliranom okolinom. Novije formulacije akcijskim prostorom politike čine samu krutost regulatora, pa politika uči ne samo kamo se gibati nego i koliko biti popustljiva u pojedinom trenutku [5]. Cijena je gubitak uvida u razloge odluke i ovisnost o vjernosti simulacije.

Usporedba tih dvaju pristupa ima smisla samo ako se provodi na istom zadatku, istom robotu i istoj fizici okoline. Ovaj rad zato oba pristupa razvija za isti sustav (mobilni manipulator KUKA KMR iiwa u simulacijskom okruženju), i uspoređuje ih na istim mjerilima uspješnosti.

1.2. Cilj rada

Cilj rada je razviti i eksperimentalno vrednovati sustav koji mobilnom manipulatoru omogućuje autonomnu interakciju s okolinom, te na tom sustavu usporediti dva pristupa upravljanju. Zadatak je konkretiziran otvaranjem vrata dvaju tipova, zakretnih i kliznih, pri čemu robot tip vrata ne dobiva kao zadan podatak nego ga prepoznaje sam.

U sklopu rada razvijen je modul percepcije koji iz slike određuje položaj i orijentaciju kvake, postupak procjene sile i momenta na vrhu alata iz momenata u zglobovima, bez zasebnog senzora sile, te dva međusobno neovisna rješenja zadatka upravljanja. Klasično rješenje izvodi cijeli lanac, od prilaska i hvata preko otvaranja do prolaska kroz vrata, oslanjajući se na geometriju ograničenja izračunatu iz percepcije. Rješenje temeljeno na učenju zadatak formulira kao Markovljev proces odlučivanja s varijabilnom impedancijom u prostoru akcije, pa politika u svakom koraku bira koliko će regulator biti krut po svakoj osi, a ponašanje ograničenja mora zaključiti iz vlastitih opažanja sile i pomaka.

Usporedba je pokazala da oba pristupa dosežu zadani cilj, na oba tipa vrata, ali uz bitno različito opterećenje. Klasični pristup otvara vrata u svakom pokretanju, dok naučena politika kao cjelovito izvođenje uspijeva u otprilike polovici epizoda; promatra li se samo kao zakon upravljanja, nad epizodama u kojima izvođenje krene, otvara vrata u više od devedeset posto slučajeva. Kontaktne su sile pritom red veličine niže kod naučene politike: efektivna vrijednost iznosi 29 N naspram 325 N kod zakretnih, odnosno 22 N naspram 270 N kod kliznih vrata. Naučena politika vrata otvara silom bliskom njihovom stvarnom otporu, dok kod klasičnog pristupa veći dio sile potječe od tranzijenata koji nastaju u krutoj vezi između manipulatora i kvake.

1.3. Struktura rada

Poglavlje 2. daje pregled dosadašnjih istraživanja, od klasičnih zakona upravljanja u kontaktu preko procjene kinematičkih modela artikuliranih objekata do novijih pristupa temeljenih na podržanom učenju. Poglavlje 3. opisuje robotski sustav i simulacijsko okruženje: mobilni manipulator KMR iiwa, prihvatnicu izrađenu za ovaj zadatak, modele vrata te programsku arhitekturu koja povezuje simulator i upravljački kod.

Poglavlja 4. i 5. obrađuju ulazne module sustava. Prvo opisuje određivanje položaja i orijentacije kvake iz slike, a drugo procjenu sile i momenta na vrhu alata te postupak kojim sustav iz izmjenjenog odziva zaključuje o ograničenju gibanja i krutosti okoline.

Poglavlja 6. i 7. predstavljaju dva uspoređivana pristupa upravljanju. Prvo opisuje rješenje temeljeno na modelu, organizirano kao slijed faza s eksplicitnom procjenom geometrije ograničenja. Drugo opisuje formulaciju zadatka kao Markovljevog procesa odlučivanja, prostor stanja i akcija s promjenjivom impedancijom, oblikovanje funkcije nagrade, te postupak učenja.

Poglavlje 8. donosi usporedbu dvaju pristupa na istoj sceni i istim mjerilima, uz raspravu o tome što razlike znače i o ograničenjima provedene usporedbe. Poglavlje 9. sažima postignuto i navodi smjernice za daljnji rad.

2. PREGLED DOSADAŠNJIH ISTRAŽIVANJA

Zadatak iz ovog rada dodiruje tri područja koja se u literaturi razvijaju odvojeno: upravljanje u kontaktu, koje se bavi time kako robot smije djelovati na okolinu; mobilnu manipulaciju, koja se bavi koordinacijom platforme i manipulatora; te interakciju s artikuliranim objektima, koja se bavi time kako robot doznaje kako se objekt uopće giba. Pregled slijedi tu podjelu, a završava pristupima temeljenima na učenju, koji zadnjih godina povezuju sva tri.

2.1. Klasični pristupi upravljanju u kontaktu

Upravljanje robotom u kontaktu s okolinom ne može biti čisto pozicijsko. Čim je vrh alata krut, a okolina također kruta, mala pogreška položaja proizvodi veliku silu, pa se regulator mora odnositi i prema odnosu položaja i sile.

Dva su rana odgovora na taj problem oblikovala područje. Hibridno silno-pozicijsko upravljanje prostor zadatka dijeli na smjerove u kojima se regulira položaj i smjerove u kojima se regulira sila, prema unaprijed poznatoj matrici izbora izvedenoj iz geometrije zadatka [1]. Impedancijsko upravljanje ne razdvaja te smjerove, nego propisuje željeni dinamički odnos između pomaka i sile, pa se robot prema okolini ponaša kao opruga zadane krutosti i prigušenja.

Formalni okvir koji povezuje oba pristupa dao je Khatib upravljanjem u operacijskom prostoru [4]. Jednadžbe gibanja manipulatora ondje se izražavaju izravno u prostoru zadatka, pa se sila na vrhu alata preslikava u momente zglobova preko transponiranog Jakobijana. Isti taj odnos se u ovom radu koristi za procjenu sile iz mjerenja momenata (poglavlje 5.). Kod redundantnih manipulatora taj okvir omogućuje i upravljanje u nul-prostoru, dakle promjenu konfiguracije zglobova bez pomicanja vrha alata.

Primjenu kartezijskog impedancijskog upravljanja upravo na otvaranje vrata mobilnim manipulatorom prikazali su Ott i suradnici [2]. Njihov je rad blizak zadatku iz ovog rada, s tom razlikom što se oslanja na unaprijed poznat model vrata.

Impedancijsko upravljanje u međuvremenu je preraslo u zasebno područje, u kojem se parametri impedancije ne zadaju unaprijed nego mijenjaju tijekom izvođenja ili uče iz podataka; pregled tog razvoja daju Abu-Dakka i Saveriano [6].

Zajednička slabost svih tih pristupa jest osjetljivost na kvalitetu modela. Ako procijenjena geometrija ograničenja odstupa od stvarne, regulator tu razliku pretvara u kontaktnu silu, i to tim izraženije što je krutost veća. Upravo se ta osjetljivost u ovom radu pokazala kao granica klasičnog pristupa na zakretnim vratima (poglavlje 6.).

2.2. Mobilna manipulacija

Spajanjem manipulatora s mobilnom platformom uklanja se ograničenje dosega, ali se uvodi problem koordinacije: platforma i manipulator dijele isti zadatak, a imaju vrlo različitu dinamiku i točnost. Sustavan pregled pristupa planiranju gibanja za mobilne manipulatore daju Sandakalum i Ang [7].

Postoje dvije osnovne strategije. Hijerarhijski pristup platformu i manipulator rješava odvojeno, najčešće tako da se platforma najprije dovede na povoljan položaj, a zatim manipulator izvede zadatak iz mirovanja. Prednost je jednostavnost, a slabost to što se gibanja ne preklapaju i što loš izbor položaja platforme zadatak može učiniti neizvedivim. Cjelovito upravljanje platformu i manipulator promatra kao jedan sustav s velikim brojem stupnjeva slobode, čime dobiva na svestranosti, ali uz znatno složenije upravljanje.

Predstavnik cjelovitog pristupa je perceptivno prediktivno upravljanje temeljeno na modelu, u kojem se gibanje platforme i manipulatora optimira zajedno, uz model okoline izgrađen iz senzorskih podataka [8]. Takvi pristupi daju glatko i usklađeno gibanje, ali zahtijevaju model zadatka i računalno su zahtjevni.

Klasični pristup u ovom radu je dijelom cjeloviti, dijelom hijerarhijski, dok pristup temeljen na učenju koordinaciju rješava jednom naučenom strategijom.

2.3. Interakcija s artikuliranim objektima

Vrata, ladice i slični objekti dijele svojstvo da im je gibanje ograničeno na jedan ili nekoliko stupnjeva slobode, koje robot unaprijed ne poznaje. Prije nego takav objekt pomakne, robot mora utvrditi kako se on uopće smije gibati.

Sturm i suradnici formulirali su taj problem kao učenje kinematičkih modela artikuliranih objekata iz opažanja gibanja [3]. Njihov okvir iz zabilježene putanje odabire model koji ju najbolje objašnjava (rotacijski, prizmatični ili krut) i time istovremeno prepoznaje tip zgloba i procjenjuje njegove parametre. Isto načelo, prilagodba više modela istoj putanji, stoji iza postupka procjene ograničenja opisanog u poglavlju 5..

Noviji radovi taj problem rješavaju tijekom samog izvođenja, bez prethodne faze promatranja. Rizzi i suradnici predstavili su upravljanje mobilnim manipulatorom temeljeno na uzorkovanju, otporno na nepoznate parametre artikuliranog objekta [9]. Martín-Martín i Brock procjenu kinematičkog modela vode kao neprekidan, rekurzivan postupak koji se osvježava svakim novim opažanjem tijekom interakcije, umjesto da se provodi jednom prije nje [10].

Mittal i suradnici zadatak promatraju na razini cijelog robota: gibanje platforme i manipulatora optimiraju zajedno, u prethodno nepoznatoj sceni, pri čemu se kinematički model objekta procjenjuje tijekom izvođenja [11]. Taj je rad blizak zadatku iz ovog rada

i po robotu i po postavci, uz razliku što ovdje koordinacija platforme i manipulatora nije rezultat optimizacije nego, ovisno o pristupu, unaprijed propisanog slijeda faza ili naučene politike.

Osobito je zanimljiv smjer koji ide korak dalje i tvrdi da model objekta uopće nije nužan. Zhao i suradnici pokazuju da je dovoljno održavati stabilan dodir između prihvatnice i objekta te prilagođavati gibanje prema odstupanjima koja se pritom osjete, čime robot otvara vrata i ladice bez ikakvog prethodnog znanja o njihovoj kinematici [12]. Njihov je argument izravno relevantan za ovaj rad: modeli utemeljeni na pretpostavkama gube pouzdanost kad su te pretpostavke netočne ili nepotpune, što je upravo ograničenje klasičnog pristupa iz poglavlja 6..

Za ovaj je rad posebno blizak rad Stuedea i suradnika [13], u kojem mobilni manipulator istog tipa kao u ovom radu otvara vrata i prolazi kroz njih uz kartezijsko impedancijsko upravljanje, bez poznatog modela vrata, pri čemu se kvaka detektira konvolucijskom neuronskom mrežom. Taj rad pokazuje i put kojim bi se moglo ukloniti najizraženije pojednostavljenje ovog rada, a to je oslanjanje na vizualne oznake (potpoglavlje 4.7.).

2.4. Pristupi temeljeni na učenju

Podržano učenje na zadatke mobilne manipulacije primjenjuje se jer ne zahtijeva eksplicitan model zadatka: politika strategiju stječe kroz interakciju s okolinom. Cijena je gubitak uvida u razloge pojedine odluke i ovisnost o vjernosti simulacije u kojoj se uči.

Za zadatke s kontaktom presudan je odabir prostora akcije. Martín-Martín i suradnici pokazali su da politika koja izravno zadaje momente ili položaje slabo uči zadatke bogate kontaktom, dok politika kojoj je akcijski prostor varijabilna impedancija (referentni pomak zajedno s krutošću regulatora) uči znatno uspješnije [5]. Politika tada ne uči samo kamo se gibati, nego i koliko biti popustljiva u pojedinom trenutku. Taj je akcijski prostor izravna osnova formulacije u poglavlju 7..

Taj se smjer nastavio i nakon toga. Yang i suradnici pokazali su da se politika s varijabilnom impedancijom može učiti izravno na stvarnom robotu, bez prethodnog učenja u simulaciji, oslanjajući se na malen broj nesavršenih demonstracija [14]. Zhang i suradnici krutost koriste kao sredstvo sigurnosti, tako da politika uz zadatak istovremeno uči i kada popustiti da kontaktna sila ostane u dopuštenim granicama [15]. Oba rada potvrđuju zapažanje koje se pokazalo i ovdje, da je izbor krutosti dio zadatka, a ne postavka koja se zadaje unaprijed.

Drugi smjer istraživanja bavi se time kako naučiti gibanje platforme koje manipulatoru održava kinematičku izvedivost. Honerkamp i suradnici najprije su pokazali da se politika platforme može naučiti tako da prati zadanu putanju vrha alata i drži je unutar dosega [16], a zatim taj pristup proširili na proizvoljna gibanja u nepoznatoj i promjenljivoj okolini

[17].

Osim samog upravljanja, učenje se koristi i za oblikovanje sustava. Schneider i suradnici optimiraju parametre montaže manipulatora na platformu, koristeći naučenu politiku u unutarnjoj petlji, i pokazuju da izbor montaže sam po sebi bitno mijenja uspješnost otvaranja vrata [18]. Nalaz je vrijedan i za ovaj rad, jer je manipulator i ovdje montiran izvan osi platforme, što zakretom platforme proširuje radni prostor (potpoglavlje 7.2.3.). Algoritam korišten u ovom radu je proksimalna optimizacija politike (PPO) [19], odabrana zbog stabilnosti pri velikom broju paralelnih okruženja.

2.5. Prijenos iz simulacije na stvarnog robota

Učenje u simulaciji zaobilazi trošak i opasnost prikupljanja podataka na stvarnom robotu, ali uvodi vlastiti problem: politika naučena u modelu ne mora raditi na stvarnom uređaju, jer se model i stvarnost razlikuju. Pregled postupaka kojima se taj razmak smanjuje daju Zhao i suradnici [20].

Najrasprostranjeniji je pristup nasumično variranje parametara simulacije tijekom učenja, pri čemu politika ne nauči jedan model nego obitelj njih, među kojima je i stvarni uređaj samo još jedna inačica. Tobin i suradnici taj su postupak uveli za vizualne ulaze, mijenjajući teksture i osvjetljenje [21], a Peng i suradnici proširili su ga na dinamiku, mijenjajući mase, trenja i vremenska kašnjenja [22].

Nasumično variranje dinamičkih parametara izravno je primijenjeno i u ovom radu, gdje se otpor vrata mijenja pri svakom resetu okruženja (potpoglavlje ??). Time politika ne uči jedna konkretna vrata nego raspon njih. Prijenos na stvarnog robota, međutim, nije proveden, pa zaključci ovog rada ostaju vezani uz model; ograničenja koja iz toga slijede navedena su u poglavlju 9..

2.6. Položaj ovog rada

Navedeni radovi pojedine dijelove zadatka rješavaju bolje nego ovaj rad, ali ga uglavnom promatraju odvojeno: ili razvijaju upravljanje uz poznat model objekta, ili uče politiku bez usporedbe s klasičnom alternativom. Doprinos ovog rada nije novi postupak upravljanja, nego izravna usporedba dvaju pristupa izvedenih za istog robota, istu scenu i ista mjerila uspješnosti, uključujući dva tipa vrata koja isti zadatak čine različito teškim. Time se pokušava odgovoriti na pitanje pod kojim uvjetima eksplicitno poznavanje geometrije donosi prednost, a pod kojima je gubi.

3. ROBOTSKI SUSTAV I SIMULACIJSKO OKRUŽENJE

Ovo poglavlje opisuje robotski sustav na kojem su razvijena i ispitana oba pristupa upravljanju, modele vrata koji čine radnu okolinu, postupak izrade simulacijskog modela te programsku arhitekturu koja povezuje simulator i upravljački kod. Cijeli je rad proveden u simulaciji; razlozi i posljedice tog izbora navedeni su u potpoglavljju 3.7..

3.1. KMR iiwa — mobilna platforma i manipulator

KUKA KMR iiwa (slika 1) mobilni je manipulator sastavljen od dviju serijskih komponenti: omnidirekcijske mobilne platforme KMP 200 omniMove i laganog robota LBR iiwa. Na prirubnicu manipulatora dodana je priхватnica opisana u potpoglavljju 3.2.. Kombinacija pokretljive platforme i osjetljivog manipulatora namijenjena je radu bez zaštitne ograde, u okolini u kojoj se robot kreće između radnih mjesta [23].



Slika 1. Mobilni manipulator KMR iiwa u simulacijskom okruženju

3.1.1. Mobilna platforma

Platforma se giba pomoću četiriju Mecanum kotača (slika 2). Svaki se kotač sastoji od niza valjaka postavljenih pod kutom od 45° u odnosu na os kotača, čime se postiže omnidirekcijsko gibanje — platforma se može gibati u proizvoljnom smjeru u ravnini i

istovremeno se zakretati, bez potrebe za promjenom orijentacije prije translacije. Ta je osobina bitna za zadatak otvaranja vrata, jer omogućuje da baza slijedi luk krila bez manevriranja. Tehnički podaci mobilne platforme nalaze se u tablici 1.



Slika 2. Građa Mecanum kotača [24]

Tablica 1. Tehnički podaci mobilne platforme

Veličina	Vrijednost
Dimenzije ($V \times \check{S} \times D$)	$700 \times 1080 \times 630$ mm
Masa	390 kg
Najveća nosivost	170 kg (200 kg bez manipulatora)
Brzina u uzdužnom smjeru	najviše 3,6 km/h
Brzina u poprečnom smjeru	najviše 2,0 km/h
Promjer kotača	250 mm
Klasa čistoće	ISO 5

3.1.2. Manipulator LBR iiwa 7 R800

Korišten je manipulator LBR iiwa 7 R800, redundantna kinematička struktura sa sedam rotacijskih osi. Za ovaj je rad ključno da manipulator ima senzor momenta u svakoj osi, što omogućuje procjenu sile i momenta na vrhu alata bez zasebnog senzora sile na zapešću. Sedma os čini strukturu redundantnom u odnosu na šest stupnjeva slobode zadatka, pa isti položaj i orijentaciju vrha alata ostvaruje veći broj konfiguracija. Tehnički podaci manipulatora nalaze se u tablici 2.

Tablica 2. Tehnički podaci manipulatora LBR iiwa 7 R800

Veličina	Vrijednost
Nazivna nosivost	7 kg
Broj osi	7
Doseg	800 mm
Izvedba zapešća	u liniji
Prirubnica na osi 7	DIN ISO 9409-1-A50
Ponovljivost pozicioniranja	$\pm 0,1$ mm
Točnost momenta po osi	± 2 %
Masa	23,9 kg
Stupanj zaštite	IP54
Položaj ugradnje	pod, strop, zid

Granični momenti pojedinih zglobova navedeni su u tablici 3.

Tablica 3. Granični momenti zglobova manipulatora


Zglob	1	2	3	4	5	6	7
Granični moment, Nm	176	176	110	110	110	40	40

3.2. Prihvatnica


Za hvatanje kvake izrađena je prilagođena prihvatnica (slika 3). Budući da se rad provodi isključivo u simulaciji, a stvarni prihvatni uređaj nije bio zadan, prihvatnica je oblikovana kao zamjenjiva komponenta, tj. upravljanje njome potpuno je odvojeno od ostatka softvera (potpoglavlje 3.8.), pa se može zamijeniti bez izmjena u ostatku sustava.

Prihvatnica ima četiri prsta raspoređena u dva para koja se zatvaraju duž osi x baze, dok uhvaćena šipka leži duž osi y . Svaki prst na sebi ima utor čiji je unutarnji luk prilagođen šipki kvake promjera 28 mm. Pri potpuno zatvorenom hvatu otvor između prstiju uži je od šipke, pa hvat ne počiva na geometrijskom dosjedanju nego na sili pogona i popustljivosti prstiju. Time se izbjegava zazor koji bi pri guranju vrata dopustio da se kvaka pomiče unutar hvata. Položaj vrha alata (*TCP*, engl. *tool center point*) može se vidjeti na slici 4. Značajke prihvatnice nalaze se u tablici 4.

Parovi prstiju ne gibaju se savršeno simetrično, pa se predmet ne centrira sam od sebe. Ta se asimetrija ne pokušava ukloniti, nego se mjeri: tijekom prilaza kvaki uspoređuju se položaji suprotnih prstiju i iz razlike se izračunava bočna korekcija kojom se prihvatnica poravna nad kvakom prije nego što se hvat zatvori. Postupak je opisan u potpoglavlju 6.2..



Slika 3. Prihvatnica s četiri prsta; otvorena (lijevo) i zatvorena (desno)



Slika 4. Položaj vrha alata (*TCP*)

Tablica 4. Značajke prihvatnice

Značajka	Vrijednost
Promjer prirubnice	63 mm
Dimenzije nosive ploče	85 × 85 mm
Duljina prsta	66,5 mm
Unutarnji polumjer utora	16 mm
Hod po prstu	0–25 mm
Masa nosivog dijela	442 g
Masa prsta	30,6 g
Ukupna masa	564 g
Položaj vrha alata iznad prirubnice	74,85 mm
Statički koeficijent trenja prstiju	1,2
Dinamički koeficijent trenja prstiju	1,0

Vrh alata leži na osi alata, na visini od 74,85 mm iznad prirubnice manipulatora. Ta visina odgovara središtu unutarnjeg luka kuka pri zatvorenom hvatu, dakle visini na kojoj se nalazi os uhvaćene šipke. Vrh alata time nije materijalna točka na prihvatnici, nego sjecište osi alata i osi predmeta u hvatu, čime regulator momente računa oko stvarnog hvatišta.

Prsti su u simulacijskom modelu upravljani pozicijski, s krutošću pogona 20 000 N/m, prigušenjem 200 Ns/m i graničnom silom 600 N. Pri guranju vrata silu prenose djelotvorno samo dva od četiriju prstiju, jer jedan par radi protiv vlastitog pogona, pa je djelotvorna krutost hvata polovica nominalne. Ta je pojedinost bitna za tumačenje rezultata u poglavlju 8..

3.3. Kamera i njezin nosač

Za detekciju kvake robot je opremljen kamerom Intel RealSense D435, postavljenom na mobilnu platformu pomoću vlastito izrađenog nosača (slika 5). Sam postupak detekcije i procjene poze opisan je u poglavlju 4.; ovdje je opisana samo montaža i pripadni koordinatni sustavi.

Nosač kamere oblikovan je tako da iskoristi postojeće provrte na platformi. Manipulator se na platformu pričvršćuje preko četiri provrta promjera 13,3 mm raspoređena po kružnici polumjera 108 mm. Ta je kružnica na platformi izvedena zrcalno s obje strane, a strana suprotna manipulatoru ostaje slobodna, pa je nosač kamere postavljen upravo na nju. Time montaža ne zahtijeva nikakvu izmjenu platforme.



Slika 5. Kamera i nosač kamere postavljeni na robotu

Kamera je smještena na visini gornje plohe platforme, bočno pomaknuta u odnosu na manipulator. Time je kvaka u vidnom polju i tijekom prilaza i tijekom hvata, a kamera ne ulazi u radni prostor manipulatora. Nosač je zamišljen kao izradak aditivnom pro-

izvodnjom; masa od 193 g izračunata je iz obujma modela uz gustoću materijala PETG od 1270 kg/m^3 .

Kamera u modelu ima dva koordinatna sustava. Prvi je vezan uz kućište i služi za montažu, a drugi je optički koordinatni sustav u kojem se izražavaju rezultati detekcije. Optički je zaokrenut u odnosu na kućište prema uobičajenoj konvenciji, pri čemu os z gleda u smjeru promatranja, a osi x i y leže u ravnini slike. Ta konvencija nije proizvoljna nego je očekuju biblioteke za obradu slike, pa je zadržana kako procjena poze ne bi zahtijevala dodatnu pretvorbu.

Kamera podržava i dubinsku sliku, no ona u ovom radu nije korištena. Detekcija vrata i kvake odvija se isključivo iz slike u boji, pomoću oznaka AprilTag, a postignuta točnost pokazala se dovoljnom i bez dubinske informacije.


3.4. Lidar

Uz kameru, robot je opremljen i dvodimenzijskim laserskim skenerom (lidarom), postavljenim na prednjoj strani mobilne platforme. Za razliku od kamere, koja služi isključivo detekciji kvake (poglavlje 4.), lidar se koristi za dvije zadaće vezane uz neposrednu okolinu robota: otkrivanje prepreka ispred platforme tijekom otvaranja vrata i pronalaženje otvora u zidu radi prolaska kroz vrata. Obje su zadaće opisane u poglavlju 6., u opsegu klasičnog pristupa; pristup temeljen na učenju ne koristi lidar direktno, već očitava pozicije zidova izravno iz simulatora.

Senzor ima i minimalni domet ispod kojeg mjerenja nisu pouzdana. Budući da je kvaka nakon hvata na udaljenosti od tek oko 0,65 m od senzora, unutar tog dometa krilo vrata ostaje nevidljivo, pa je vrijednost minimalnog dometa u konfiguraciji senzora spuštена na 0,05 m.

3.5. Modeli vrata

Radnu okolinu čine dva modela vrata, zakretna i klizna (slika 6). Oba su izgrađena od osnovnih geometrijskih tijela, s istim krilom, a razlikuju se stupnjem slobode gibanja i oblikom kvake. Zajednička geometrija je namjerna: razlika u ponašanju dvaju pristupa time se ne može pripisati razlici u dimenzijama ili masi krila. Geometrijska i inercijska svojstva vrata mogu se vidjeti u tablici 5.



Slika 6. Modeli zakretnih i kliznih vrata s označenim stupnjem slobode gibanja

Tablica 5. Geometrija i inercijska svojstva modela vrata

Veličina	Zakretna vrata	Klizna vrata
Krilo, dimenzije	$40 \times 850 \times 2000$ mm	$40 \times 850 \times 2000$ mm
Krilo, masa	15 kg	15 kg
Nepomični dio	stup $60 \times 60 \times 2000$ mm	vodilica $60 \times 2000 \times 60$ mm
Stupanj slobode	rotacija oko osi z	translacija duž osi y
Raspon gibanja	$0-135^\circ$	$0-1,0$ m
Kvaka, oblik	poluga, duljina 160 mm	šipka, duljina 250 mm
Kvaka, promjer šipke	28 mm	28 mm
Kvaka, masa	0,35 kg	0,35 kg
Visina hvatišta	1000 mm	1000 mm

Kod zakretnih vrata kvaka je izvedena kao poluga usmjerena prema osi šarke, kako je uobičajeno kod stvarnih vrata. Zglob brave, koji bi omogućio zakretanje kvake, zavaren je u nepomični zglob u oba pristupa, pa je jedini pokretni stupanj slobode zakretnih vrata os šarke. Okretanje kvake time je izvan opsega rada; razlog i posljedice te odluke navedeni su u potpoglavlju 6.6.. Posljedica koju treba imati na umu jest da se cijeli moment šarke prenosi trenjem prstiju na šipki kvake.

Kod kliznih vrata kvaka je okomita šipka pričvršćena dvama odstojećima, pa je hvatište

dostupno s prednje strane krila po cijeloj visini šipke.

Vrata su s obje strane omeđena zidom, izvedenim kao dva zasebna, nepomična elementa, svaki dimenzija $0,06 \times 2,5 \times 2,0$ m i mase 15 kg. Zidovi su postavljeni tako da između njih ostaje slobodan prolaz od 0,85 m, jednak širini krila vrata, čime nastaje realistična okolina vrata umjesto izoliranog objekta u praznom prostoru. Ta je okolina preduvjet za dvije zadaće opisane u poglavlju 6.. Lidar treba stvarnu prepreku da bi u njoj prepoznao otvor, a MoveIt treba stvarnu geometriju zida da bi je uzeo u obzir pri planiranju gibanja manipulatora.

3.5.1. Otpor gibanja i njegovo nasumično variranje

Otpor vrata nije zapisan u geometrijskom modelu, nego se postavlja pri svakom pokretanju epizode iz zadanog raspona. Time politika nije vezana uz jednu vrijednost otpora, nego uči raditi na rasponu vrata. Otpor je razdvojen na dva fizikalno različita člana:

$$\tau_{\text{otpor}} = \tau_{\text{tr}} + d\dot{q}, \quad (1)$$

gdje je q koordinata jedinog stupnja slobode vrata, dakle kut zakreta krila kod zakretnih odnosno pomak krila kod kliznih vrata, a $\dot{q}$ njegova derivacija po vremenu, to jest brzina otvaranja. Član τ_{tr} Coulombovo je trenje, konstantno po iznosu i neovisno o brzini, dok je d koeficijent viskoznog prigušenja, koji daje otpor razmjern brzini. Izraz je zapisan općenito za oba tipa vrata: kod zakretnih su τ_{otpor} i τ_{tr} momenti, a kod kliznih sile.

Parametri se zadaju u apsolutnim jedinicama, dakle u njutnima za prizmatični i njutnmetrima za revolutni zglobov, a ne kao bezdimenzijski koeficijenti. Da bi se to potvrdilo, provedeno je mjerenje u simulaciji. Vratima je zadana poznata vrijednost trenja, a zatim je polagano rastućom silom određena sila pri kojoj se vrata pokrenu. Omjer izmjerene sile pokretanja i zadanog trenja kretao se između 1,00 i 1,03 za zadane vrijednosti trenja u rasponu od 5 do 60 N, čime je potvrđeno da zadana vrijednost izravno odgovara sili potrebnoj za pokretanje vrata.

U tablici 6 mogu se vidjeti rasponi iz kojih su birane vrijednosti otpora vrata:

Tablica 6. Rasponi iz kojih se bira otpor vrata

Tip vrata	Trenje	Prigušenje
Klizna	5–60 N	5–50 Ns/m
Zakretna	0,5–5 Nm	0,5–5 Nms/rad

Rasponi nisu određeni mjerenjem na stvarnim vratima, nego su usvojeni kao inženjerska procjena, sa širinom raspona odabranom tako da obuhvati i lagana i teška vrata. Svrha

im nije vjerno preslikati određena vrata, već spriječiti da naučena politika ovisi o jednoj vrijednosti otpora.

3.6. Model robota i pretvorba u simulacijski format

Geometrijski i kinematički model robota opisan je u formatu *Unified Robot Description Format* (URDF). Model manipulatora preuzet je iz javno dostupnog paketa `iiwa_stack` [25], a model mobilne platforme iz proizvođačeve dokumentacije [23]. Prihvatnica, nosač kamere i oba modela vrata izrađeni su u sklopu ovog rada. Model je organiziran pomoću `xacro` predložaka, tako da se prihvatnica u model uključuje jednim pozivom makronaredbe.

Isaac Sim ne koristi URDF izravno, nego format *Universal Scene Description* (USD). Pretvorba nije jedan korak nego niz skripti, jer sama pretvorba ne prenosi sve što je za rad potrebno.


Osnovnu pretvorbu obavlja `convert_urdf_usd.py`, proširena inačica alata iz Isaac Laba. Dvije su postavke pritom bitne:

- **Vrsta kolidera** (engl. *collider type*). Prsti prihvatnice moraju se pretvarati postupkom konveksne dekompozicije. Zamotavanje u konveksnu ovojnici zatvorilo bi utore na prstima i prihvatnica ne bi mogla obuhvatiti šipku.
- **Sažimanje nepomičnih zglobova**. Ne smije se primijeniti na model robota, jer bi uklonilo zglob na kojem se očitavaju sile i momenti (potpoglavlje 3.2.).

Na dobiveni model zatim se primjenjuju tri naknadne skripte:

- `apply_gripper_friction.py` pridružuje materijal trenja ploham prstiju i kvaka. Pridruživanje se ne može izvesti izravno na složenoj sceni, jer se geometrija prsta, referencirana četiri puta iz iste datoteke, pojavljuje kao instancirani sloj u koji nije dopušteno upisivati; skripta zato pronalazi stvarni sloj u kojemu se geometrija nalazi i materijal upisuje u njega.
- `add_arm_ros_control_graph.py` umeće graf koji povezuje zglobove manipulatora s temama ROS-a 2, čime se model može voditi izvana. Graf mora biti ugniježđen unutar stabla osnovnog elementa modela, jer se inače pri referenciranju modela u scenu tiho izgubi.
- `add_camera_ros_graph.py` dodaje kameru s izmjerenim unutarnjim parametrima i položajem te objavljuje sliku i stabla koordinatnih sustava.

Na slici 7 može se vidjeti dijagram toka pretvorbe datoteka iz URDF formata u simulatoru koriste datoteke u USD formatu.



Slika 7. Postupak izrade simulacijskog modela iz opisa robota i vrata

Za učenje se koristi zasebna inačica modela. Iz modela vrata uklonjeni su nosivi elementi oznaka za percepciju, jer tijela mase 0,001 kg uz krilo mase 15 kg loše uvjetuju numerički postupak rješavanja. Nazivi članaka i zglobova ujednačeni su između obaju tipova vrata, čime jedna programska implementacija okruženja posluži oba tipa bez grananja po tipu vrata.

3.6.1. Gibanje mobilne platforme

Mecanum kotači nisu simulirani kao tijela u kontaktu s podlogom. Umjesto toga, gibanje platforme zadaje se kinematički: naredba brzine iz poruke `/cmd_vel` pretvara se u pomake platforme po osima x i y te zakret oko osi z . U okruženju za učenje isti je mehanizam ostvaren trima pomoćnim zglobovima umetnutima između nepomičnog ishodišta i članka platforme, pa se platforma giba kao dio iste kinematičke strukture kao i manipulator.

Korijen kinematičke strukture pritom ostaje nepomičan. To je nužno jer regulator u operacijskom prostoru, opisan u poglavlju 7., računa jakobijan i matricu inercije uz pretpostavku nepomičnog korijena; uz slobodan korijen kompenzacija gravitacije ispada neispravna.

Zanemarivanje dinamike kotača pojednostavljenje je koje uklanja proklizavanje, elastičnost valjaka i ograničenja pogona kotača. Za zadatak u kojem se platforma giba malim brzinama i u kojem su zanimljive sile na vrhu alata, a ne na kotačima, to je prihvatljivo, ali ograničava prenosivost rezultata na stvarnog robota. Ograničenje je navedeno u poglavlju 9..

3.6.2. Odometrija

Prijeđeni put platforme ne računa se iz naređene brzine i vremena, nego se mjeri. Most prema simulatoru objavljuje odometriju izvedenu iz stvarne poze članka platforme u sceni, pa se podudara sa stvarnim stanjem. Budući da platforma u modelu nema kotače, nego je predstavljena jednim kolizijskim tijelom, enkodera iz kojih bi se odometrija inače izvela nema.

Uporaba te veličine u upravljanju ipak ne narušava načelo da se stanje simulacije ne čita u regulacijskoj petlji. Odometrija je senzorska veličina koju stvarni KMR iiwa posjeduje i objavljuje kao dio isporučene programske podrške, za razliku od, primjerice, kuta zgloba vrata, koji na stvarnom robotu ne bi bio dostupan. Razlika je u tome što je ovdje riječ o savršenoj odometrij, bez proklizavanja i bez akumulirajućeg odstupanja, što stvarni enkoderi imaju.

3.7. Simulacijsko okruženje

Simulacija se izvodi u okruženju NVIDIA Isaac Sim, uz biblioteku Isaac Lab [26] za paralelno učenje. Fizika se rješava pogonom PhysX. Cijeli je rad proveden u simulaciji jer stvarni robot nije bio dostupan, a zadatak zahtijeva velik broj ponavljanja interakcije s kontaktom, što na stvarnom robotu nije izvedivo u opsegu završnog rada.

Bitna je značajka postava razdvajanje odgovornosti: geometrijski model nosi topologiju i geometriju, a sva pojačanja pogona i svojstva otpora zadaju se u konfiguraciji okruže-

nja. Time se izbjegava da se naučena politika veže uz jednu konkretnu datoteku modela umjesto uz raspon uvjeta.

Pogoni osi manipulatora postavljeni su na nultu krutost i prigušenje. Momente računa regulator u operacijskom prostoru i zadaje ih izravno; da je zadržana krutost iz pretvorbe, pogon i regulator djelovali bi jedan protiv drugoga i krutost koju politika zada ne bi imala učinka. Pogon platforme brzinski je, s prigušenjem 10^4 , a pogon prstiju pozicijski, s vrijednostima navedenima u potpoglavlju 3.2..

Programska i sklopovska konfiguracija može se vidjeti u tablici 7.

Tablica 7. Programska i sklopovska konfiguracija

Stavka	Vrijednost
Operacijski sustav	Ubuntu 22.04 LTS
Simulator	NVIDIA Isaac Sim 5.1.0
Biblioteka za učenje	Isaac Lab 2.3.2
Robotski operacijski sustav	ROS 2 Humble
Python (Isaac Lab)	3.11.15
Python (ROS 2)	3.10.12
Procesor	AMD Ryzen 7 260
Grafička kartica	NVIDIA GeForce RTX 5050, 8 GB VRAM
Radna memorija	32 GB DDR5

3.8. Programska arhitektura

Softver je podijeljen u pakete unutar radnog prostora ROS 2, navedene u tablici 8. Podjela slijedi funkcionalne cjeline rada: opis robota, percepcija, veza sa simulatorom, izvođenje zadatka, konfiguracija i pokretanje sustava.


Tablica 8. Paketi radnog prostora ROS 2

Paket	Sadržaj
<code>kmr_iiwa_description</code>	modeli robota, prihvatnice, kamere i vrata
<code>kmr_iiwa_perception</code>	detekcija oznaka, fuzija poze, procjena sile i momenta
<code>kmr_iiwa_sim_bridge</code>	veza sa simulatorom: platforma, prihvatnica, kamera
<code>kmr_iiwa_task</code>	izvođenje zadatka i procjena ograničenja gibanja
<code>kmr_iiwa_moveit_config</code>	konfiguracija planiranja gibanja manipulatora
<code>kmr_iiwa_bringup</code>	pokretanje cjelokupnog sustava

Isaac Sim nema izvornu podršku za sučelje `ros2_control`, pa je veza sa simulatorom


ostvarena vlastito izrađenim čvorovima koji prevode poruke ROS 2 u naredbe simulatoru. Upravljanje prihvaticom namjerno je izvedeno kao potpuno odvojena cjelina: jedini čvor koji zna da prihvatica ima četiri prizmatična zgloba i hod od 25 mm jest njezin upravljački čvor, dok ostatak sustava prihvaticu vidi kroz jedan broj u rasponu od nula do jedan, uz povratnu informaciju o trenutnom položaju i o tome je li zaustavljena prije dolaska u zadani položaj. Time je zadovoljen zahtjev iz potpoglavlja 3.2. da se prihvatica može zamijeniti bez izmjena u ostatku sustava.

Na slici 8 može se vidjeti dijagram arhitekture za klasični pristup.



Slika 8. Programska arhitektura klasičnog pristupa

Pristup temeljen na učenju koristi bitno jednostavniju arhitekturu (slika 9). Tijekom učenja ROS 2 nije u regulacijskoj petlji: okruženje, regulator i politika izvode se unutar Isaac Laba, izravno nad tenzorima na grafičkoj kartici. Razlog je paralelizacija — učenje se izvodi u više stotina istovremenih okruženja, a posredovanje kroz ROS 2 bilo bi usko grlo. Veza s ROS-om potrebna je tek pri izvođenju naučene politike izvan simulacije, što nije bilo u opsegu ovog rada i opisano je u poglavlju 8..



Slika 9. Programska arhitektura pristupa temeljenog na učenju

4. MODUL PERCEPCIJE

Zadatak modula percepcije jest odrediti položaj i orijentaciju hvatišta kvake iz slike, u koordinatnom sustavu vezanom uz robota, kako bi se manipulator mogao voditi prema hvatištu bez unaprijed poznatog položaja vrata. Fizička izvedba kamere i njezina montaža opisane su u potpoglavlju 3.3.; ovdje je opisan postupak obrade slike i izlaz koji modul daje ostatku sustava.

4.1. Odabir pristupa


Procjena poze provodi se pomoću vizualnih oznaka postavljenih na vrata i kvaku. Oznake su odabrane jer daju potpunu procjenu poze s poznatom mjernom nesigurnošću iz jedne slike, bez prethodnog učenja i bez skupa označenih primjera. To je u ovom radu bitno, jer je fokus zadatka na upravljanju u kontaktu, a ne na prepoznavanju objekata; oznake omogućuju da modul percepcije bude pouzdan ulaz za ostatak sustava, umjesto da sam postane predmet istraživanja.

Uporaba oznaka istovremeno je i najveće pojednostavljenje u radu. Stvarna vrata nemaju oznake, pa robot s ovakvim modulom ne bi radio izvan pripremljene okoline. Postupci koji ne zahtijevaju oznake postoje — Stuede i suradnici za isti zadatak i isti tip robota kvaku detektiraju konvolucijskom neuronskom mrežom [13] — ali traže skup podataka i vrijeme učenja koji nisu bili u opsegu ovog rada. Posljedice su navedene u potpoglavlju 4.7..

Od dviju uobičajenih obitelji oznaka odabran je AprilTag [27], i to zbog zrelijih detekcijskih biblioteka u sustavu ROS 2 te točnije procjene orijentacije pri malim oznakama nego što je daju usporedive alternative.

4.2. Raspored oznaka

Na svakim vratima nalaze se tri oznake (slika 10), raspoređene prema tablici 9. Podjela na jednu veliku i dvije male oznake slijedi iz toga što prilaz i hvat imaju različite zahtjeve. Velika oznaka na sredini krila služi fazi prilaza. Njezina veličina omogućuje pouzdanu detekciju s udaljenosti od dva do tri metra, dakle iz položaja u kojem robot započinje zadatak. U toj fazi nije potrebna velika točnost, nego samo dovoljno dobra procjena smjera i udaljenosti da se platforma dovede pred vrata.




Slika 10. AprilTagovi: sredina vrata (gore), kvaka (A dolje lijevo, B dolje desno)

Dvije male oznake na krajevima kvake služe fazi hvata, na radnoj udaljenosti od otprilike jednog do jednog i pol metra. Njihova je veličina ograničena promjerom šipke kvake, koji iznosi 28 mm, pa je za njih odabrana obitelj s mrežom 4×4 umjesto 6×6 : pri istoj duljini stranice takva oznaka ima krupnija polja i ostaje čitljiva na većoj udaljenosti. Cijena je manja Hammingova udaljenost među kodovima, dakle veća sklonost lažnim detekcijama, što je ublaženo time da modul očekuje unaprijed poznate identifikatore i provjerava je li izmjereni razmak dviju oznaka u očekivanom rasponu.

Tablica 9. Raspored vizualnih oznaka na vratima

Oznaka	Vrata	Nosivi članak	Veličina	Obitelj
središnja	oba	krilo	80 mm	tag36h11
kvaka, <i>A</i>	zakretna	poluga kvake	25 mm	tag16h5
kvaka, <i>B</i>	zakretna	poluga kvake	25 mm	tag16h5
kvaka, <i>A</i>	klizna	šipka kvake	25 mm	tag16h5
kvaka, <i>B</i>	klizna	šipka kvake	25 mm	tag16h5

Razmak dviju malih oznaka razlikuje se po tipu vrata i iznosi 130 mm na zakretnim te 220 mm na kliznim vratima, jer je kod zakretnih vrata poluga kvake vodoravna i kraća, a kod kliznih je šipka okomita i dulja. Raspored je prikazan na slici 11.



Slika 11. Raspored vizualnih oznaka na zakretnim (lijevo) i kliznim (desno) vratima

4.3. Detekcija oznaka

Detekcija se provodi gotovim paketom `apriltag_ros` za sustav ROS 2, koji iz slike u boji i unutarnjih parametara kamere daje potpunu pozu svake prepoznate oznake u optičkom koordinatnom sustavu kamere. Kako jedan primjerak čvora obrađuje samo jednu obitelj oznaka, pokreću se dva primjerka, po jedan za veliku i za male oznake.

Slika i unutarnji parametri kamere dolaze izravno iz simulatora, kao i cijelo stablo koordinatnih sustava robota. Objavljivanje stabla nije samorazumljivo: uvoz modela ne stvara ga sam od sebe, nego ga je trebalo dodati zasebno pri izradi simulacijskog modela (potpoglavlje 3.6.).

4.4. Fuzija dviju oznaka na kvaki

Poza kvake ne uzima se od pojedine oznake, nego se računa iz obiju. Razlog je osjetljivost procjene orijentacije na veličinu oznake: pri stranici od 25 mm i udaljenosti od preko jednog metra procjena orijentacije pojedine oznake znatno je nesigurnija od procjene položaja. Dvije oznake razmaknute 130 odnosno 220 mm daju mjernu bazu red veličine dulju od stranice same oznake, pa se smjer duž kvake iz njihovih položaja procjenjuje bitno pouzdanije nego iz orijentacije bilo koje pojedine oznake.

Neka su $\mathbf{p}_A$ i $\mathbf{p}_B$ položaji dviju oznaka, a $\mathbf{z}_A$ i $\mathbf{z}_B$ njihove normale, sve izraženo u koordinatnom sustavu robota. Položaj hvatišta uzima se kao polovište

$$\mathbf{p} = \frac{1}{2} (\mathbf{p}_A + \mathbf{p}_B). \quad (2)$$

Os y hvatišta postavlja se duž kvake, iz razlike položaja dviju oznaka:

$$\mathbf{e}_y = \frac{\mathbf{p}_B - \mathbf{p}_A}{\|\mathbf{p}_B - \mathbf{p}_A\|}. \quad (3)$$

Preostale dvije osi izvode se iz normala oznaka. Njihova srednja vrijednost $\bar{\mathbf{z}} = \frac{1}{2}(\mathbf{z}_A + \mathbf{z}_B)$ općenito nije okomita na $\mathbf{e}_y$, pa se ortogonalizira Gram-Schmidtovim postupkom:

$$\mathbf{e}_z = \frac{\bar{\mathbf{z}} - (\bar{\mathbf{z}} \cdot \mathbf{e}_y) \mathbf{e}_y}{\|\bar{\mathbf{z}} - (\bar{\mathbf{z}} \cdot \mathbf{e}_y) \mathbf{e}_y\|}, \quad \mathbf{e}_x = \mathbf{e}_y \times \mathbf{e}_z. \quad (4)$$

Matrica rotacije hvatišta jest $\mathbf{R} = [\mathbf{e}_x \ \mathbf{e}_y \ \mathbf{e}_z]$. Ovakav postupak nije usrednjavanje dviju poza, nego prilagodba krutog tijela dvjema izmjerenim točkama, pri čemu se od pojedinih oznaka preuzima samo ono što one dobro mjere: položaj u cijelosti, a od orijentacije samo normala.

Prije računanja provode se dvije provjere. Uspoređuju se vremenske oznake dviju detekcija, da se ne spoje mjerenja iz različitih trenutaka, i provjerava se je li njihov razmak unutar raspona od 50 do 400 mm, čime se odbacuju lažne detekcije. Usporedba vremenskih oznaka provodi se međusobno, između dviju detekcija, a ne u odnosu na sat računala, jer simulator ne objavljuje vlastito vrijeme, pa bi takva usporedba spajala dvije nepovezane vremenske domene.

4.5. Sučelje modula i radni doseg

Modul objavljuje pozu hvatišta na jednoj temi, s frekvencijom od 10 Hz, izraženu u koordinatnom sustavu platforme. Time je sučelje prema ostatku sustava svedeno na jednu poruku, neovisno o tome koliko je oznaka i kojih obitelji upotrijebljeno, pa se postupak detekcije može zamijeniti bez izmjena u kodu koji izvodi zadatak.

Dvije skupine oznaka imaju bitno različit radni doseg. Središnja oznaka pouzdano se detektira s udaljenosti od dva do tri metra, pa pokriva cijelu fazu prilaza. Male oznake na kvaki traže udaljenost manju od otprilike 1.2 m, i to ne zbog razlučivosti nego zbog vidnog polja: bliže od te udaljenosti gornja oznaka izlazi iz kadra, a procjena smjera duž kvake gubi jednu od dviju mjernih točaka i orijentacija hvatišta se raspada.

Ta udaljenost istovremeno je veća od dosega manipulatora pri nepomičnoj platformi, pa se poza kvake očita s ruba radnog dosega, a platforma se tek nakon toga primakne. Kako platforma nema odometriju, poza kvake pritom se rekonstruira iz njezina nepromjenjivog odnosa prema središnjoj oznaci. Postupak je opisan u potpoglavlju 6.2..


4.6. Preciznost percepcijskog modula

Provedeno je testiranje točnosti i preciznosti percepcijskog modula, čiji se rezultati mogu vidjeti u tablici 10 te na slici 12. Testiranje je provedeno tako da se robot dovodio

na nasumične pozicije ispred vrata tako da kamera vidi oznake na kvaki. Zatim se uz pomoć vlastito izrađene skripte `perception_accuracy_logger.py` očitala poza hvatišta koju daje percepcijski modul i uspoređivala sa stvarnom pozom dobivenom iz simulatora. Postupak je ponovljen 15 puta za obje vrste vrata.

Tablica 10. Točnost procjene poze hvatišta, 30 mjernih točaka

Veličina	Jedinica	Srednja vrijednost	Std. devijacija	Najveća
Pogreška položaja	mm	17.07	9.01	44.82
okomito na kvaku	mm	15.59	9.47	44.81
duž kvake	mm	5.74	2.70	11.95
Pogreška smjera kvake	°	2.13	2.82	11.48
Pogreška orijentacije	°	4.88	5.76	23.97
Rasip procjene položaja	mm	1.29	0.75	3.90



Slika 12. Ovisnost pogreške položaja i smjera kvake o udaljenosti hvatišta od robota

Može se primijetiti da je odstupanje položaja i smjera kvake veće pri većim udaljenostima, a pri manjim udaljenostima je pogreška svega desetak milimetara, odnosno par stupnjeva. Kako se poza hvatišta traži tek kad je robot dovoljno blizu vratima (oko 1.2 m), pogreška percepcije je dovoljno mala da ne igra veliku ulogu. Pogreška se kasnije kompenzira prilikom faze hvata, kako je opisano u 3.2. i 6.2..

4.7. Ograničenja

Oznake na vratima. Modul pretpostavlja pripremljenu okolinu i na stvarnim vratima ne bi radio bez prethodnog postavljanja oznaka. To je najizraženije pojednostavljenje u radu. Prijelaz na detekciju bez oznaka mijenja modul percepcije, ali ne i ostatak sustava, jer je sučelje prema izvođenju zadatka svedeno na pozu hvatišta.

Percepcija se ne koristi pri učenju. Pristup temeljen na učenju u fazi učenja uzima pozu kvake izravno iz simulacije, kao povlaštenu informaciju. Razlog je paralelizacija: postupak detekcije radi nad jednim tokom slike i na procesoru, pa bi njegovo provođenje kroz stotine istovremenih okruženja onemogućilo učenje u razumnom vremenu. Modul percepcije time je alat za provjeru i izvođenje, a ne dio petlje učenja. Posljedica je razlika između uvjeta učenja i uvjeta izvođenja, o kojoj se raspravlja u poglavlju 8.

Dubinska slika nije korištena. Sve procjene proizlaze iz slike u boji i poznate veličine oznaka. Dubinski kanal kamere ostaje neiskorišten, pa bi se pri prijelazu na detekciju bez oznaka mogao iskoristiti kao dodatni izvor podataka.

Model kamere. Položaj optičkog središta u modelu kamere određen je iz geometrije kućišta, uz pretpostavku da je poprečni pomak zanemariv. Očekivana je pogreška reda nekoliko milimetara, što je na radnoj udaljenosti od preko jednog metra zanemarivo, ali bi pri radu na manjim udaljenostima trebalo biti izmjereno.

Slika iz simulatora nije izobličena. Simulator daje sliku iz idealnog modela kamere, bez izobličenja leće, pa se koristi izravno. Stvarna kamera zahtijevala bi prethodno ispravljanje slike, što je dodatan korak koji u ovom postavu nije bio potreban.

5. PROCJENA SVOJSTAVA OKOLINE

Zadatak traži da robot svojstva okoline procjenjuje iz mjerenja sile i momenta tijekom interakcije, a ne da mu se ona zadaju unaprijed. Ovo poglavlje opisuje kako se iz veličina dostupnih na robotu dolazi do sile i momenta na vrhu alata, te kako se iz njihova odnosa prema gibanju u načelu procjenjuju svojstva okoline poput krutosti i ograničenja gibanja. Naglasak je na tome da su sve procjene izvedene isključivo iz veličina koje bi imao i stvarni robot (poze vrha alata i procijenjene sile) a nikada iz stanja zglobova vrata, koje simulator doduše zna, ali stvarni robot ne bi. Stanje zgloba vrata koristi se samo kao referentna vrijednost pri provjeri procjenitelja, nikada u upravljačkoj petlji.

5.1. Procjena sile i momenta na vrhu alata

Manipulator nema zaseban senzor sile na zapešću, nego se sila i moment na vrhu alata procjenjuju iz momenata u zglobovima. Veza je posljedica načela virtualnog rada: za manipulator u ravnoteži, moment u zglobovima koji uravnotežuje vanjsku silu i moment na vrhu alata dan je izrazom

$$\boldsymbol{\tau} = \mathbf{J}^T(\mathbf{q}) \mathbf{w}, \quad (5)$$

gdje je $\boldsymbol{\tau}$ vektor momenata u zglobovima, $\mathbf{q}$ vektor zglobnih koordinata, $\mathbf{J}(\mathbf{q})$ Jakobijan manipulatora, a $\mathbf{w} = [\mathbf{F}^T \ \mathbf{M}^T]^T$ vektor sile i momenta na vrhu alata (engl. *wrench*). Procjena sile i momenta dobiva se rješavanjem tog sustava po $\mathbf{w}$.

Za manipulator sa sedam zglobova i šesterodimenzijskim vektorom sile i momenta sustav (5) je preodređen, pa se rješava u smislu najmanjih kvadrata pomoću Moore-Penroseova pseudoinverza transponiranog Jakobijana:

$$\hat{\mathbf{w}} = (\mathbf{J}^T)^+ \boldsymbol{\tau}. \quad (6)$$

Jakobijan se računa iz trenutne konfiguracije manipulatora, dobivene iz stabla koordinatnih sustava, pa procjena ne zahtijeva nikakav dodatan senzor osim već postojećih mjerila momenta u zglobovima.

5.1.1. Svojstva i ograničenja procjene

Izraz (6) pretpostavlja da je izmjereni moment u zglobovima posljedica isključivo sile i momenta na vrhu alata. U stvarnosti mjereni moment sadrži i doprinos vlastite težine manipulatora i prihvatnice, koji o kontaktu ništa ne govori. `tcp_wrench_estimator` tu

težinu ne kompenzira proračunom, nego je uklanja umjerivanjem: neposredno prije zanimljivog dijela zadatka, dok manipulator miruje u konfiguraciji bliskoj onoj u kojoj će se odvijati kontakt i dok kontakta još nema, očitani se moment pohrani kao poravnanje na nulu (*tare*) i oduzima od svih narednih očitavanja. Umjeravanje je stoga vezano uz konfiguraciju: ono uklanja gravitacijski doprinos onoj pozi u kojoj je izvedeno, a odstupanje raste kako manipulator odmiče od te poze u sljedećim koracima gibanja.

Ni nakon umjeravanja procjena nije bez pogreške. U slobodnom gibanju, bez kontakta, procjena sile pokazuje šum reda pola njutna, što je razina ispod koje se kontakt ne može pouzdano razlučiti od mjerne nesigurnosti. Procjena momenta uz to zadržava sustavni rezidual reda desetak njutnmetara, koji potječe od preostale, nepotpuno uklonjene dinamike manipulatora, ponajviše iz odstupanja stvarne poze od one u kojoj je umjeravanje provedeno. Na tipičnom kraku hvata taj rezidual odgovara sili reda dvadesetak njutna.

Posljedica je da procjena dobro razlučuje smjer i prisutnost kontaktne sile, ali njezin apsolutni iznos treba uzimati s obzirom na navedeni rezidual, a umjeravanje treba ponoviti kad god se manipulator znatnije udalji od poze u kojoj je posljednje umjeravanje provedeno. Ponovno umjeravanje tijekom zadatka provodi se uvjetno, samo kad je trenutno očitana sila već niska. U suprotnom bi se u nulu upisala stvarna kontaktna sila, umjesto samo preostalog gravitacijskog doprinosa. Za upravljanje u ovom radu to je dovoljno, jer se sila koristi za otkrivanje kontakta i za ograničavanje njezina iznosa, a ne kao precizno mjerilo.

5.2. Ispitivanje ograničenja gibanja

Iz procijenjene sile i istovremeno mjerenog gibanja može se utvrditi u kojim je smjerovima gibanje vrata slobodno, a u kojima ograničeno. Postupak je izveden kao zasebna rutina (`door_probe.py`) koja se pokreće iz uspostavljenog hvata. Vrh alata izvodi male, silom nadzirane pomake u šest smjerova, uzduž triju osi koordinatnog sustava prihvatnice u oba smjera, po četiri koraka od 3 mm.

5.2.1. Mjera koja razlikuje slobodan smjer od ograničenog

Kriterij nije iznos sile, već koeficijent sile po naredenom pomaku, izražen u njutnima po metru. Razlika između dvaju slučajeva jasno je vidljiva u obliku niza očitavanja. U slobodnom smjeru sila naraste do razine potrebne da se svlada trenje u zglobovima vrata i ondje se zadrži, jer se vrata gibaju. U ograničenom smjeru ništa se ne giba, pa se lanac između platforme i vrata samo napinje i sila monotono raste. Smjer se proglašava slobodnim ispod 8 N/mm, a ograničenim iznad 40 N/mm.

5.2.2. *Razlikovanje tipa vrata*

Ishod ispitivanja razlikuje dva tipa vrata, kako prikazuje tablica 11.

Tablica 11. Očekivani ishod ispitivanja po osima prihvatnice

Os	Zakretna vrata	Klizna vrata
prilazna, okomita na krilo	slobodna	ograničena
os zatvaranja prstiju	ograničena	slobodna
uzduž kvake	slobodna	slobodna

Kod zakretnih vrata normala na krilo pri zatvorenom stanju poklapa se s tangentom luka između šarke i kvake, pa je guranje duž prilazne osi ujedno i smjer otvaranja. Kod kliznih se vrata krilo giba u vlastitoj ravni, pa je slobodna os ona duž koje se prsti zatvaraju. Pravilo je time jednostavno: koja je od tih dviju osi mekša, takva su vrata.

Os uzduž kvake ne koristi se jer je slobodna kod obaju tipova, budući da prihvatnica ondje klizi duž same kvake. To je ujedno i načelno ograničenje metode: sila sama ne razlikuje gibanje vrata od klizanja hvata, jer oboje daje nisku silu.

5.2.3. *Odnos prema razlikovanju iz percepcije*

Ispitivanje nije neovisan klasifikator. Da bi se uopće izvelo, prihvatnica mora držati kvaku, a za hvat je potrebna pripremna poza koja ovisi o tipu kvake, okomitoj šipki naspram vodoravne poluge. Tip se dakle mora pretpostaviti prije nego ispitivanje može početi.

Riječ je o dvostupanjskoj shemi. Prvi stupanj daje hipotezu iz percepcije, iz smjera vektora među dvjema oznakama na kvaki (potpoglavlje 6.2.2.). Drugi stupanj tu hipotezu provjerava kroz interakciju, mjerenjem odziva sile. Vrijednost drugog stupnja nije u tome da zamijeni prvi, nego da ga potvrdi mjerenjem koje ne ovisi o vidljivosti oznaka, osvjetljenju ni kutu gledanja, i da usput izmjeri otpor, koji percepcija ne može dati.

U sustavu izvedenom u ovom radu razlikovanje tipa vrata provodi se isključivo iz percepcije, bez ispitivanja silom. Razlog je taj što se prvi stupanj pokazao dovoljno pouzdanim. U svim je pokretanjima tip vrata prepoznat točno, a ispitivanje silom tu je klasifikaciju potvrdilo u svih dvadeset pokretanja, deset po tipu vrata (potpoglavlje 5.3.). Uvođenje drugog stupnja u tijek izvođenja dodalo bi trajanje i kontaktne cikluse, a ne bi promijenilo nijednu odluku.

Ispitivanje silom time u ovom radu ima ulogu neovisne provjere i mjernog postupka, a ne dijela upravljačkog lanca. Njegova bi vrijednost došla do izražaja tek u okolini u kojoj oznake nisu postavljene ili nisu pouzdano vidljive, gdje bi preuzelo ulogu prvog stupnja, a ne samo njegove potvrde.

5.3. Provjera procjena

Sve su procjene provjerene usporedbom sa stvarnim stanjem scene, koje simulator zna, ali koje u upravljačku petlju nikada ne ulazi.

5.3.1. Procjena osi šarke i kuta vrata

Tablica 12 sažima odstupanja izmjerena kroz deset pokretanja otvaranja zakretnih vrata, ukupno 72 koraka upravljanja.

Tablica 12. Odstupanje procjene osi šarke i kuta vrata od stvarnih vrijednosti

Veličina	Sredina	Medijan	Najveća	Std. devijacija
Pogreška položaja osi šarke	5,8 mm	4,9 mm	14,3 mm	3,8 mm
Pogreška kuta vrata	0,28°	0,23°	1,46°	0,28°

Pogreška položaja osi raste s otvorenošću vrata, otprilike dvostruko između zatvorenog stanja i 65°. Pogreška kuta pritom nema takav trend, i razlog je geometrijski: pomak procijenjene osi uglavnom je usmjeren prema kvaki, a kut se računa upravo iz tog smjera, pa pomak duž njega u kut ne ulazi.

Procjena polumjera hvata pokazuje sustavno odstupanje od $-1,43$ mm, uz standardnu devijaciju od svega 0,17 mm. Uska raspodjela oko konstantne vrijednosti pokazuje da je riječ o pristranosti, a ne o šumu, tj. polumjer se dosljedno podcjenjuje.

5.3.2. Razlikovanje tipa vrata i otpor

Ispitivanje je provedeno u deset pokretanja po tipu vrata, pri čemu svako kreće od resetirane scene i punog prilaska, pa raspršenje uključuje i promjenjivost samog hvata. Rezultati su u tablici 13.

Tablica 13. Ishod ispitivanja ograničenja, deset pokretanja po tipu vrata

Veličina	Zakretna	Klizna
Točno razlikovanih	10/10	10/10
Koeficijent, prilazna os, medijan	4,6 N/mm	99,8 N/mm
Koeficijent, os prstiju, medijan	14,0 N/mm	0,08 N/mm
Omjer dvaju koeficijenata, medijan	0,35	1081

Iz istog se ispitivanja dobiva i otporni moment zakretnih vrata, s medijanom od 260 Nm i rasponom od 195 do 325 Nm. Ta se vrijednost poklapa s 280 do 308 Nm izračunatima iz

sile izmjerene tijekom samog otvaranja, dakle dvije neovisne metode daju isti otpor, što je najjača potvrda da procjena mjeri svojstvo vrata, a ne artefakt postupka.

Treba ipak biti precizan oko toga što ta sila jest. Sila izmjerena u hvatu tijekom otvaranja nije čisti otpor vrata, nego sadrži i silu kojom platforma gura kroz krutu vezu manipulatora. Zbog toga se u ovom radu naziva silom u hvatu, a ne otporom vrata; iznos otpora dobiven ispitivanjem iz mirovanja bliži je pravom svojstvu vrata.

5.4. Uloga procjene u ovom radu

Dva se pristupa upravljanju bitno razlikuju po tome koliko se od gore opisanog stvarno koriste, i to je jedna od glavnih razlika koja se razmatra u poglavlju 8..

Klasični pristup, opisan u poglavlju 6., geometriju ograničenja ne procjenjuje iz gibanja, nego je uzima iz poze kvake dobivene percepcijom. Os šarke i smjer otvaranja poznati su iz položaja i orijentacije hvatišta. Procjena sile i momenta ipak mu je nužna, za otkrivanje uspješnog hvata i za ograničavanje kontaktne sile tijekom otvaranja. Ispitivanje ograničenja iz potpoglavlja 5.2. u njegovu se izvođenju ne koristi, nego služi kao neovisna provjera pretpostavke o tipu vrata i kao mjerenje otpora.


Pristup temeljen na učenju, opisan u poglavlju 7., geometriju ograničenja ne dobiva ni iz percepcije ni iz eksplicitnog procjenitelja, nego ponašanje ograničenja mora zaključiti sam, iz procijenjene sile i ostvarenog pomaka, i na temelju toga prilagoditi djelovanje. Time procjena sile i momenta u tom pristupu nije pomoćni signal, nego jedini put kojim politika uopće doznaje o mehaničkim svojstvima okoline.

6. KLASIČNI PRISTUP UPRAVLJANJU

Klasični pristup rješava zadatak otvaranja vrata i prolaska kroz njih kao slijed jasno odvojenih faza, od kojih svaka koristi eksplicitno poznavanje geometrije zadatka: poze kvake iz percepcije, poznatog oblika prihvatnice i, za zakretna vrata, geometrijski izračunate osi šarke. To je bitna razlika prema pristupu iz poglavlja 7..

6.1. Struktura zadatka

Zadatak je organiziran u četiri faze: prilaz, hvat, otvaranje i prolazak. Tip vrata robot prepoznaje sam, iz geometrije kvake, tijekom faze hvata (potpoglavlje 6.2.). Ta odluka određuje koja se grana faze otvaranja pokreće. Prolazak kroz vrata izveden je za oba tipa, uz razliku u načinu vođenja opisanu u potpoglavlju 6.4.. Slijed je prikazan na slici 13.



Slika 13. Slijed faza klasičnog pristupa

6.2. Faza prilaza i hvata

6.2.1. Poravnanje platforme

Platforma se dovodi na određenu udaljenost od vrata (potpoglavlje 4.5.) regulacijom položaja prema velikoj oznaci na sredini vrata. Cilj regulacije nije samo udaljenost, nego potpuna poza u ravnini, tj. bočni i uzdužni položaj te zakret, sve do zadanih tolerancija. Ciljna točka i ciljni zakret određeni su duž normale vrata, izvedene iz orijentacije oznake, a ne samo iz smjera pogleda prema njoj. Regulacija koja nastoji držati oznaku na sredini pogleda kamere ne jamči da će platforma stati okomito na vrata. Ako orijentacija oznake iz nekog razloga nije dostupna, sustav se vraća na regulaciju smjera pogleda, čime se izbjegava da robot potpuno stane, po cijenu manje pouzdanog poravnanja.

6.2.2. Prepoznavanje tipa kvake

Kad je platforma na ciljanoj udaljenosti, sustav sam prepoznaje tip vrata iz geometrije kvake, umjesto da mu se tip zadaje pri pokretanju. Kvaka nosi dvije male oznake (potpoglavlje 4.2.); vektor između njihovih položaja jednoznačno razlikuje tipove, jer je kod zakretnih vrata poluga kvake vodoravna, a kod kliznih šipka okomita. Kriterij je jednos-

tavan prag na okomitoj komponenti tog vektora: ako ona prelazi 70 % duljine vektora, kvaka je okomita i vrata su klizna, inače su zakretna. Prepoznati tip određuje koja se od dviju unaprijed zadanih početnih poza manipulatora koristi u nastavku, a poslije i koja se grana faze otvaranja pokreće (potpoglavlje 6.3.).

6.2.3. *Hvat*

1. **Ponovno čitanje poze.** Na početnoj udaljenosti kvaka je izvan dosega manipulatora pri nepomičnoj platformi, pa se platforma nakon prvog očitavanja poze dodatno primakne. Poza kvake se pritom ne prati kontinuirano, nego se rekonstruira iz njezina nepromjenjivog odnosa prema velikoj oznaci, koja ostaje u vidnom polju tijekom cijelog primicanja.
2. **Prilaz.** Manipulator se dovodi u pozu prilaska ispred kvake te se zatim približava do konačne poze hvata.
3. **Bočna korekcija.** Parovi prstiju prihvatnice ne gibaju se savršeno simetrično, pa se hvat sam od sebe ne centrira nad predmetom. Umjesto da se ta asimetrija ukloni, ona se mjeri: uspoređuju se položaji suprotnih prstiju tijekom zatvaranja, a iz njihove razlike izračunava se bočna korekcija kojom se prihvatnica poravna nad kvakom prije konačnog zatvaranja.
4. **Korekcija dubine (engl. *hill-climbing*).** Prihvatnica postupno prilagođava svoju dubinu duž osi prilaza kako bi šipka kvake u potpunosti sjela u utor prstiju. Pri svakom pokušaju prsti se zatvaraju do zaustavljanja i mjeri se ostvareni stupanj zatvorenosti; ako se mjera pogorša u odnosu na prethodni pokušaj, algoritam mijenja smjer pomaka i vraća se na dotad najbolju poziciju, sve dok se ne postigne željena dubina hvata ili se ne obavi najveći dopušteni broj pokušaja.

6.2.4. *Sidrenje cilja na oznaku*

Neposredno nakon potvrđenog hvata mjeri se i pohranjuje fiksni prostorni odnos između vrha alata i velike oznake, tj. pomak i zakret koji vrijede u tom trenutku. Taj se odnos u nastavku zadatka koristi za određivanje cilja gibanja: umjesto da se cilj izvodi iz posljednje poznate poze vrha alata, on se u svakom koraku iznova računa iz trenutne poze oznake i pohranjenog odnosa. Razlika je bitna kad kvaka unutar hvata blago klizne, što se pokazalo mjerljivim pri otvaranju zakretnih vrata (potpoglavlje 6.3.2.): bez sidrenja na oznaku, cilj bi klizio zajedno s kvakom, klizanje se ne bi moglo ni izmjeriti, a manipulator nikad ne bi dobio naredbu da nadoknadi razliku. Isti se mehanizam koristi i za neovisno mjerenje samog klizanja, kao razlike između očekivane i stvarno postignute poze vrha alata.

6.3. Faza otvaranja

Nakon uspješnog hvata, kreće faza otvaranja vrata.

Nakon uspješnog hvata, manipulator do kraja faze otvaranja ostaje u dostignutoj konfiguraciji ili joj se vraća između malih koraka gibanja, a cjelokupno napredovanje izvodi platforma, uz iznimku opisanu u potpoglavlju 6.3.2.. Ta je odluka namjerna i vezana je uz procjenu sile opisanu u poglavlju 5.: postupak umjeravanja procjenitelja momenta vrijedi za konfiguraciju u kojoj je proveden (potpoglavlje 5.1.1.), pa svaki veći pomak manipulatora tu procjenu čini nevaljanom, osim ako se umjeravanje ponovi.

6.3.1. Klizna vrata

Kod kliznih vrata smjer gibanja poznat je unaprijed — vodoravna translacija duž zgloba klizanja — pa se platformi zadaje trapezni profil brzine u tom smjeru, s ubrzanjem, ravnomjernom fazom i usporavanjem. Sam taj smjer izvodi se iz orijentacije prihvatnice, i to iz njezine lokalne osi x , duž koje se prsti zatvaraju (potpoglavlje 3.2.), projicirane na vodoravnu ravninu. Smjer se ne računa jednom na početku, nego se osvježava u svakom koraku iz trenutne orijentacije prihvatnice. Kad bi ostao fiksiran, a platforma se u međuvremenu neznatno zakrenula, počela bi se stvarati komponenta sile koja stoji okomito na vrata umjesto duž njih, a rasla bi s nakupljenim zakretom. Regulacija brzine prema izmjerenoj sili namjerno nije korištena: sila uvijek naraste u trenutku kretanja platforme iz mirovanja, pa bi svaki takav povratni regulator uveo zastajkivanje umjesto glatkog gibanja. Sila se koristi isključivo kao sigurnosni prekid.

Hod kliznih vrata premašuje ono što platforma stigne prijeći unutar jednog trapeznog profila, pa se vožnja prema potrebi ponavlja u više prolaza, bez ponovnog hvata. Prihvatnica drži kvaku neprekidno, platforma se samo zaustavi na kraju jednog profila i ponovno krene s početka sljedećeg. Napredak nakon svakog prolaza provjerava se iz percepcije, kao pomak velike oznake izražen u nepomičnom okviru: poza oznake u koordinatnom sustavu platforme pretvara se u taj okvir pomoću odometrije (potpoglavlje 3.6.2.). Odstupanje tako dobivenog pomaka od stvarnog stanja zgloba vrata iznosi 44 mm, odnosno 4,6 %.

6.3.2. Zakretna vrata

Kod zakretnih vrata gibanje platforme nije jednostavna translacija, pa način na koji je otvaranje ostvareno bitno odstupa od kliznih vrata: umjesto da precizno praćenje luka izvodi platforma, tu je zadaću preuzeo manipulator, dok platforma ima samo pomoćnu ulogu.

Otvaranje se izvodi u dvije uzastopne faze: guranjem, u kojem robot kvaku vodi po luku, i završnim zakretom platforme, kojim se vrata doguravaju do konačnog kuta.

Tijekom guranja platforma se giba po smjeru tangente luka kvake, a manipulator u svakom koraku zakreće vrh alata za mali kut duž procijenjene kružnice, inverznom kinematikom. Precizno vođenje po luku time je prepušteno manipulatoru, a platformi ostaje gibanje po pravcu. Cilj se pritom sidri na oznaku, na način opisan u potpoglavlju 6.2.4., čime se u svakom koraku nadovezuje na stvarno postignuto stanje kvake, a ne na vlastitu prethodnu naredbu.

Izbor smjera tangente za gibanje baze počiva na činjenici da se sila kojom baza gura prenosi kroz krutu ruku na kvaku. Ako ta sila ima komponentu duž kvake, ta komponenta izvlači prihvatnicu s kvake i hvat klizi.

Korak manipulatora nije fiksni, nego razmjerni trajanju prethodnog ciklusa upravljanja, uz gornju granicu. Razlog je taj što platforma vozi neprekidno, a trajanje ciklusa određuje planiranje gibanja i kreće se između 0,4 i 2,1 s; uz fiksni korak manipulator bi u duljem ciklusu zaostao za platformom.

Mjerenja i sigurnosni prekidi ne izvode se u glavnoj petlji, nego u zasebnoj niti na 20 Hz. Kako ciklus glavne petlje traje i do dvije sekunde, a platforma za to vrijeme vozi i vrata se otvore 15 do 18°, prag bi se inače uvijek prekoračio prije nego bi ga sustav primijetio. Ta nit ujedno vodi regulator platforme i sama je zaustavlja čim uvjet prekida okine.

Budući da vrh alata inverznom kinematikom vodi MoveIt, prije početka povlačenja iz njegove planerske scene uklanjaju se kolizijski objekti vrata i zidova (potpoglavlje 3.5.). U suprotnom bi planer odbijao upravo ono gibanje koje je namjerno usmjereno prema kvaki i kroz prostor koji zid inače zatvara. Kolizijski objekti zida u planersku scenu ne ulaze kao dva unaprijed poznata tijela, nego se sastavljaju iz skena lidara, pa njihov broj nije unaprijed određen. Kad su vrata zatvorena, krilo i oba zida optički čine jednu neprekinutu plohu, dok se otvaranjem krilo odmakne i pojave se dva razdvojena segmenta.


Za razliku od procjene ograničenja iz poglavlja 5., os šarke se ovdje ne procjenjuje iz gibanja, nego se izravno izračunava iz geometrije poznate percepciji, i to iz jednog, fiksnog vektora izraženog u koordinatnom sustavu same oznake. Neka je $\mathbf{p}_{\text{tag}}$ položaj velike oznake, a $\mathbf{R}(\mathbf{q}_{\text{tag}})$ matrica rotacije koja opisuje njezinu orijentaciju. Os šarke procjenjuje se kao

$$\mathbf{c} = \mathbf{p}_{\text{tag}} + \mathbf{R}(\mathbf{q}_{\text{tag}}) \mathbf{v}_{\text{hinge}}, \quad \mathbf{v}_{\text{hinge}} = \begin{pmatrix} 0 \\ -L/2 \\ -\delta \end{pmatrix}, \quad (7)$$

gdje je $\mathbf{c}$ procijenjeni položaj osi šarke. Računa se kao položaj velike oznake, pomaknut vektorom $\mathbf{v}_{\text{hinge}}$ koji je prethodno zaokrenut u svjetski koordinatni sustav istom rotacijom kao i sama oznaka. Druga i treća komponenta tog vektora izražene su u lokalnim osima oznake: L je širina krila (tablica 5), a $\delta = 21$ mm odmak oznake od središnje ravnine

debljine krila. Slika 14 prikazuje konstrukciju u tlocrtu.

Vektor $\mathbf{v}_{\text{hinge}}$ ima jednostavno geometrijsko značenje: oznaka je postavljena točno na sredinu krila, pa je udaljenost do osi šarke, mjerena duž krila, jednaka točno polovici njegove širine. Krilo je debelo 40 mm, a os šarke, kao i kod stvarnih vrata, prolazi kroz sredinu te debljine, ne kroz plohu na kojoj je oznaka zalijepljena. Time nastaje razmak od 20 mm (polovica debljine krila) kojemu se pridodaje i sitan odmak same naljepnice od plohe od svega 1 mm, pa je ukupni δ 21 mm.



Slika 14. Konstrukcija procjene osi šarke iz poze i lokalnih osi velike oznake, tlocrt

Izraz (7) vrijedi iz jednog, trenutnog očitavanja poze oznake, bez praćenja kuta vrata kroz vrijeme: kako oznaka rotira zajedno s krilom oko prave, nepomične osi šarke, umnožak $\mathbf{R}(\mathbf{q}_{\text{tag}}) \mathbf{v}_{\text{hinge}}$ rotira s njom na jednak način, pa zbroj u svakom trenutku ponovno pogađa istu točku u prostoru.

Oznaka se ipak koristi samo do hvata. Kako se vrata otvaraju, ona izlazi iz vidnog polja kamere, pa se položaj osi šarke jednom utvrdi pri hvatu i dalje prati odometrijom (potpoglavlje 3.6.2.). To je moguće jer je os šarke nepomična u prostoru, pa je dovoljno pratiti gibanje same platforme.

Iz istog razloga i kut otvorenosti vrata prati se posredno. Dok prihvatnica drži kvaku, smjer od osi šarke prema vrhu alata ujedno je i smjer krila, pa se kut računa iz te dvije poze, i to u nepomičnom okviru.

6.3.3. Završni zakret platforme

Guranje se zaustavlja na 70° , iz razloga navedenog u potpoglavlju 6.6.. Taj kut nije dovoljan za prolazak, pa slijedi druga faza, u kojoj platforma zakreće oko točke na sredini vlastite prednje strane, za otprilike 20° .

Bitna je razlika u tome što manipulator tijekom tog zakreta miruje u dosegnutoj konfiguraciji, a prihvatnica i dalje drži kvaku. Cijeli se sklop (platforma, manipulator i krilo) giba kao jedno tijelo, pa hvat nije dodatno opterećen. Za kruženje oko točke $\mathbf{c}$ izražene u koordinatnom sustavu platforme, naredba brzine slijedi iz uvjeta da ta točka miruje:

$$v_x = \omega c_y, \quad v_y = -\omega c_x, \quad \omega_z = \omega. \quad (8)$$

Time se vrata doguravaju do otprilike 100° pa krilo više ne strši u prolaz, a robot može nesmetano proći.

6.4. Prolazak kroz vrata

Nakon otvaranja slijedi prolazak, izveden za oba tipa vrata. Robot se ovdje oslanja na lidar (potpoglavlje 3.4.).

Otvor se iz skena traži u dva koraka. Najprije se postupkom konsenzusa slučajnog uzorka (*RANSAC*, engl. *Random Sample Consensus*) među točkama skena traži najizraženiji pravac, koji odgovara ravnini zidova, uz uvjet da mu je smjer pretežno poprečan u odnosu na robota. Taj je uvjet nužan jer bez njega, kad je robot blizu vrata, gusto uzorkovano krilo postane najizraženiji pravac i klasifikacija pada. Zatim se među točkama koje pripadaju zidu traži praznina širine bliske poznatoj širini dovratnika. Na mirujućem robotu središte i širina tako pronađenog otvora ostaju točni i precizni unutar otprilike jednog centimetra. Pred zatvorenim vratima postupak ispravno ne pronalazi ništa.

Postupak prolaska ima sljedeće korake:

1. **Otpuštanje i povlačenje.** Prihvatnica otvara prste, a manipulator se povlači unazad duž osi prilaza, kako se pri odlasku u pozu parkiranja ne bi sudario sa šipkom kvake.
2. **Parkiranje ruke.** Manipulator odlazi u unaprijed zadanu pozu iznad baze kako ne bi zapeo za zidove ili vrata tijekom prolaska.
3. **Odmicanje i ispravljanje** (samo zakretna vrata). Platforma se odmiče 0,35 m unatrag i ispravlja okomito na ravninu zida, čime dobiva prostor za manevar pred otvorom.
4. **Poravnanje.** Platforma se bočno pomiče, holonomnim gibanjem u poprečnom smjeru, dok se pronađeni otvor ne dovede pred robota.
5. **Prolazak.** Platforma se giba naprijed kroz otvor.

Kod kliznih vrata prolazak je pravocrtan i bez korekcije, jer se krilo povuklo u stranu, a poravnanje je dovršeno prije nego vožnja počne. Kod zakretnih vrata krilo pri 100° više ne strši u koridor, ali ono zna ometati detekciju, pa se robot ne uspije poravnati savršeno okomito. Vožnja se ondje vodi odbojnim poljem. Svaka zapamćena točka prepreke unutar zadanog dometa gura robota od sebe, jače što je bliže, a doprinosi se zbrajaju i usrednjuju. Zbroj preko stotina točaka mijenja se glatko pa nema oscilacija tijekom prolaska.

Tri su pojedinosti nužne da to radi. Polje se računa u točki nešto ispred robota, a ne oko njegova trenutnog položaja, jer se ondje doprinosi s lijeve i desne strane međusobno poništavaju dok je robot između prepreka, pa reakcija dolazi prekasno; krilo uz to strši ispred robota, ne bočno. Doprinosi se ograničavaju po uzdužnoj osi, jer inače udaljeni dijelovi zida nadglasaju krilo i polje na većoj udaljenosti pokazuje u krivu stranu. Naposljetku, polje upravlja samo zakretom, bez bočne komponente, jer translacija ima istu mrtvu zonu opisanu u potpoglavlju 6.6., pa bi naredba bila ili puna ili nikakva.

Lidar se nalazi na prednjoj strani platforme, pa robot pri samom prolasku izgubi iz vida i zid i krilo upravo kad su mu najbliži. Zbog toga se sve viđene točke pamte u nepomičnom okviru, sažete u rešetku ćelija od pet centimetara. Udaljenost do prepreke pritom se računa do ruba pravokutnika platforme, a ne do njezina središta, i točke se ne odbacuju prema tome jesu li iza robota, primjerice dovratnik uz lijevi bok robota, kojeg je prednji rub upravo prošao, i dalje je opasan za stražnji kut.

6.5. Rezultati

Slike 15 i 16 prikazuju karakteristične trenutke izvođenja na oba tipa vrata. Slijed je isti za oba, uz razliku u fazi otvaranja, gdje kod zakretnih vrata nakon guranja slijedi završni zakret platforme.




(a) početno stanje




(b) prilazak vratima




(c) hvat kvake



(d) otvaranje




(e) namještanje pred otvorom




(f) prolazak kroz vrata


Slika 15. Faze izvođenja klasičnog pristupa na zakretnim vratima




(a) početno stanje




(b) prilazak vratima




(c) hvat kvake



(d) otvaranje



(e) namještanje pred otvorom



(f) prolazak kroz vrata

Slika 16. Faze izvođenja klasičnog pristupa na kliznim vratima

6.5.1. Prilazak i hvat

Pogreška poravnanja platforme iznosi 1,2 do 1,5°. Odstupanje postignute pred-hvatne poze od cilja iznosi 8 do 11 mm u položaju te 0.1 do 0.2° u orijentaciji, a odstupanje same poze hvata 6 do 8 mm i oko 0.5°. Prepoznavanje tipa kvake iz geometrije (potpoglavlje 6.2.2.) pokazalo se pouzdanim na objema scenama vrata.

6.5.2. Zakretna vrata

Guranje se zaustavlja na 70°, a završni zakret platforme (potpoglavlje 6.3.3.) vrata doguruje do otprilike 100°, što je dovoljno za prolazak. Izmjerene vrijednosti navedene su u tablici 14.

Tablica 14. Izmjerene vrijednosti pri otvaranju zakretnih vrata

Veličina	Vrijednost
Kut otvaranja guranjem	70° (cilj), 71° stvarno
Kut nakon završnog zakreta	oko 100°
Sila povlačenja, prosječna	320–450 N
Sila povlačenja, najveća	do 630 N
Radijalno klizanje hvata	do 8 mm
Pogreška praćenja položaja	0,4–2,5 mm
Pogreška procjene osi šarke	2–9 mm

6.5.3. Klizna vrata

Ostvareno je otvaranje od 904 do 910 mm uz cilj od 900 mm, u dva prolaza, nakon čega je prolazak kroz otvor uspješan. Sila povlačenja iznosila je u prosjeku 240 do 260 N, s vrhom do 660 N, a klizanje hvata ostalo je između 4 i 6 mm kroz cijeli manevar. To je manje nego kod zakretnih vrata, u skladu s time da se kod kliznih vrata smjer sile poklapa sa smjerom gibanja hvata, dok kod zakretnih hvat prati zakrivljenu putanju. Prijedeni put platforme iznosio je 900 mm, mjereno odometrijom.

6.6. Ograničenja

- Gibanje platforme ima izraženu mrtvu zonu i ne postiže naredenu brzinu. Rotacija se ne pokreće ispod 0,36 rad/s, bočna translacija ispod otprilike 0,18 m/s, a uzdužna translacija postiže oko 45 % naredenoga. Omjer je dosljedan kroz ispitani raspon brzina od 0,05 do 0,22 m/s, a brzina očitana u samom simulatoru odgovara naredenoj, pa je uzrok negdje u prijenosu naredbe do fizike platforme. Provjereno je i isključeno više mogućih uzroka: pogon i trenje u zglobu vrata, viskozno prigušenje platforme, brzina same simulacije te trajanje prijelazne faze na početku gibanja. Posljedica je da regulator koji zadaje male korekcije postaje dvopoložajan, jer je naredba ili ispod praga i bez učinka, ili puna.
- Prijedeni put platforme ne smije se računati iz naredene brzine i vremena, iz prethodno navedenog razloga. Umjesto toga se mjeri odometrijom (potpoglavlje 3.6.2.), pa se svi iznosi pomaka u ovom poglavlju odnose na izmjerenu, a ne na zadanu veličinu.
- Kako je navedeno u potpoglavlju 3.5., zglob koji bi omogućio zakretanje kvake u konačnom je modelu nepomičan. Ta je odluka svjesno smanjenje opsega rada, ne nedostatak: zakretanje kvake bilo je u ranijoj fazi razvoja najproblematičniji dio

zadatka, jer je kruto pozicijsko upravljanje tim dodatnim stupnjem slobode davalo velike kontaktne sile na svako odstupanje procjene. Uklanjanjem tog stupnja slobode zadatak je sveden na jedan stupanj slobode po tipu vrata. Ista je odluka primijenjena i u pristupu temeljenom na učenju, opisanom u poglavlju 7., čime ostaje osnova za usporedbu dvaju pristupa.

- Guranje zakretnih vrata ne prelazi otprilike 71° . Kako se vrata otvaraju, potreban doseg manipulatora raste s 0,81 na 0,88 m, a to se ne može nadoknaditi zakretanjem platforme, jer rotacija ima mrtvu zonu opisanu gore: svaki zakret kreće s barem $20^\circ/\text{s}$ i slomi vezu između manipulatora i kvake. Ograničenje je zaobiđeno završnim zakretom platforme (potpoglavljje 6.3.3.), koji vrata doguruje do otprilike 100° bez opterećenja hvata. Otvaranje preko 100° zahtijevalo bi prepozicioniranje hvata, dakle puštanje kvake, premještanje platforme i ponovni hvat iz povoljnije konfiguracije, što nije izvedeno u opsegu ovog rada.
- Sustav sadrži zaseban postupak procjene geometrije ograničenja iz odnosa sile i gibanja, opisan u poglavlju 5., ali on u klasičnom pristupu nije povezan s izvođenjem: os šarke u fazi otvaranja izračunava se geometrijski iz percepcije, a procjena iz gibanja postoji u zasebnim, samostalno pokretanim skriptama, izvan glavnog tijeka zadatka. Sustav zna i procijeniti ograničenje iz gibanja i otvoriti vrata, ali te dvije sposobnosti nisu spojene u jedan tijek izvođenja.
- Lidar tijekom otvaranja i prolaska prati postoji li prepreka neposredno ispred platforme i zaustavlja zadatak ako je udaljenost premala, ali ne raspolaže planiranjem puta niti izbjegavanjem prepreke.

7. PRISTUP TEMELJEN NA UČENJU

Pristup temeljen na učenju rješava isti zadatak kao poglavlje 6., ali bitno drugačijim sredstvima. Klasični pristup vrh alata vodi krutim pozicijskim upravljanjem po una-prijed izračunatoj putanji, uz geometriju ograničenja poznatu iz percepcije. Ovdje se, umjesto toga, uvodi varijabilna impedancija: politika u svakom koraku sama bira koliko će regulator biti krut po svakoj osi, a geometriju ograničenja ne dobiva ni iz percepcije ni iz eksplicitnog procjenitelja, nego je mora otkriti iz vlastitih opažanja sile i gibanja. To je izravan odgovor na nalaz iz poglavlja 6.: kruto pozicijsko praćenje luka davalo je velike kontaktne sile na svako odstupanje procjene, pa varijabilna impedancija postoji upravo zato da politika tu krutost regulira sama.

7.1. Opseg

Politika ne uči prilaz ni hvat kvake. Epizoda počinje od stanja u kojem prihvatnica već drži kvaku, a klasični postupak prilaza i hvata (potpoglavlje 6.2.) smatra se zajedničkim za oba pristupa. Razlog je dvostruk: prilaz i hvat rješavaju problem navigacije i planiranja gibanja, a ne problem interakcije koji je predmet ovog rada, i njihovo bi dupliciranje otežalo poštenu usporedbu, jer bi mjerena razlika između pristupa uključivala i razliku u tome tko je bolji u navigaciji, ne samo u interakciji. Iz istog je razloga izostavljen i prolazak kroz vrata: i on je navigacija kroz poznatu geometriju, ista kategorija kao prilaz. Ta odluka o opsegu izravno oblikuje ono što se u poglavlju 8. smije uspoređivati. Usporedba se odnosi isključivo na fazu otvaranja, ne na cijeli zadatak, dok klasični pristup taj cijeli zadatak stvarno izvodi od početka do kraja.

Sam postupak prolaska kroz vrata je implementiran i radi, uključivo za slučaj naučene politike, ali je namjerno isključen iz rezultata radi dosljednosti opsega. Vrijedan je kao potvrda da se naučena politika može ugraditi u isti izvršni sloj kao klasični pristup.

Trening se u cijelosti odvija unutar simulacijskog okruženja Isaac Lab, bez sustava ROS 2 u regulacijskoj petlji. Razlog je paralelizacija: trening istovremeno pokreće više stotina okruženja, a posredovanje kroz ROS 2 bilo bi usko grlo. Epizoda traje 10 sekundi, uz korak upravljanja od 60 Hz (fizika 120 Hz, decimacija 2), što daje 600 koraka po epizodi.

Uspješnost politike pri determinističkom izvođenju, koje se razlikuje od učenja, mjerena je zasebno i uspoređena s klasičnim pristupom u poglavlju 8..

7.2. Formulacija Markovljevog procesa odlučivanja

7.2.1. *Prostor opažanja*

Vrijedi isto načelo kao u klasičnom pristupu: kut ili pomak zgloba vrata, dakle stvarno stanje zadatka, nikada nije dio opažanja politike, nego se koristi isključivo u nagradi i pri prekidu epizode, gdje je legitiman jer se računa izvan regulacijske petlje. Opažanje sadrži:

- pozu vrha alata u koordinatnom sustavu platforme (položaj i orijentacija);
- linearnu i kutnu brzinu vrha alata, u istom koordinatnom sustavu;
- brzinu platforme, (linearna brzina po x i y , kutna brzina oko z);
- procijenjenu silu i moment na vrhu alata, uz Gaussov šum standardne devijacije 0,5 N, koji odgovara šumu stvarnog procjenitelja iz poglavlja 5.;
- vektore od platforme do najbližih točaka susjednih prepreka (zid, dovratnik), uz Gaussov šum standardne devijacije 1 cm, koji odgovara izmjerenoj stabilnosti sredine otvora iz skena lidara u klasičnom pristupu (potpoglavlje 6.4.);
- posljednju akciju.

7.2.2. *Prostor akcija*

Ruka se upravlja regulatorom u operacijskom prostoru s varijabilnom impedancijom. Akcija zadaje pomak reference vrha alata u odnosu na trenutnu pozu, za svih šest stupnjeva slobode, i šest pripadnih krutosti, po jedna za svaku os. Time politika izravno bira, u svakom koraku i za svaku os zasebno, koliko će regulator biti krut, točno ono što je poglavlje 6. pokazalo da kruto pozicijsko upravljanje ne može samo po sebi ostvariti.

Uz šest stupnjeva slobode ruke, akcija sadrži i tri komponente brzine platforme, uzdužnu, poprečnu i kutnu, pa politika sama koordinira ruku i platformu. Ukupna dimenzija akcijskog prostora time iznosi petnaest.

Izlaz politike nije ni u jednoj dimenziji fizikalna veličina, nego bezdimenzijski broj koji se množi pripadnim faktorom razmjera. Tablica 15 navodi te faktore i granice unutar kojih rezultat završava, jer su oni nužni za ponovljivost postupka.

Tablica 15. Sastav akcijskog prostora, faktori razmjera i granice

Komponenta	Dimenzija	Faktor razmjera
Pomak reference, translacija	3	0,015 m
Pomak reference, rotacija	3	0,1 rad
Krutost regulatora	6	300 N/m
Brzina platforme, uzdužna	1	0,1 m/s
Brzina platforme, poprečna	1	0,1 m/s
Brzina platforme, kutna	1	0,17 rad/s

Krutost je jedina veličina s tvrdom granicom. Donja granica sprječava da regulator posve popusti, a gornja je odabrana tako da umnožak najveće krutosti i faktora razmjera pomaka iznosi 225 N, dakle ispod praga od 280 N na kojem počinje kazna za prekomjernu silu. Politika time smije odabrati i najveću krutost, a da je sama po sebi ne odvede u kaznu. Ostale su veličine neograničene jer je akcija izlaz Gaussove razdiobe, pa je njihov doseg statistički, a ne propisan.

Izlaz politike tipično se kreće u rasponu od otprilike ± 3 , pa navedeni faktori daju pomak reference reda nekoliko centimetara po koraku te brzinu platforme reda 0,3 m/s i 0,5 rad/s. Prigušenje regulatora nije zasebna dimenzija akcije, nego se zadaje omjerom prigušenja jednakim jedinici, dakle kritično prigušen odziv pri svakoj krutosti koju politika odabere. Odabir faktora razmjera za krutost nije bio neutralan. Regulator akciju množi faktorom bez pomaka, pa akcija jednaka nuli daje krutost nula, koja se potom ograničava na donju granicu.

Uz sam regulator djeluje i upravljanje u nul-prostoru, s krutošću 10 N/m i kritičnim prigušenjem, koje redundantnu konfiguraciju ruke drži blizu nazivne. Bez njega lakat odluta u singularitet ili zglobni limit iako vrh alata miruje na svojoj referenci.

7.2.3. Koordinacija platforme i manipulatora

Uvedena je dodatna kazna na odstupanja platforme od okomice na ravninu vrata, s težinom razmjernom tome koliko takvo odstupanje kod danog tipa vrata stvarno šteti: znatno većom kod zakretnih, gdje dijagonalan položaj platforme kasnije ne prolazi kroz suženi otvor, nego kod kliznih, gdje platforma svejedno mora pratiti krilo poprečno pa okomitost manje košta. Kazna je uz to zatvorena ovisno o ostvarenom napretku, tako da ne djeluje u ranoj fazi zadatka, kada bi se sukobila s potrebom da politika zakrene platformu radi dosega. Ruka je montirana izvan osi platforme, pa zakret platforme proširuje radni prostor ruke na legitiman način.

7.2.4. Funkcija nagrade

Tablica 16 navodi sve članove nagrade. Sve su težine određene empirijskim procesom kalibracije tako da se provelo kraće treniranje politike (300 iteracija) s grubo pretpostavljenom težinom te se zatim težina skalirala linearno dok član nagrade ne iznosi između 3 i 10 % udjela člana napretka.

Tablica 16. Članovi funkcije nagrade

Član	Težina	Svrha
napredak	+10,0	glavni član, normiran na prag uspjeha
okomita sila	-0,02	kazni silu okomitu na stvarni smjer gibanja vrata
zasićenje zglobova	-2,0 / -6,0	kazni rad blizu granice raspona zglobova ruke
singularitet	-20,0	kazni pad manipulabilnosti ispod praga
ubrzanje ruke	$-5 \cdot 10^{-4}$	kazni ubrzanje zglobova ruke
trzaj ruke	$-1 \cdot 10^{-7}$	kazni trzaj, dakle drugu derivaciju brzine zglobova
prekomjerna sila	-0,05	kazni ukupnu silu iznad referentne granice
poravnanje hvata	-3,0	kazni odstupanje prilazne osi hvata od okomice na krilo
poravnanje platforme	-0,1 / -6,0	kazni odstupanje platforme od okomice na ravninu vrata
prodor u krilo	-20,0	kazni približavanje ruba platforme krilu ispod sigurnog razmaka
prodor u zid	-20,0	kazni približavanje ruba platforme zidu ili do vratniku ispod sigurnog razmaka
promjena akcije	-0,002	kazni razliku uzastopnih akcija
uspjeh	+2,0	bonus po koraku dok je pomak vrata iznad praga uspjeha

Gdje su navedene dvije težine, prva vrijedi za klizna, a druga za zakretna vrata.

Napredak se ne normira na puni hod zgloba vrata, već na puno manju referentnu vrijednost 0,6 m kod kliznih i 0,5 rad (28,6 °) kod zakretnih vrata. Uz normiranje na puni hod, manji pomak nosio bi premalu nagradu da nadjača kazne, pa bi politika naučila dovesti vrata na određeni pomak i ne pomicati ih dalje. Time napredak nije ograničen odozgo, već smije prijeći jedinicu, što znači da nagrada za napredak raste što su vrata više otvorena.

Prag uspjeha, koji određuje kada se dodjeljuje bonus iz zadnjeg retka tablice 16, zasebna je veličina. Kod kliznih vrata poklapa se s referentnom vrijednošću normalizacije i iznosi 0,6 m. Kod zakretnih vrata je namjerno odvojen i postavljen na 1,57 rad (90 °). Razlog je taj što je 0,5 rad dovoljno da se vrata mjerljivo pomaknu, ali nije dovoljno da robot kroz njih prođe. Normalizacija je pritom ostala nepromijenjena kako bi kalibracija svih ostalih veličina ostala valjana. Bonus za uspjeh dodjeljuje se po koraku dok je pomak iznad praga, a ne kao jednokratna nagrada uz prekid epizode.

Kazna na singularitet koristi Yoshikawin indeks manipulabilnosti [28]:

$$w(\mathbf{q}) = \sqrt{\det(\mathbf{J}(\mathbf{q})\mathbf{J}(\mathbf{q})^\top)}, \quad (9)$$

koji je jednak nuli točno na kinematičkom singularitetu i nigdje drugdje. Kazna je normirana na raspon od nule do jedan.

7.2.5. *Prekidi epizode*

Epizoda prekida prije isteka vremena u četiri slučaja

- sila je prešla sigurnosnu granicu,
- hvat je izgubljen jer se vrh alata previše udaljio od šipke kvake,
- rub platforme je dotaknuo krilo vrata,
- rub platforme dotaknuo zid ili dovratnik.

7.2.6. *Nasumičnost pri početku epizode i kurikulum otpora*

Pri svakom početku epizode, kut prilaska platforme vratima nasumično se zakreće unutar $\pm 20^\circ$ oko nazivne vrijednosti. Otpor vrata bira se nasumično u rasponima navedenima u poglavlju 3. (tablica 6).

Kod kliznih vrata otpor se uz to uvodi postupno, kurikulumom koji tijekom prvih 1500 iteracija učenja linearno širi gornju granicu trenja i prigušenja s vrijednosti koja odgovara laganim vratima do pune vrijednosti iz tablice 6, nakon čega ostaje na punoj vrijednosti do kraja treninga. Kurikulum politici omogućuje da najprije nauči na lakšim vratima, gdje se povratna informacija o napretku redovito javlja, prije nego što se suoči s punim rasponom. Zakretna vrata kurikulum nemaju, jer je njihov otpor za red veličine manji i politika na njemu uči bez poteškoća; različit režim treninga po tipu vrata posljedica je te razlike u težini zadatka, ne proizvoljne odluke.

7.3. Postupak učenja

Učenje se provodi algoritmom proksimalne optimizacije politike (PPO) [19], s hiperparametrima u tablici 17.

PPO pripada obitelji postupaka s aktorom i kritikom, koji uče dvije odvojene neuronske mreže. Aktor je sama politika, ona iz opažanja daje srednje vrijednosti normalne razdiobe iz koje se potom uzorkuje akcija, po jednu za svaku dimenziju akcijskog prostora. Kritičar ničim ne upravlja, nego iz opažanja procjenjuje očekivani ukupni diskontirani povrat iz zatečenog stanja, dakle mjeru toga koliko je stanje samo po sebi povoljno. Kritičar je potreban jer ostvarena nagrada sama po sebi ne govori je li akcija bila dobra: visoka nagrada može biti posljedica povoljnog stanja, a ne odabrane akcije. Razlika između stvarno ostvarenog povrata i kritikove procjene, tzv. prednost, ono je što ulazi u ažuriranje aktora. Pozitivna prednost pojačava vjerojatnost odabrane akcije, negativna je smanjuje. Diskontni faktor γ i faktor generalizirane procjene prednosti λ iz tablice 17 upravljaju upravo izračunom te prednosti.

Obje su mreže potpuno povezane i međusobno neovisne, bez zajedničkih slojeva, s trima skrivenim slojevima širine 256, 128 i 64. Aktor preslikava 41 ulaznu veličinu, koliko ih ima opažanje iz potpoglavlja 7.2.1., u 15 izlaznih, koliko ih ima akcija iz potpoglavlja 7.2.2.. Kritičar ima isti ulaz, ali jedan jedini izlaz. Postupno suženje slojeva uobičajen je obrazac: široki prvi sloj izdvaja značajke iz sirovog opažanja, a svaki ih sljedeći sažima prema odluci. Ukupno je riječ o svega stotinjak tisuća parametara po obje mreže, što je za mjerila neuronskih mreža malo, ali uobičajeno kada je opažanje vektor izmjerenih veličina, a ne primjerice slika.

Kao aktivacijska funkcija skrivenih slojeva koristi se ELU (engl. *exponential linear unit*),

$$\text{ELU}(x) = \begin{cases} x, & x > 0 \\ e^x - 1, & x \leq 0 \end{cases} \quad (10)$$

koja unosi nelinearnost, bez koje bi tri uzastopna linearna sloja bila jednakovrijedna jednomu. Pozitivne ulaze ne mijenja, dok za negativne daje glatku negativnu vrijednost umjesto nule. Time se, prvo, izbjegava da neuron s negativnim izlazom ostane trajno neaktivan, jer mu gradijent ne pada na nulu, i drugo, srednja vrijednost aktivacija ostaje bliža nuli, što ubrzava konvergenciju. Potonje je ovdje osobito prikladno, jer su ulazne veličine (sile, brzine i pomaci) predznačene i prirodno raspoređene oko nule, pa bi funkcija koja negativne vrijednosti postavlja na nulu odbacila polovicu njihova raspona.


Tablica 17. Hiperparametri učenja

Hiperparametar	Vrijednost
Broj koraka po okruženju prije ažuriranja	24
Broj epoha učenja po ažuriranju	5
Broj mini-grupa	4
Stopa učenja	10^{-3} , prilagodljiva prema odstupanju KL
Diskontni faktor γ	0,99
Faktor generalizirane procjene prednosti λ	0,95
Koeficijent odsijecanja ϵ	0,2
Koeficijent entropije	0,001
Početna standardna devijacija politike	0,5

Broj paralelnih okruženja postavljen je na 1024, kao kompromis između propusnosti i broja dostupnih pokretanja. Svako je pokretanje trajalo 2400 iteracija, a sve brojke u nastavku očitane su kao prosjek zadnjih 100 iteracija, zato što pojedinačna iteracija nosi previše šuma da bi sama predstavljala izvedbu politike.

7.4. Rezultati


Slika 17 prikazuje karakteristične trenutke izvođenja naučene politike. Epizoda počinje od stanja u kojem prihvatnica već drži kvaku, u skladu s opsegom iz potpoglavlja 7.1., pa faze prilaska i hvata na slikama nema.

**Slika 17. Faze izvođenja naučene politike na oba tipa vrata**

Slika 18 prikazuje tijek učenja dvjema veličinama. Gornji red je prosječni otvor vrata, dobiven iz pripadnog člana nagrade dijeljenjem njegovom težinom i množenjem referentnom

vrijednošću. Riječ je o dvostrukom prosjeku, po vremenu unutar epizode i po svim istovremenim okruženjima, pa je sustavno niži od otvora postignutog na kraju uspješne epizode: epizoda počinje sa zatvorenim vratima, a u prosjek ulaze i okruženja u kojima otvaranje ne uspije. Donji red prikazuje udio epizode tijekom kojeg su vrata iznad praga uspjeha, što izravnije pokazuje koliko je politika naučila otvarati. Svijetla linija je vrijednost po iteraciji, a tamna pomični prosjek.


Obje veličine konvergiraju, uz ustaljenu vrijednost u zadnjoj trećini učenja. Donja krivulja kreće kasnije od gornje, jer politika najprije nauči vrata uopće pomaknuti, a tek potom otvoriti ih dovoljno široko da prijeđe prag. Kod kliznih vrata ucrtana je i iteracija na kojoj završava kurikulum otpora (potpoglavlje 7.2.6.).



Slika 18. Tijek učenja: prosječni otvor vrata kroz epizodu, po iteraciji

Obje politike konvergiraju, uz ustaljenu vrijednost u zadnjoj trećini učenja. Kod kliznih vrata ucrtana je i iteracija na kojoj završava kurikulum otpora (potpoglavlje 7.2.6.), pa se vidi mijenja li se ponašanje kad politika prvi put vidi puni raspon otpora.

Slika 19 prikazuje kako se kroz učenje mijenjaju udjeli pojedinih razloga prekida epizode.



Slika 19. Udjeli razloga prekida epizode kroz iteracije učenja

Udio epizoda prekinutih istekom vremena raste kroz učenje, a udio onih prekinutih gubitkom hvata i dodiranjem krila pada. Politika, dakle, ne uči samo otvarati vrata, nego prije svega prestaje raditi ono zbog čega bi epizoda završila prerano.

Tablica 18 navodi rezultate na sceni sa zidovima i s graničnim vrijednostima zgloba vrata usklađenima s klasičnim pristupom. Radi usporedivosti, obje su politike trenirane s istim brojem okruženja i istim brojem iteracija, a sve su vrijednosti prosjek zadnjih 100 iteracija. Prva dva retka tablice vrijednosti su pripadnih članova nagrade, a ne veličine koje izravno opisuju ishod. Okruženje ih prije zapisivanja dijeli duljinom epizode, pa su ispod svakog člana navedene veličine izvedene iz njega: član napretka razmjernan je prosječnom otvoru vrata kroz epizodu, a član uspjeha udjelu epizode tijekom kojeg su vrata iznad praga uspjeha. Udjeli prekida u nastavku tablice jesu udjeli epizoda i zbrajaju se na jedinicu.

Tablica 18. Rezultati pristupa temeljenog na učenju, 1024 okruženja, 2400 iteracija

Veličina	Zakretna vrata	Klizna vrata
Član napretka	18,93	9,87
prosječni otvor kroz epizodu	0,947 rad	0,592 m
Član uspjeha	0,743	0,831
udio epizode iznad praga	0,371	0,416
Udio: izgubljen hvat	0,072	0,000
Udio: dodir krila	0,061	0,003
Udio: dodir zida	0,002	0,000
Udio: prekomjerna sila	0,006	0,028
Udio: istek vremena	0,860	0,969
Duljina epizode, koraci	561,8	587,4

Te vrijednosti opisuju ponašanje politike tijekom učenja, uz šum istraživanja. Stopa uspjeha pri determinističkom izvođenju mjerena je zasebno i navedena je u poglavlju 8..

7.5. Ograničenja

- Naučena politika koristi srednju vrijednost razdiobe akcije, bez šuma istraživanja, pa se izvedba pri izvođenju ne mora poklapati s brojkama iz treninga, koje su mjerene uz šum.
- Kazna za odstupanje platforme od okomice na vrata pogoršava se u zadnjoj četvrtini treninga, jer okomit položaj platforme stvarno smanjuje doseg ruke montirane izvan njezine osi, pa politika pred kraj treninga taj kompromis rješava nešto drugačije nego ranije.
- Politika, za razliku od klasičnog pristupa, ne raspolaže nikakvim posredovanim signalom o tipu ili smjeru ograničenja: geometriju mora otkriti iz iste sile i pomaka kojima i djeluje.

8. REZULTATI SIMULACIJSKOG ISPITIVANJA I RASPRAVA

Poglavlja 6. i 7. iznose rezultate svakog pristupa na njegovim vlastitim uvjetima, a ovo ih poglavlje uspoređuje. Najprije utvrđuje što se smije uspoređivati, zatim izlaže usporedbu po uspješnosti otvaranja, kontaktnim silama i pouzdanosti izvođenja, i naposljetku raspravlja o tome što razlike znače.

8.1. Protokol usporedbe

8.1.1. Što se uspoređuje

Usporedba obuhvaća isključivo fazu otvaranja vrata. Klasični pristup izvodi cijeli lanac, od prilaska i hvata preko otvaranja do prolaska kroz vrata, dok pristup temeljen na učenju kreće od stanja u kojem prihvatnica već drži kvaku (potpoglavlje 7.1.). Da bi usporedba bila dosljedna, oba pristupa moraju krenuti od uspješno uspostavljenog hvata, tj. neuspjesi klasičnog pristupa nastali prije početka otvaranja, dakle u fazi prilaska ili hvata, ne ulaze u stopu uspjeha otvaranja, nego se razmatraju zasebno, u potpoglavlju 8.4..

Bitno je razgraničiti i to što se zapravo uspoređuje. Nije riječ o općenitoj usporedbi pristupa temeljenih na modelu s onima temeljenima na učenju, nego o usporedbi dviju konkretnih izvedbi: klasičnog pristupa koji vrh alata vodi krutim pozicijskim upravljanjem po unaprijed izračunatoj putanji, i naučene politike koja upravlja varijabilnom impedancijom. Razlika u ostvarenim rezultatima stoga se ne smije pripisati učenju kao takvom. Posve je moguće da bi klasični pristup uz impedancijski regulator, kakav je opisan u poglavlju 2., dao bitno bolje rezultate od ovdje izvedenog; takva usporedba nije provedena i ostaje otvorena.

8.1.2. Dvije različite mjere

Rezultati naučene politike iskazuju se dvjema odvojenim veličinama, koje se ne smiju miješati.

Pouzdanost cjelovitog izvođenja računa se nad svim evaluacijskim epizodama. U dijelu epizoda pri determinističkom izvođenju izostane koordinirano gibanje platforme, pa manipulator doseže granicu vlastitog radnog prostora i otvaranje staje na oko 0,45 m odnosno 12° (potpoglavlje 7.5.). Budući da je takvo ponašanje posljedica same politike, a ne vanjske smetnje, te epizode predstavljaju neuspjeh upravljačkog sustava i ulaze u ovu mjeru.

Uspješnost regulatora računa se samo nad epizodama u kojima je koordinirano gibanje

ostvareno. Ona ne opisuje pouzdanost sustava, nego sposobnost samog zakona upravljanja da vrata otvori kad izvođenje uopće krene.

8.2. Uspješnost otvaranja

Tablica 19. Stopa uspjeha otvaranja, uz uspostavljen hvat na početku

Vrata	Prag	Klasični	Pristup učenjem	
		pristup	sve epizode	s ostvarenim gibanjem
zakretna	50°	100,0 %	54,0 %	100,0 %
zakretna	90°	100,0 %	51,9 %	96,1 %
klizna	0,60 m	100,0 %	48,4 %	95,1 %
klizna	0,90 m	100,0 %	46,9 %	93,2 %

Stupac *sve epizode* računat je nad svim evaluacijskim epizodama, a stupac *s ostvarenim gibanjem* samo nad epizodama u kojima je ostvareno koordinirano gibanje platforme (potpoglavlje 8.1.2.).

Uz uspostavljen hvat klasični pristup doseže zadani kut u svakom pokretanju, na obama tipovima vrata. Kod zakretnih vrata guranje dovodi krilo do otprilike 70°, a završni zakret platforme do otprilike 100°, čime se prelazi i prag od 90° koji koristi naučena politika. Klizna vrata otvaraju se 904 do 910 mm uz cilj od 900 mm.

Naučena politika, promatrana kao cjelovito izvođenje, uspijeva u otprilike polovici epizoda, i to podjednako na oba tipa vrata. Promatra li se samo kao zakon upravljanja, nad epizodama u kojima izvođenje ispravno krene, otvara vrata u više od 90 % epizoda.

Promatra li se samo uspješnost, klasični pristup doseže cilj u svakom pokretanju, na oba praga i oba tipa vrata, dok naučena politika kao cjelovito izvođenje uspijeva u otprilike polovici epizoda. Po tom mjerilu klasični je pristup pouzdaniji i robustniji.

Raspodjela ostvarenog otvora kod naučene politike izrazito je dvomodalna: epizoda ili stane na početnoj vrijednosti, ili se vrata otvore gotovo do kraja hoda. Kod zakretnih vrata medijan ostvarenog otvora iznosi 122°, a gornji kvartil 134°, praktički na mehaničkoj granici zgloba; kod kliznih vrata medijan leži na 0,94 m, tik ispod punog hoda. Između praga uspjeha i te granice gotovo da nema epizoda. Klasični se pristup ponaša suprotno: ostvareni otvor vrlo je ponovljiv i zaustavlja se točno ondje gdje mu je cilj postavljen.

8.3. Kontaktne sile

Sile se iskazuju trima veličinama. Prosječna vrijednost opisuje tipično opterećenje, efektivna vrijednost (RMS) je mjera energije opterećenja i kažnjava trajno visoku silu više nego kratke vrhove, a najveća vrijednost opisuje najgori pojedinačni trenutak. Kod na-

učene politike navode se odvojeno za epizode u kojima je ostvareno koordinirano gibanje i za sve epizode, u skladu s razgraničenjem iz potpoglavlja 8.1.2..

Tablica 20. Kontaktne sile pri otvaranju

Vrata	Pristup	Prosječna	RMS	Najveća
zakretna	klasični	300–450 N	325 N	645 N
zakretna	učenjem, s ostvarenim gibanjem	20,1 N	29,2 N	391,0 N
zakretna	učenjem, sve epizode	15,5 N	21,5 N	391,0 N
klizna	klasični	240–285 N	270 N	660 N
klizna	učenjem, s ostvarenim gibanjem	11,9 N	21,7 N	381,0 N
klizna	učenjem, sve epizode	10,7 N	17,5 N	381,0 N

Efektivna vrijednost računata je unutar pojedine epizode, a zatim usrednjena preko epizoda.

Podjela po ishodu epizode otkriva nešto što se iz ukupnog prosjeka ne bi vidjelo, a to je da epizode bez ostvarenog gibanja platforme imaju nižu, a ne višu silu. Prosjek preko svih epizoda time je niži od prosjeka preko onih u kojima je gibanje ostvareno. Politika u tim epizodama jednostavno ne djeluje na vrata.

Razlika među pristupima je reda veličine. Efektivna vrijednost sile naučene politike iznosi jedanaest do dvanaest puta manje od one kod klasičnog pristupa, na oba tipa vrata. Uzrok je razlika u načinu vođenja: klasični pristup vrh alata vodi krutim pozicijskim upravljanjem, pa svako odstupanje između procijenjene i stvarne geometrije, kao i svako ubrzanje platforme, prolazi kroz krutu vezu i pojavljuje se kao sila. Naučena politika krutost regulatora bira po osi i u svakom koraku, pa u smjeru u kojem se bori s ograničenjem popušta.

Da je riječ upravo o tome, potvrđuje usporedba s otporom samih vrata. Kod kliznih vrata otpor je varirao u rasponu od 5 do 60 N (tablica 6), a prosječna sila naučene politike iznosi 11,9 N, dakle unutar tog raspona. Politika vrata otvara silom koja je istog reda veličine kao njihov stvarni otpor, dok je sila klasičnog pristupa red veličine veća od njega i većim dijelom potječe od tranzijenata, a ne od savladavanja otpora.

Najveća sila kod naučene politike iznosi 391 N na zakretnim i 381 N na kliznim vratima, dakle tik ispod granice prekida od 400 N. Ta vrijednost stoga ne opisuje tipično ponašanje, nego vrlo vjerojatno mjesto na kojem se epizoda prekida, a udio takvih epizoda iznosi 0,6 % odnosno 2,8 %.

Sile kod klasičnog pristupa procijenjene su iz momenata u zglobovima, postupkom čiji je rezidual reda dvadesetak njutna (potpoglavlje 5.1.1.), dok su kod naučene politike očitane izravno iz simulacije, bez šuma. Rezidual procjenitelja time je istog reda veličine kao cjelokupna prosječna sila naučene politike. Razlika od reda veličine ostaje valjana, ali usporedba pojedinačnih iznosa ispod otprilike dvadeset njutna nije.

8.4. Pouzdanost cjelovitog izvođenja

Dva pristupa ne otkazuju na istim mjestima, i ta je razlika informativnija od samih stopa uspjeha.

Kod klasičnog pristupa otkazivanje se skoro isključivo javlja prije otvaranja, u fazi hvata. Kad otvaranje jednom krene, dovrši se svaki put i s malim rasipanjem. Slabija karika klasičnog pristupa time nije upravljanje u kontaktu, nego percepcija i hvat, dakle dijelovi koje naučena politika prema odluci o opsegu iz potpoglavlja 7.1. uopće ne izvodi.

Naučena politika otkazuje tijekom faze koja se uspoređuje. Uz izostanak koordiniranog gibanja platforme, koji je najčešći način otkazivanja, gubi hvat u 5,7 % epizoda na zakretnim vratima i dodiruje krilo u 6,1 %. Kod kliznih su vrata oba udjela gotovo nula. Dodir zida zanemariv je u obama slučajevima, što pokazuje da je politika naučila izbjegavati i prepreku koja je u zadatak uvedena kasnije, a ne samo onu koja je od početka bila kažnjavana.

Posljedica je da se prednost jednog ili drugog pristupa ne može izreći jednim brojem. Klasični je pristup pouzdaniji i doseže cilj u svakom pokretanju, ali uz opterećenje reda veličine veće od otpora samih vrata. Naučena politika djeluje silom bliskom tom otporu, ali u polovici pokretanja uopće ne krene.

8.5. Rasprava

8.5.1. *Različiti ulazi u isti problem*

Razlika u rezultatima ne smije se čitati samo kao razlika u kvaliteti upravljanja, jer dva pristupa ne rješavaju problem s istim informacijama.

Klasični pristup zna gdje je os šarke. Izračunava je iz poze oznake i poznate širine krila, kao fiksni vektor u koordinatnom sustavu oznake (izraz (7)), uz izmjerenu pogrešku od 5,8 mm prosječno do 14,3 mm. Naučena politika taj podatak nema ni u kojem obliku i geometriju ograničenja mora zaključiti iz vlastitih opažanja sile i pomaka.

Tu tvrdnju ipak treba uzeti s mjerom opreza. Politika nije jedinstvena: za zakretna i klizna vrata istrenirane su zasebne politike, uz različite težine pojedinih članova nagrade i, kod kliznih vrata, uz postupno uvođenje otpora tijekom učenja (potpoglavlje 7.2.6.). Svaka politika stoga uči jedan tip ograničenja, a ne razlikovanje među njima. Ono što politika doista otkriva jest kako se ograničenje ponaša tijekom interakcije, a ne kojeg je tipa.

Asimetrija ide i u drugom smjeru. Naučena politika koordinaciju platforme i manipulatora uči zajedno s ostatkom zadatka, dok je klasični pristup rješava unaprijed propisanim slijedom faza.

8.5.2. *Uspješnost naspram opterećenja*

Nalaz da oba pristupa dosežu cilj, a razlikuju se za red veličine u sili, traži objašnjenje na obje strane.

Klasični pristup uspijeva unatoč visokoj sili zato što je ona uglavnom tranzijentna, a ne trajna. Nastaje pri pokretanju platforme iz mirovanja i pri svakom odstupanju između procijenjene i stvarne geometrije, prolazi kroz krutu vezu manipulatora i kvake, i traje kratko. Model vrata, prihvatnica i hvat to opterećenje podnose, pa se zadatak dovrši. Na stvarnom robotu ista bi sila bila bitno problematičnija, jer bi je morali podnijeti i stvarni prsti, stvarna kvaka i stvarni zglobovi vrata.

Naučena politika istu razinu sile ne treba jer krutost regulatora bira po osi i u svakom koraku. U smjeru u kojem se bori s ograničenjem popušta, pa odstupanje procjene ne postaje sila nego pomak reference koji ograničenje samo ispravi. Izmjerena prosječna sila od 11,9 N na kliznim vratima, unutar raspona stvarnog otpora od 5 do 60 N, pokazuje da politika vrata otvara gotovo isključivo savladavanjem njihova otpora, bez dodatnog opterećenja.

Zaključak je time uvjetovan, a ne općenit. Ako je mjerilo isključivo dovršava li robot zadatak, kruto pozicijsko upravljanje uz dobro procijenjenu geometriju dovoljno je i pouzdano. Ako se u mjerilo uključi i opterećenje koje pritom nastaje, prednost prelazi na upravljanje s promjenjivom krutošću. Ta razlika nije razlika između modela i učenja, nego između krutog i popustljivog vođenja, kako je istaknuto u potpoglavlju 8.1..

8.6. Ograničenja usporedbe

- Usporedba obuhvaća isključivo fazu otvaranja. Prilazak i hvat klasični pristup izводи, a naučena politika ne, pa se ukupna sposobnost rješavanja zadatka ovim mjerenjima ne uspoređuje.
- Usporedba nije općenita usporedba pristupa temeljenih na modelu s onima temeljenima na učenju, nego usporedba krutog pozicijskog upravljanja s varijabilnom impedancijom. Klasični pristup izveden s impedancijskim regulatorom nije ispitan.
- Uzorci nisu iste veličine: stotine epizoda naspram 20 pokretanja klasičnog pristupa. Stopa uspjeha klasičnog pristupa time nosi znatno veću nesigurnost.
- Trajanje izvođenja nije uspoređivano. Epizoda naučene politike traje najviše deset sekundi i najčešće istekne bez prekida, jer uspjeh ne prekida epizodu, dok klasični pristup traje dok zadatak ne dovrši. Te dvije veličine ne mjere isto.
- Obje su izvedbe ispitane isključivo u simulaciji. Zaključci se odnose na model, a

prenosivost na stvarni robot ograničena je pojednostavljenjima navedenima u poglavljima 3. i 4..

9. ZAKLJUČAK

U radu je razvijen i eksperimentalno vrednovan sustav za autonomnu interakciju mobilnog manipulatora s okolinom, na primjeru otvaranja zakretnih i kliznih vrata. Sustav objedinjuje percepciju, procjenu sile i momenta te upravljanje u kontaktu, a zadatak upravljanja riješen je dvama pristupima: klasičnim, temeljenim na modelu, i pristupom temeljenim na podržanom učenju. pristupi su potom uspoređeni na istom robotu, istoj sceni i istim mjerilima.

Modul percepcije određuje položaj i orijentaciju kvake iz slike, pomoću vizualnih oznaka. Postupak procjene sile i momenta na vrhu alata izveden je iz momenata u zglobovima, bez zasebnog senzora sile, a iz odnosa procijenjene sile i ostvarenog pomaka pokazano je kako se procjenjuju krutost okoline i geometrija ograničenja gibanja.

Klasični pristup rješava cijeli zadatak, od prilaska i hvata preko otvaranja do prolaska kroz vrata, pri čemu tip vrata prepoznaje sam, iz geometrije kvake. Pristup temeljen na učenju formuliran je kao Markovljev proces odlučivanja s varijabilnom impedancijom u prostoru akcije, čime politika u svakom koraku bira koliko će regulator biti krut po svakoj osi.

9.1. Glavni nalazi

Oba pristupa dosežu zadani cilj, na obama tipovima vrata. Razlika među njima ne očituje se u tome uspijevaju li, nego u pouzdanosti izvođenja i u opterećenju kojim vrata otvaraju, i upravo je taj odnos najvrjedniji nalaz rada.

Klasični pristup otvara vrata u svakom pokretanju u kojem je hvat uspješno uspostavljen, uz vrlo ponovljiv ishod. Naučena politika, promatrana kao cjelovito izvođenje, uspijeva u otprilike polovici epizoda, jer u preostalima izostane koordinirano gibanje platforme; promatra li se samo kao zakon upravljanja, nad epizodama u kojima izvođenje krene, otvara vrata u više od devedeset posto slučajeva. Te se dvije mjere ne smiju miješati, pa se u radu navode odvojeno.

Kontaktne su sile red veličine niže kod naučene politike. Efektivna vrijednost iznosi 29 N naspram 325 N kod zakretnih te 22 N naspram 270 N kod kliznih vrata, dakle jedanaest do dvanaest puta manje. Usporedba s randomiziranim otporom vrata pokazuje zašto: prosječna sila naučene politike na kliznim vratima iznosi 11,9 N, što je unutar raspona stvarnog otpora od 5 do 60 N. Politika, dakle, vrata otvara gotovo isključivo savladavanjem njihova otpora, dok kod klasičnog pristupa veći dio sile potječe od tranzijenata koji nastaju pri pokretanju platforme i pri svakom odstupanju procjene, a prolaze kroz krutu vezu između manipulatora i kvake.

Zaključak je time uvjetovan, a ne općenit. Ako je mjerilo isključivo dovršava li robot zadatak, kruto pozicijsko upravljanje uz dobro procijenjenu geometriju dovoljno je i pouzdano. Ako se u mjerilo uključi i opterećenje koje pritom nastaje, prednost prelazi na upravljanje s promjenjivom krutošću. Ta razlika nije razlika između modela i učenja, nego između krutog i popustljivog vođenja; klasični pristup izveden s impedancijskim regulatorom nije ispitan i mogao bi dati drugačiji ishod.

Dva se pristupa razlikuju i po tome što o zadatku znaju. Klasični pristup položaj osi šarke izračunava iz poze oznake i poznate širine krila, uz pogrešku od 5,8 mm prosječno do 14,3 mm, dok naučena politika tu geometriju nema ni u kojem obliku i ponašanje ograničenja mora zaključiti iz vlastitih opažanja sile i pomaka. Tu tvrdnju treba uzeti s mjerom opreza, jer su za svaki tip vrata trenirane zasebne politike, pa svaka uči jedan tip ograničenja, a ne razlikovanje među njima.

9.2. Ograničenja

Cjelokupan je rad proveden u simulaciji, pa se zaključci odnose na model, a ne izravno na stvarni robot. Uz to, sustav sadrži nekoliko svjesnih pojednostavljenja i nekoliko neriješenih pitanja.

Zglob koji bi omogućio zakretanje kvake zavaren je u oba pristupa, čime je zadatak sveden na jedan stupanj slobode po tipu vrata. Percepcija se oslanja na vizualne oznake postavljene na vrata, pa sustav u nepripremljenoj okolini ne bi radio. Mecanum kotači nisu simulirani kao tijela u kontaktu s podlogom, nego je gibanje platforme zadano kinematički. Gibanje platforme ima izraženu mrtvu zonu i ne postiže naredenu brzinu, a uzrok nije utvrđen unatoč tomu što je više mogućih objašnjenja provjereno i isključeno. Posljedica je da regulator koji zadaje male korekcije postaje dvopoložajan. Prijedeni put platforme zato se ne računa iz naredene brzine nego se mjeri odometrijom.

Pri determinističkom izvođenju naučene politike u dijelu epizoda izostane koordinirano gibanje platforme. Uzrok je zatvoreni kinematički lanac koji nastaje kad prihvatnica drži kvaku, a manipulator se ispruži do granice radnog prostora, a lanac se tada geometrijski zaključa. Kazna na blizinu singularitetu taj problem uklanja tijekom učenja, gdje politika ima šum istraživanja, ali se pri izvođenju srednje akcije vraća.

Naposljetku, sustav sadrži postupak procjene geometrije ograničenja iz odnosa sile i gibanja, ali on nije povezan s izvođenjem: u klasičnom se pristupu os šarke izračunava iz percepcije, a procjena iz gibanja postoji kao zaseban, samostalno provjeren postupak.

9.3. Smjernice za daljnji rad

- **Povezivanje procjene ograničenja s izvođenjem.** Pokretanje procjene odmah nakon hvata i odabir načina otvaranja na temelju njezina ishoda uklonilo bi oslaňjanje na tip kvake prepoznat iz percepcije i učinilo sustav neovisnim o poznatoj geometriji.
- **Klasični pristup s impedancijskim regulatorom.** Usporedba provedena u ovom radu suprotstavlja kruto pozicijsko upravljanje upravljanju promjenjivom krutošću. Izvedba klasičnog pristupa s impedancijskim regulatorom pokazala bi koliko je razlika u silama posljedica učenja, a koliko same popustljivosti.
- **Zakretanje kvake.** Vraćanje tog stupnja slobode proširilo bi zadatak na vrata sa stvarnom bravom, ali bi tražilo upravljanje koje kut zakreta kvake ne prati kruto.
- **Detekcija bez oznaka.** Zamjena vizualnih oznaka postupkom koji kvaku prepoznaje izravno iz slike uklonila bi najizraženije pojednostavljenje u radu, pri čemu ostatak sustava ne bi trebalo mijenjati, jer je sučelje prema izvođenju zadatka svedeno na pozu hvatišta.
- **Prijenos na stvarni robot.** Konačna provjera svih zaključaka traži izvođenje izvan simulacije, pri čemu su procjena sile bez zasebnog senzora i pojednostavljeni model gibanja platforme najizgledniji izvori odstupanja.

LITERATURA

- [1] Marc H. Raibert and John J. Craig. Hybrid position/force control of manipulators. *Journal of Dynamic Systems, Measurement, and Control*, 103(2):126–133, 1981.
- [2] Christian Ott, Berthold Bäuml, Christoph Borst, and Gerd Hirzinger. Employing cartesian impedance control for the opening of a door: A case study in mobile manipulation. In *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), Workshop on Mobile Manipulators*, 2005.
- [3] Jürgen Sturm, Cyrill Stachniss, and Wolfram Burgard. A probabilistic framework for learning kinematic models of articulated objects. *Journal of Artificial Intelligence Research*, 41:477–526, 2011.
- [4] Oussama Khatib. A unified approach for motion and force control of robot manipulators: The operational space formulation. *IEEE Journal of Robotics and Automation*, 3(1):43–53, 1987.
- [5] Roberto Martín-Martín, Michelle A. Lee, Rachel Gardner, Silvio Savarese, Jeannette Bohg, and Animesh Garg. Variable impedance control in end-effector space: An action space for reinforcement learning in contact-rich tasks. In *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 1010–1017, 2019.
- [6] Fares J. Abu-Dakka and Matteo Saveriano. Variable impedance control and learning — a review. *Frontiers in Robotics and AI*, 7:590681, 2020.
- [7] Thushara Sandakalum and Marcelo H. Ang. Motion planning for mobile manipulators — a systematic review. *Machines*, 10(2), 2022.
- [8] Johannes Pankert and Marco Hutter. Perceptive model predictive control for continuous mobile manipulation. *IEEE Robotics and Automation Letters*, 5(4):6177–6184, 2020.
- [9] Giuseppe Rizzi, Jen Jen Chung, Abel Gawel, Lionel Ott, Marco Tognon, and Roland Siegwart. Robust sampling-based control of mobile manipulators for interaction with articulated objects. *IEEE Transactions on Robotics*, 39(3), 2023.
- [10] Roberto Martín-Martín and Oliver Brock. Coupled recursive estimation for online interactive perception of articulated objects. *The International Journal of Robotics Research*, 41(8):741–777, 2022.

- [11] Mayank Mittal, David Hoeller, Farbod Farshidian, Marco Hutter, and Animesh Garg. Articulated object interaction in unknown scenes with whole-body mobile manipulation. In *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 1647–1654, 2022.
- [12] Zihang Zhao, Yuyang Li, Wanlin Li, Zhenghao Qi, Lecheng Ruan, Yixin Zhu, and Kaspar Althoefer. Tac-Man: Tactile-informed prior-free manipulation of articulated objects. *IEEE Transactions on Robotics*, 41:538–557, 2024.
- [13] Marvin Stuede, Kathrin Nuelle, Svenja Tappe, and Tobias Ortmaier. Door opening and traversal with an industrial cartesian impedance controlled mobile robot. In *IEEE International Conference on Robotics and Automation (ICRA)*, 2019.
- [14] Quantao Yang, Alexander Dürr, Elin A. Topp, Johannes A. Stork, and Todor Stoyanov. Variable impedance skill learning for contact-rich manipulation. *IEEE Robotics and Automation Letters*, 7(3):8391–8398, 2022.
- [15] Heng Zhang, Gokhan Solak, Gustavo J. G. Lahr, and Arash Ajoudani. SRL-VIC: A variable stiffness-based safe reinforcement learning for contact-rich robotic tasks. *IEEE Robotics and Automation Letters*, 9(6):5631–5638, 2024.
- [16] Daniel Honerkamp, Tim Welschhold, and Abhinav Valada. Learning kinematic feasibility for mobile manipulation through deep reinforcement learning. *IEEE Robotics and Automation Letters*, 6(4):6289–6296, 2021.
- [17] Daniel Honerkamp, Tim Welschhold, and Abhinav Valada. N²M²: Learning navigation for arbitrary mobile manipulation motions in unseen and dynamic environments. *IEEE Transactions on Robotics*, 2023.
- [18] Raphael Schneider, Daniel Honerkamp, Tim Welschhold, and Abhinav Valada. Task-driven co-design of mobile manipulators. *arXiv preprint arXiv:2412.16635*, 2024.
- [19] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017.
- [20] Wenshuai Zhao, Jorge Peña Queralta, and Tomi Westerlund. Sim-to-real transfer in deep reinforcement learning for robotics: A survey. In *IEEE Symposium Series on Computational Intelligence (SSCI)*, pages 737–744, 2020.
- [21] Josh Tobin, Rachel Fong, Alex Ray, Jonas Schneider, Wojciech Zaremba, and Pieter Abbeel. Domain randomization for transferring deep neural networks from simulation to the real world. In *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 23–30, 2017.

- [22] Xue Bin Peng, Marcin Andrychowicz, Wojciech Zaremba, and Pieter Abbeel. Sim-to-real transfer of robotic control with dynamics randomization. In *IEEE International Conference on Robotics and Automation (ICRA)*, pages 3803–3810, 2018.
- [23] KUKA Deutschland GmbH. KMR iiwa — always spot-on safely. Katalog proizvoda, PBJ Portfolio (EN) 05/2024, 2024. <https://www.kuka.com>.
- [24] RobotShop. Andymark bb mecanum wheel. <https://www.robotshop.com/products/andymark-4in-bb-mecanum-wheel-05in-hex-bore-right>. pristupljeno: 07.09.2026.
- [25] Christoph Hennersperger, Salvatore Virga, et al. iiwa_stack: ROS integration for KUKA LBR IIWA robots. https://github.com/IFL-CAMP/iiwa_stack. Technische Universität München, IFL-CAMP.
- [26] NVIDIA. Isaac Lab: A unified framework for robot learning. <https://isaac-sim.github.io/IsaacLab/>, 2024.
- [27] Edwin Olson. AprilTag: A robust and flexible visual fiducial system. In *IEEE International Conference on Robotics and Automation (ICRA)*, pages 3400–3407, 2011.
- [28] Yoshikawa. Manipulability of robotic mechanisms. *The International Journal of Robotics Research*, 4(2), 1985.

PRILOZI

Poveznica na repozitorij sa svim programskim kodom korištenim u ovom radu:

<https://github.com/DavidMihic/bachelors-thesis>