

SVEUČILIŠTE U ZAGREBU
FAKULTET STROJARSTVA I BRODOGRADNJE

ZAVRŠNI RAD

David Mihić

ZAGREB, 2026.

SVEUČILIŠTE U ZAGREBU

FAKULTET STROJARSTVA I BRODOGRADNJE

ZAVRŠNI RAD

Mentor:

Student:

Doc. dr. sc. Bojan Šekoranja,
mag.ing.

David Mihić

ZAGREB, 2026.

Izjavljujem da sam ovaj rad izradio samostalno koristeći znanja stečena tijekom studija i navedenu literaturu.

Zahvaljujem se mentoru, doc. dr. sc. Bojanu Šekoranji na pomoći i prijedlozima, kao i kolegi Branimiru Čaranu na iznimnoj pomoći i podršci.

Hvala mojoj obitelji i svim prijateljima, kao i svima ostalima koji su me podržavali i poticali tijekom studija.

Također sam vrlo zahvalan kolegama i osoblju iz laboratorija CRTA na svim prilikama koje su mi pružili tijekom studija.

David Mihić

Sveučilište u Zagrebu Fakultet strojarstva i brodogradnje	
Datum	Prilog
Klasa: 602-01/26-01/3	
Ur.broj: 15-31000-26-	

ZAVRŠNI ZADATAK

Student: David Mihić

JMBAG: 0035250443

Naslov rada na hrvatskom jeziku: **Razvoj i evaluacija metode upravljanja mobilnim manipulatorom u interakciji s okolinom**Naslov rada na engleskom jeziku: **Development and evaluation of a control method for a mobile manipulator in interaction with the environment**

Opis zadatka:

U ovom radu razmatra se problem autonomne interakcije mobilnog manipulatora s okolinom kroz zadatke koji uključuju uspostavu i održavanje kontakta s objektima te izvođenje koordiniranih manipulacijskih radnji. Naglasak je na integraciji percepcije, procjene stanja i upravljanja u jedinstveni sustav sposoban za izvršavanje višefaznih zadataka u nepoznatim ili djelomično poznatim uvjetima.

Cilj rada je razviti i eksperimentalno evaluirati metodologiju upravljanja koja omogućuje robotu donošenje odluka i generiranje gibanja na temelju više senzorskih podataka, uzimajući u obzir mehanička svojstva okoline i interakcijske sile.

U radu je potrebno:

- istražiti postojeće pristupe upravljanju mobilnim manipulatorima u zadacima koji uključuju fizičku interakciju s objektima
- razviti modul percepcije za detekciju relevantnih objekata te procjenu njihove pozicije i orijentacije korištenjem dostupnih senzora
- implementirati postupak procjene svojstava okoline (npr. krutost, ograničenja gibanja) na temelju mjerenja sile i momenta tijekom interakcije
- modelirati i implementirati dva različita pristupa upravljanju sustavom (klasični pristup temeljen na modelu i pristup temeljen na učenju)
- definirati i implementirati odgovarajuću reprezentaciju stanja, akcija i kriterija uspješnosti za odabrani pristup učenja
- analizirati i usporediti performanse implementiranih metoda s obzirom na učinkovitost i robusnost sustava

U radu je potrebno navesti korištenu literaturu i eventualno dobivenu pomoć.

Zadatak zadan:

22. 4. 2026.

Zadatak zadao:

doc. dr. sc. Bojan Šekoranja

Datum predaje rada:

2. rok: 15. i 16. 7. 2026.

3. rok: 16. i 17. 9. 2026.

Predviđeni datumi obrane:

2. rok: 21. - 23. 7. 2026.

3. rok: 22. - 24. 9. 2026.

Predsjednik Povjerenstva:

izv. prof. dr. sc. Petar Čurković

SADRŽAJ

SADRŽAJ	i
POPIS SLIKA	iii
POPIS TABLICA	iv
POPIS OZNAKA	v
POPIS KRATICA	vi
SAŽETAK	vii
SUMMARY	viii
1. UVOD	1
1.1. Motivacija	1
1.2. Struktura rada	2
2. PREGLED DOSADAŠNJIH ISTRAŽIVANJA	3
2.1. Klasični pristupi upravljanju u kontaktu	3
2.2. Mobilna manipulacija	3
2.3. Interakcija s artikuliranim objektima	3
2.4. Pristupi temeljeni na učenju	3
3. ROBOTSKI SUSTAV I SIMULACIJSKO OKRUŽENJE	4
3.1. KMR iiwa — mobilna platforma i manipulator	4
3.1.1. Mobilna platforma	4
3.1.2. Manipulator LBR iiwa 7 R800	5
3.2. Prihvatnica	6
3.3. Modeli vrata	8
3.3.1. Otpor gibanja i njegova randomizacija	9
3.4. Model robota i pretvorba u simulacijski format	9
3.4.1. Gibanje mobilne platforme	12
3.5. Simulacijsko okruženje	12
3.6. Programska arhitektura	13
4. MODUL PERCEPCIJE	16

4.1.	Senzorski postav	16
4.2.	Detekcija i procjena poze	16
4.3.	Sučelje modula	16
4.4.	Ograničenja pristupa	16
5.	PROCJENA SVOJSTAVA OKOLINE	17
5.1.	Procjena sile i momenta na vrhu alata	17
5.2.	Procjena ograničenja gibanja	17
5.3.	Ispitno gibanje za utvrđivanje stanja brave	17
6.	KLASIČNI PRISTUP UPRAVLJANJU	18
6.1.	Struktura zadatka	18
6.2.	Upravljanje u fazi prilaza i hvata	18
6.3.	Upravljanje u fazi otvaranja	18
6.4.	Ograničenja	18
7.	PRISTUP TEMELJEN NA UČENJU	19
7.1.	Formulacija Markovljevog procesa odlučivanja	19
7.1.1.	Prostor stanja	19
7.1.2.	Prostor akcija	19
7.1.3.	Funkcija nagrade	19
7.2.	Postupak učenja	19
7.3.	Ablacijske studije	19
8.	EKSPERIMENTALNI REZULTATI I RASPRAVA	20
8.1.	Metrike i eksperimentalni protokol	20
8.2.	Rezultati klasičnog pristupa	20
8.3.	Rezultati pristupa temeljenog na učenju	20
8.4.	Usporedba pristupa	20
8.5.	Rasprava	20
9.	ZAKLJUČAK	21
	LITERATURA	22

POPIS SLIKA

1	Mobilni manipulator KMR iiwa u simulacijskom okruženju	4
2	Građa Mecanum kotača	5
3	Prihvatnica s četiri prsta; otvorena (lijevo) i zatvorena (desno)	7
4	Položaj vrha alata	7
5	Modeli zakretnih i kliznih vrata s označenim stupnjem slobode gibanja . . .	8
6	Postupak izrade simulacijskog modela iz opisa robota i vrata	11
7	Programska arhitektura klasičnog pristupa	14
8	Programska arhitektura pristupa temeljenog na učenju	15

POPIS TABLICA

2	Tehnički podaci mobilne platforme	5
3	Tehnički podaci manipulatora LBR iiwa 7 R800	6
4	Granični momenti zglobova manipulatora	6
5	Značajke prihvatnice	7
6	Geometrija i inercijska svojstva modela vrata	8
7	Rasponi randomizacije otpora vrata	9
8	Programska i sklopovska konfiguracija	13
9	Paketi radnog prostora ROS 2	13

POPIS OZNAKA

Oznaka	Jedinica	Opis
$\mathbb{R}$		Skup realnih brojeva
$\mathbf{q}$	rad	Vektor poopćenih koordinata (zglobne varijable)
$\boldsymbol{\tau}$	N m	Vektor momenata u zglobovima
q	rad, m	Koordinata stupnja slobode vrata (kut zakreta ili pomak krila)
$\dot{q}$	rad/s, m/s	Brzina stupnja slobode vrata
τ_{tr}	N m, N	Coulombovo trenje u zglobu vrata
d	Nms/rad, Ns/m	Koeficijent viskoznog prigušenja zgloba vrata
$\mathbf{J}$		Jakobijan manipulatora
$\mathbf{F}$	N	Vektor sile na vrhu alata
$\mathbf{w}$		Vektor sila i momenata (engl. <i>wrench</i>)
$\mathbf{K}_p$	N/m	Matrica krutosti regulatora
$\mathbf{K}_d$	Ns/m	Matrica prigušenja regulatora
$\mathbf{x}$		Vektor stanja
$\mathbf{a}$		Vektor akcije
r		Nagrada
γ		Diskontni faktor
π		Politika upravljanja
$(\cdot)^\top$		Transponiranje matrice ili vektora
$\ \cdot\ $		Norma vektora

POPIS KRATICA

Kratika	Opis
DOF	Stupanj slobode gibanja (engl. <i>degree of freedom</i>)
F/T	Sila i moment (engl. <i>force/torque</i>)
IK	Inverzna kinematika
KMR	KUKA Mobile Robotics
LBR	Lagani robot (njem. <i>Leichtbauroboter</i>)
MDP	Markovljev proces odlučivanja (engl. <i>Markov decision process</i>)
MPC	Prediktivno upravljanje temeljeno na modelu (engl. <i>model predictive control</i>)
ONNX	Otvoreni format za razmjenu neuronskih mreža (engl. <i>Open Neural Network Exchange</i>)
OSC	Upravljanje u operacijskom prostoru (engl. <i>operational space control</i>)
PhysX	Fizikalni pogon simulatora
PPO	Proksimalna optimizacija politike (engl. <i>proximal policy optimization</i>)
RL	Podržano učenje (engl. <i>reinforcement learning</i>)
ROS	Robotski operacijski sustav (engl. <i>Robot Operating System</i>)
TCP	Vrh alata (engl. <i>tool center point</i>)
TF	Transformacijsko stablo koordinatnih sustava
URDF	Objedinjeni opis robota (engl. <i>Unified Robot Description Format</i>)
USD	Univerzalni opis scene (engl. <i>Universal Scene Description</i>)

SAŽETAK

TODO: piše se ZADNJE, kad su rezultati poznati. Struktura (4–6 rečenica): problem → pristup → što je implementirano → što je izmjereno → glavni nalaz.

KLJUČNE RIJEČI: mobilni manipulator, fizička interakcija, procjena svojstava okoline, impedancijsko upravljanje, podržano učenje, simulacija.

SUMMARY

TODO: prijevod sažetka na engleski (obavezan bez obzira na jezik rada).

Key words: mobile manipulator, physical interaction, environment property estimation, impedance control, reinforcement learning, simulation.

1. UVOD

TODO: piše se PRETPOSLJEDNJE (prije zaključka), kad su rezultati poznati.

1.1. Motivacija

Industrijska robotika od svog početka počiva na pretpostavci strukturirane okoline. Robot je ograden zaštitnom ogradom, radni komadi nalaze se na predodređenom mjestu, a zadatak se svodi na ponavljanje prethodno naučene i isprogramirane radnje. U takvim uvjetima pozicijsko upravljanje visoke krutosti daje izvrsne rezultate, robot vrlo ponovljivo i bez većih odstupanja slijedi zadanu putanju bez obzira na smetnje.

Ta se pretpostavka ruši čim robot izađe iz kaveza. Industrijska okruženja puna su ljudi koji istovremeno obavljaju svoje poslove, servise, logističke zadatke i okolnosti koje se mijenjaju između dva izvođenja istog zadatka. Odgovor na takve probleme su mobilni manipulatori - sustavi koji integriraju svestranost mobilne platforme s artikuliranošću robotske ruke i time uklanjaju ograničenje dosega koje veže nepokretni manipulator za jedno radno mjesto.

Najčešća primjena industrijskih robota je za tzv. *pick-and-place* radnje, ali postoji i veliki broj operacija za koje je potrebna uspostava i održavanje fizičkog kontakta, primjerice otvaranje vrata i ladica, umetanje predmeta, posluživanje stroja ili pomicanje objekata. Postojanje kontakta uvelike mijenja problem upravljanja. Dok se robot giba u slobodnom prostoru, greška položaja je relativno mala i nema brige da će robot oštetiti okolinu. U kontaktu s krutom okolinom ista greška položaja proizvodi silu koja raste s krutošću regulatora i može oštetiti predmet, okolinu ili samog robota. Zbog toga upravljanje u kontaktu ne može biti čisto pozicijsko, već mora regulirati odnos između položaja i sile [1].

Otvaranje vrata reprezentativan je predstavnik te klase zadataka i zbog toga se u literaturi često koristi kao referentni problem [2]. Vrata su artikulirani objekt čije je gibanje ograničeno na jedan stupanj slobode, ali robot taj stupanj slobode ne poznaje unaprijed. Drugim riječima, robot ne zna gdje je os šarke, u kojem smjeru se krilo otvara ili koliki je otpor u zglobu. Sve to mora zaključiti iz vlastitih mjerenja tijekom interakcije [3]. Uz to, hod krila redovito premašuje doseg ruke pri nepomičnoj bazi, pa zadatak traži i koordinaciju platforme i manipulatora. Zadatak time istovremeno obuhvaća percepciju, procjenu svojstava okoline i upravljanje u kontaktu, što ga čini prikladnim ispitnim slučajem za cjelovit sustav.

Postoje dva prevladavajuća pristupa takvim zadacima. Klasični pristup temeljen na modelu oslanja se na eksplicitan opis zadatka: procijeni se geometrija ograničenja, iz nje se

generira referentna putanja, a impedancijski ili hibridni silno-pozicijski regulator izvodi gibanje uz propisanu popustljivost [4]. Prednost je razumljivost i predvidljivost, svaki je korak moguće analizirati i obrazložiti. Slabost je osjetljivost na kvalitetu procjene: pogreška u procijenjenoj geometriji ograničenja izravno se pretvara u kontaktnu silu. Pristup temeljen na učenju ne zahtijeva eksplicitan model, već strategiju upravljanja stječe kroz interakciju sa simuliranom okolinom. Novije formulacije akcijskim prostorom politike čine samu krutost regulatora, pa politika uči ne samo kamo se gibati nego i koliko biti popustljiva u pojedinom trenutku [5]. Cijena je gubitak uvida u razloge odluke i ovisnost o vjernosti simulacije.

Usporedba tih dvaju pristupa ima smisla samo ako se provodi na istom zadatku, istom robotu i istoj fizici okoline. Ovaj rad zato oba pristupa razvija za isti sustav (mobilni manipulator KUKA KMR iiwa u simulacijskom okruženju), i uspoređuje ih na istim mjerilima uspješnosti.

1.2. Struktura rada

Poglavlje 2. daje pregled dosadašnjih istraživanja, od klasičnih zakona upravljanja u kontaktu preko procjene kinematičkih modela artikuliranih objekata do novijih pristupa temeljenih na podržanom učenju. Poglavlje 3. opisuje robotski sustav i simulacijsko okruženje: mobilni manipulator KMR iiwa, prihvatnicu izrađenu za ovaj zadatak, modele vrata te programsku arhitekturu koja povezuje simulator i upravljački kod.

Poglavlja 4. i 5. obrađuju ulazne module sustava. Prvo opisuje određivanje položaja i orijentacije kvake iz slike, a drugo procjenu sile i momenta na vrhu alata te postupak kojim sustav iz izmjerenog odziva zaključuje o ograničenju gibanja i krutosti okoline.

Poglavlja 6. i 7. predstavljaju dva uspoređivana pristupa upravljanju. Prvo opisuje rješenje temeljeno na modelu, organizirano kao slijed faza s eksplicitnom procjenom geometrije ograničenja. Drugo opisuje formulaciju zadatka kao Markovljevog procesa odlučivanja, prostor stanja i akcija s promjenjivom impedancijom, oblikovanje funkcije nagrade i postupak učenja.

Poglavlje 8. donosi eksperimentalne rezultate, ablacijske studije i usporedbu dvaju pristupa na istoj fizici okoline, uz raspravu o ograničenjima provedene usporedbe.

Poglavlje 9. sažima postignuto i navodi smjernice za daljnji rad.

2. PREGLED DOSADAŠNJIH ISTRAŽIVANJA

2.1. Klasični pristupi upravljanju u kontaktu

TODO: impedancijsko upravljanje, hibridno silno-pozicijsko upravljanje [1], upravljanje u operacijskom prostoru [4].

2.2. Mobilna manipulacija

TODO: perceptivni MPC [6], ograničenja whole-body pristupa.

2.3. Interakcija s artikuliranim objektima

TODO: procjena kinematičkih modela [3].

2.4. Pristupi temeljeni na učenju

TODO: varijabilna impedancija kao akcijski prostor [5], navigacija za mobilnu manipulaciju [7].

3. ROBOTSKI SUSTAV I SIMULACIJSKO OKRUŽENJE

Ovo poglavlje opisuje robotski sustav na kojem su razvijena i ispitana oba pristupa upravljanju, modele vrata koji čine radnu okolinu, postupak izrade simulacijskog modela te programsku arhitekturu koja povezuje simulator i upravljački kod. Cijeli je rad proveden u simulaciji; razlozi i posljedice tog izbora navedeni su u potpoglavlju 3.5..

3.1. KMR iiwa — mobilna platforma i manipulator

KUKA KMR iiwa mobilni je manipulator sastavljen od dviju serijskih komponenti: omnidirekcijske mobilne platforme KMP 200 omniMove i laganog robota LBR iiwa. Na prirubnicu manipulatora dodana je prihvatačica opisana u potpoglavlju 3.2.. Kombinacija pokretljive platforme i osjetljivog manipulatora namijenjena je radu bez zaštitne ograde, u okolini u kojoj se robot kreće između radnih mjesta [8].



Slika 1. Mobilni manipulator KMR iiwa u simulacijskom okruženju

3.1.1. Mobilna platforma

Platforma se giba pomoću četiriju Mecanum kotača. Svaki se kotač sastoji od niza valjaka postavljenih pod kutom od 45° u odnosu na os kotača, čime se postiže omnidirekcijsko gibanje — platforma se može gibati u proizvoljnom smjeru u ravnini i istovremeno se

zakretati, bez potrebe za promjenom orijentacije prije translacije. Ta je osobina bitna za zadatak otvaranja vrata, jer omogućuje da baza slijedi luk krila bez manevriranja.



Slika 2. Građa Mecanum kotača [9]

Tablica 2. Tehnički podaci mobilne platforme

Veličina	Vrijednost
Dimenzije ($V \times \check{S} \times D$)	$700 \times 1080 \times 630$ mm
Masa	390 kg
Najveća nosivost	170 kg (200 kg bez manipulatora)
Brzina u uzdužnom smjeru	najviše 3,6 km/h
Brzina u poprečnom smjeru	najviše 2,0 km/h
Promjer kotača	250 mm
Klasa čistoće	ISO 5

3.1.2. Manipulator LBR iiwa 7 R800

Korišten je manipulator LBR iiwa 7 R800, redundantna kinematička struktura sa sedam rotacijskih osi. Za ovaj je rad ključno da manipulator ima senzor momenta u svakoj osi, što omogućuje procjenu sile i momenta na vrhu alata bez zasebnog senzora sile na zapešću. Postupak te procjene opisan je u poglavlju 5.. Sedma os čini strukturu redundantnom u odnosu na šest stupnjeva slobode zadatka, pa isti položaj i orijentaciju vrha alata ostvaruje kontinuum konfiguracija - svojstvo koje se u poglavlju 8. pokazalo dosta važnim.

Tablica 3. Tehnički podaci manipulatora LBR iiwa 7 R800

Veličina	Vrijednost
Nazivna nosivost	7 kg
Broj osi	7
Doseg	800 mm
Izvedba zapešća	u liniji
Prirubnica na osi 7	DIN ISO 9409-1-A50
Ponovljivost pozicioniranja	$\pm 0,1$ mm
Točnost momenta po osi	± 2 %
Masa	23,9 kg
Stupanj zaštite	IP54
Položaj ugradnje	pod, strop, zid

Granični momenti pojedinih zglobova navedeni su u tablici 4.

Tablica 4. Granični momenti zglobova manipulatora


Zglob	1	2	3	4	5	6	7
Granični moment, Nm	176	176	110	110	110	40	40

3.2. Prihvatnica


Za hvatanje kvake izrađena je prilagođena prihvatnica. Budući da se rad provodi isključivo u simulaciji, a stvarni prihvatni uređaj nije bio zadan, prihvatnica je oblikovana kao zamjenjiva komponenta, tj. upravljanje njome potpuno je odvojeno od ostatka softvera (potpoglavlje 3.6.), pa se može zamijeniti bez izmjena u ostatku sustava.

Prihvatnica ima četiri prsta raspoređena u dva para koja se zatvaraju duž osi x baze, dok uhvaćena šipka leži duž osi y . Svaki prst na sebi ima utor čiji je unutarnji luk prilagođen šipki kvake promjera 28 mm. Pri potpuno zatvorenom hvatu otvor između prstiju uži je od šipke, pa хват ne počiva na geometrijskom dosjedanju nego na sili pogona i popustljivosti prstiju. Time se izbjegava zazor koji bi pri vučenju vrata dopustio da se kvaka pomiče unutar hvata.

Parovi prstiju ne gibaju se savršeno simetrično, pa se predmet ne centririra sam od sebe. Ta se asimetrija ne pokušava ukloniti, nego se mjeri: tijekom prilaza kvaki uspoređuju se položaji suprotnih prstiju i iz razlike se izračunava bočna korekcija kojom se prihvatnica poravna nad kvakom prije nego što se хват zatvori. Postupak je opisan u potpoglavlju 6.2..



Slika 3. Prihvatnica s četiri prsta; otvorena (lijevo) i zatvorena (desno)



Slika 4. Položaj vrha alata

Tablica 5. Značajke prihvatnice

Značajka	Vrijednost
Promjer prirubnice	63 mm
Dimenzije nosive ploče	85 × 85 mm
Duljina prsta	66,5 mm
Unutarnji polumjer utora	16 mm
Hod po prstu	0–25 mm
Masa nosivog dijela	442 g
Masa prsta	30,6 g
Ukupna masa	564 g
Položaj vrha alata iznad prirubnice	74,85 mm
Statički koeficijent trenja prstiju	1,2
Dinamički koeficijent trenja prstiju	1,0

Vrh alata leži na osi alata, na visini od 74,85 mm iznad prirubnice manipulatora. Ta visina odgovara središtu unutarnjeg luka kuka pri zatvorenom hvatu, dakle visini na kojoj se nalazi os uhvaćene šipke. Vrh alata time nije materijalna točka na prihvati, nego sjecište osi alata i osi predmeta u hvatu, čime regulator momente računa oko stvarnog hvatišta.

Prsti su u simulacijskom modelu upravljani pozicijski, s krutošću pogona 20 000 N/m, prigušenjem 200 Ns/m i graničnom silom 600 N. Pri vučenju vrata silu prenose djelotvorno samo dva od četiriju prstiju, jer jedan par radi protiv vlastitog pogona, pa je djelotvorna krutost hvata polovica nominalne. Ta je pojedinost bitna za tumačenje rezultata u poglavlju 8..

3.3. Modeli vrata

Radnu okolinu čine dva modela vrata, zakretna i klizna. Oba su izgrađena od osnovnih geometrijskih tijela, s istim krilom, a razlikuju se stupnjem slobode gibanja i oblikom kvake. Zajednička geometrija je namjerna: razlika u ponašanju dvaju pristupa time se ne može pripisati razlici u dimenzijama ili masi krila.

Slika 5. Modeli zakretnih i kliznih vrata s označenim stupnjem slobode gibanja

Tablica 6. Geometrija i inercijska svojstva modela vrata

Veličina	Zakretna vrata	Klizna vrata
Krilo, dimenzije	$40 \times 850 \times 2000$ mm	$40 \times 850 \times 2000$ mm
Krilo, masa	15 kg	15 kg
Nepomični dio	stup $60 \times 60 \times 2000$ mm	vodilica $60 \times 2000 \times 60$ mm
Stupanj slobode	rotacija oko osi z	translacija duž osi y
Raspon gibanja	0–1,57 rad	0–0,8 m
Kvaka, oblik	poluga, duljina 160 mm	šipka, duljina 250 mm
Kvaka, promjer šipke	28 mm	28 mm
Kvaka, masa	0,35 kg	0,35 kg
Visina hvatišta	1000 mm	1000 mm

Kod zakretnih vrata kvaka je izvedena kao poluga usmjerena prema osi šarke, kako je uobičajeno kod stvarnih vrata. Zglob brave, koji bi omogućio zakretanje kvake, **zavaren je u nepomični zglob u oba pristupa**, pa je jedini pokretni stupanj slobode zakretnih vrata os šarke. Okretanje kvake time je izvan opsega rada; razlog i posljedice te odluke navedeni su u potpoglavlju 6.4.. Posljedica koju treba imati na umu jest da se cijeli moment šarke prenosi trenjem prstiju na šipki kvake.

Kod kliznih vrata kvaka je okomita šipka pričvršćena dvama odstojećima, pa je hvatište dostupno s prednje strane krila po cijeloj visini šipke.

3.3.1. Otpor gibanja i njegova randomizacija

Otpor vrata nije zapisan u geometrijskom modelu, nego se postavlja pri svakom pokretanju epizode iz zadanog raspona. Time politika nije vezana uz jednu vrijednost otpora, nego uči raditi na rasponu vrata. Otpor je razdvojen na tri fizikalno različita člana:

$$\tau_{\text{otpor}} = \tau_{\text{tr}} + d\dot{q}, \quad (1)$$

gdje je q koordinata jedinog stupnja slobode vrata, dakle kut zakreta krila kod zakretnih odnosno pomak krila kod kliznih vrata, a $\dot{q}$ njegova derivacija po vremenu, to jest brzina otvaranja. Član τ_{tr} Coulombovo je trenje, konstantno po iznosu i neovisno o brzini, dok je d koeficijent viskoznog prigušenja, koji daje otpor razmjern brzini. Izraz je zapisan općenito za oba tipa vrata: kod zakretnih su τ_{otpor} i τ_{tr} momenti, a kod kliznih sile.

Parametri se zadaju u apsolutnim jedinicama, dakle u njutnima za prizmatični i njutnmetrima za revolutni zglobov, a ne kao bezdimenzijski koeficijenti. Da bi se to potvrdilo, provedeno je mjerenje u simulaciji. Vratima je zadana poznata vrijednost trenja, a zatim je polagano rastućom silom određena sila pri kojoj se vrata pokrenu. Omjer izmjerene sile pokretanja i zadanog trenja kretao se između 1,00 i 1,03 za zadane vrijednosti trenja u rasponu od 5 do 60 N, čime je potvrđeno da zadana vrijednost izravno odgovara sili potrebnoj za pokretanje vrata.

Tablica 7. Rasponi randomizacije otpora vrata

Tip vrata	Trenje	Prigušenje
Klizna	5–60 N	5–50 Ns/m
Zakretna	0,5–5 Nm	0,5–5 Nms/rad

Rasponi nisu određeni mjerenjem na stvarnim vratima, nego su usvojeni kao inženjerska procjena, sa širinom raspona odabranom tako da obuhvati i lagana i teška vrata. Svrha im nije vjerno preslikati određena vrata, nego spriječiti da naučena politika ovisi o jednoj vrijednosti otpora. Kod zakretnih vrata otpor potječe isključivo od trenja u šarki.

3.4. Model robota i pretvorba u simulacijski format

Geometrijski i kinematički model robota opisan je u formatu *Unified Robot Description Format* (URDF). Model manipulatora preuzet je iz javno dostupnog paketa `iiwa_stack` [10], a model mobilne platforme iz proizvođačeve dokumentacije [8]. Prihvatnica, nosač

kamere i oba modela vrata izrađeni su u sklopu ovog rada. Model je organiziran pomoću `xacro` predložaka, tako da se prihvatnica u model uključuje jednim pozivom makronaredbe.

Isaac Sim ne koristi URDF izravno, nego format *Universal Scene Description* (USD). Pretvorba nije jedan korak nego niz skripti, jer sama pretvorba ne prenosi sve što je za rad potrebno.


Osnovnu pretvorbu obavlja `convert_urdf_usd.py`, proširena inačica alata iz Isaac Laba. Dvije su postavke pritom bitne:

- **Vrsta kolidera** (engl. *collider type*). Prsti prihvatnice moraju se pretvarati postupkom konveksne dekompozicije. Zamotavanje u konveksnu ovojnici zatvorilo bi utore na prstima i prihvatnica ne bi mogla obuhvatiti šipku.
- **Sažimanje nepomičnih zglobova**. Ne smije se primijeniti na model robota, jer bi uklonilo zglob na kojem se očitavaju sile i momenti (potpoglavlje 3.2.).

Na dobiveni model zatim se primjenjuju tri naknadne skripte:

- `apply_gripper_friction.py` pridružuje materijal trenja plohama prstiju i kvaka. Pridruživanje se ne može izvesti izravno na složenoj sceni, jer se geometrija prsta, referencirana četiri puta iz iste datoteke, pojavljuje kao instancirani sloj u koji nije dopušteno upisivati; skripta zato pronalazi stvarni sloj u kojemu se geometrija nalazi i materijal upisuje u njega.
- `add_arm_ros_control_graph.py` umeće graf koji povezuje zglobove manipulatora s temama ROS-a 2, čime se model može voditi izvana. Graf mora biti ugniježđen unutar stabla osnovnog elementa modela, jer se inače pri referenciranju modela u scenu tiho izgubi.
- `add_camera_ros.py` dodaje kameru s izmjerenim unutarnjim parametrima i položajem te objavljuje sliku i stabla koordinatnih sustava.

Pojačanja pogona iz pretvorbe se ne zadržavaju, nego se postavljaju u konfiguraciji okruženja (potpoglavlje 3.5.).



Slika 6. Postupak izrade simulacijskog modela iz opisa robota i vrata

Za učenje se koristi zasebna inačica modela. Iz modela vrata uklonjeni su nosivi elementi oznaka za percepciju, jer tijela mase 0,001 kg uz krilo mase 15 kg loše uvjetuju numerički postupak rješavanja. Nazivi članaka i zglobova ujednačeni su između obaju tipova vrata, čime jedna programska implementacija okruženja posluži oba tipa bez grananja po tipu vrata.

3.4.1. Gibanje mobilne platforme

Mecanum kotači nisu simulirani kao tijela u kontaktu s podlogom. Umjesto toga, gibanje platforme zadaje se kinematički: naredba brzine iz poruke `/cmd_vel` pretvara se u pomake platforme po osima x i y te zakret oko osi z . U okruženju za učenje isti je mehanizam ostvaren trima pomoćnim zglobovima umetnutima između nepomičnog ishodišta i članka platforme, pa se platforma giba kao dio iste kinematičke strukture kao i manipulator.

Korijen kinematičke strukture pritom ostaje nepomičan. To je nužno jer regulator u operacijskom prostoru, opisan u poglavlju 7., računa jakobijan i matricu inercije uz pretpostavku nepomičnog korijena; uz slobodan korijen kompenzacija gravitacije ispada neispravna.

Zanemarivanje dinamike kotača pojednostavljenje je koje uklanja proklizavanje, elastičnost valjaka i ograničenja pogona kotača. Za zadatak u kojem se platforma giba malim brzinama i u kojem su zanimljive sile na vrhu alata, a ne na kotačima, to je prihvatljivo, ali ograničava prenosivost rezultata na stvarnog robota. Ograničenje je navedeno u poglavlju 9..

3.5. Simulacijsko okruženje

Simulacija se izvodi u okruženju NVIDIA Isaac Sim, uz biblioteku Isaac Lab [11] za paralelno učenje. Fizika se rješava pogonom PhysX. Cijeli je rad proveden u simulaciji jer stvarni robot nije bio dostupan, a zadatak zahtijeva velik broj ponavljanja interakcije s kontaktom, što na stvarnom robotu nije izvedivo u opsegu završnog rada.

Bitna je značajka postava razdvajanje odgovornosti: geometrijski model nosi topologiju i geometriju, a sva pojačanja pogona i svojstva otpora zadaju se u konfiguraciji okruženja. Time se izbjegava da se naučena politika veže uz jednu konkretnu datoteku modela umjesto uz raspon uvjeta.

Pogoni osi manipulatora postavljeni su na nultu krutost i prigušenje. Momente računa regulator u operacijskom prostoru i zadaje ih izravno; da je zadržana krutost iz pretvorbe, pogon i regulator djelovali bi jedan protiv drugoga i krutost koju politika zada ne bi imala učinka. Pogon platforme brzinski je, s prigušenjem 10^4 , a pogon prstiju pozicijski, s vrijednostima navedenima u potpoglavlju 3.2..

Tablica 8. Programska i sklopovska konfiguracija

Komponenta	Inačica
Operacijski sustav	Ubuntu 22.04 LTS
Simulator	NVIDIA Isaac Sim 5.1.0
Biblioteka za učenje	Isaac Lab 2.3.2
Robotski operacijski sustav	ROS 2 Humble
Python (Isaac Lab)	3.11.15
Python (ROS 2)	3.10.12
Procesor	AMD Ryzen 7 260
Grafička kartica	NVIDIA GeForce RTX 5050, 8 GB VRAM
Radna memorija	32 GB DDR5


3.6. Programska arhitektura

Programska podrška podijeljena je u pakete unutar radnog prostora ROS 2, navedene u tablici 9. Podjela slijedi funkcionalne cjeline rada: opis robota, percepcija, veza sa simulatorom, izvođenje zadatka i pokretanje sustava.

Tablica 9. Paketi radnog prostora ROS 2


Paket	Sadržaj
<code>kmr_iiwa_description</code>	modeli robota, prihvatnice, kamere i vrata
<code>kmr_iiwa_perception</code>	detekcija oznaka, fuzija poze, procjena sile i momenta
<code>kmr_iiwa_sim_bridge</code>	veza sa simulatorom: platforma, prihvatnica, kamera
<code>kmr_iiwa_task</code>	izvođenje zadatka i procjena ograničenja gibanja
<code>kmr_iiwa_moveit_config</code>	konfiguracija planiranja gibanja manipulatora
<code>kmr_iiwa_bringup</code>	pokretanje cjelokupnog sustava

Isaac Sim nema izvornu podršku za sučelje `ros2_control`, pa je veza sa simulatorom ostvarena vlastito izrađenim čvorovima koji prevode poruke ROS 2 u naredbe simulatoru. Upravljanje prihvatnicom namjerno je izvedeno kao potpuno odvojena cjelina: jedini čvor koji zna da prihvatnica ima četiri prizmatična zgloba i hod od 25 mm jest njezin upravljački čvor, dok ostatak sustava prihvatnicu vidi kroz jedan broj u rasponu od nula do jedan, uz povratnu informaciju o trenutnom položaju i o tome je li zaustavljena prije dolaska u zadani položaj. Time je zadovoljen zahtjev iz potpoglavlja 3.2. da se prihvatnica može zamijeniti bez izmjena u ostatku sustava.



Slika 7. Programska arhitektura klasičnog pristupa

Pristup temeljen na učenju koristi bitno jednostavniju arhitekturu. Tijekom učenja ROS 2 nije u regulacijskoj petlji: okruženje, regulator i politika izvode se unutar Isaac Laba, izravno nad tenzorima na grafičkoj kartici. Razlog je paralelizacija - učenje se izvodi u više stotina istovremenih okruženja, a posredovanje kroz ROS 2 bilo bi usko grlo. Veza s ROS-om potrebna je tek pri izvođenju naučene politike izvan simulacije, što nije bilo u opsegu ovog rada i opisano je u poglavlju 8..



Slika 8. Programska arhitektura pristupa temeljenog na učenju

4. MODUL PERCEPCIJE

Izvor: `perception_module_handoff_DONE.md`.

4.1. Senzorski postav

TODO: RealSense D435, nosač, položaj na robotu.

4.2. Detekcija i procjena poze

TODO: AprilTag [12], postupak, konvencija koordinatnih sustava.

4.3. Sučelje modula

TODO: `/perception/handle_pose`, TF stablo, frekvencija, točnost.

4.4. Ograničenja pristupa

TODO: eksplicitno napisati da je uporaba markera pojednostavljujuća pretpostavka i što bi bila alternativa (detekcija bez markera).

5. PROCJENA SVOJSTAVA OKOLINE

5.1. Procjena sile i momenta na vrhu alata

TODO: iz momenata u zglobovima preko $\mathbf{J}^T$, kalibracija, filtriranje.

5.2. Procjena ograničenja gibanja

TODO: prilagodba kružnice (zakretna vrata) odnosno pravca (klizna vrata) na izmjerenu putanju, kriterij odabira modela.

5.3. Ispitno gibanje za utvrđivanje stanja brave

TODO: faza probanja, prag sile, odluka.

6. KLASIČNI PRISTUP UPRAVLJANJU

6.1. Struktura zadatka

TODO: prilaz → hvat → procjena → otvaranje; konačni automat, uvjeti prijelaza.

6.2. Upravljanje u fazi prilaza i hvata

TODO.

6.3. Upravljanje u fazi otvaranja

TODO: vođenje po procijenjenoj kružnici/pravcu, popustljivost ruke, koordinacija baze.

6.4. Ograničenja

TODO: brava je zavarena u obje scene (kvaka se ne okreće) — svjesno pojednostavljenje opsega, primijenjeno jednako na oba pristupa.

7. PRISTUP TEMELJEN NA UČENJU

7.1. Formulacija Markovljevog procesa odlučivanja

7.1.1. *Prostor stanja*

TODO.

7.1.2. *Prostor akcija*

TODO: varijabilna impedancija u operacijskom prostoru [5].

7.1.3. *Funkcija nagrade*

TODO: komponente nagrade, težine.

7.2. Postupak učenja

TODO: algoritam, hiperparametri, broj okruženja, trajanje.

7.3. Ablacijske studije

TODO: koje su varijante uspoređene i zašto.

8. EKSPERIMENTALNI REZULTATI I RASPRAVA

8.1. Metrike i eksperimentalni protokol

TODO: napredak, stopa uspješnosti, vrijeme izvršavanja, maksimalna sila kontakta.

8.2. Rezultati klasičnog pristupa

TODO.

8.3. Rezultati pristupa temeljenog na učenju

TODO: ablacijska tablica.

8.4. Usporedba pristupa

TODO: usporedba na oba tipa vrata. Uz tablicu obavezno napisati konceptualnu razliku: klasični pristup *zna* os šarke iz markera, naučena politika je mora otkriti iz sile i pomaka — to nisu isti ulazi u problem.

8.5. Rasprava

TODO: središnji nalaz i njegovo tumačenje.

9. ZAKLJUČAK

TODO: piše se ZADNJE. Što je postignuto, koja su ograničenja, smjernice za daljnji rad (zid s kriterijem otvora, sinkronizirano gibanje baze i ruke, okretanje kvake).

LITERATURA

- [1] Marc H. Raibert and John J. Craig. Hybrid position/force control of manipulators. *Journal of Dynamic Systems, Measurement, and Control*, 103(2):126–133, 1981.
- [2] Christian Ott, Berthold Bäuml, Christoph Borst, and Gerd Hirzinger. Employing cartesian impedance control for the opening of a door: A case study in mobile manipulation. In *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), Workshop on Mobile Manipulators*, 2005.
- [3] Jürgen Sturm, Cyrill Stachniss, and Wolfram Burgard. A probabilistic framework for learning kinematic models of articulated objects. *Journal of Artificial Intelligence Research*, 41:477–526, 2011.
- [4] Oussama Khatib. A unified approach for motion and force control of robot manipulators: The operational space formulation. *IEEE Journal of Robotics and Automation*, 3(1):43–53, 1987.
- [5] Roberto Martín-Martín, Michelle A. Lee, Rachel Gardner, Silvio Savarese, Jeannette Bohg, and Animesh Garg. Variable impedance control in end-effector space: An action space for reinforcement learning in contact-rich tasks. In *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 1010–1017, 2019.
- [6] Johannes Pankert and Marco Hutter. Perceptive model predictive control for continuous mobile manipulation. *IEEE Robotics and Automation Letters*, 5(4):6177–6184, 2020.
- [7] Daniel Honerkamp, Tim Welschhold, and Abhinav Valada. N²M²: Learning navigation for arbitrary mobile manipulation motions in unseen and dynamic environments. *IEEE Transactions on Robotics*, 2023.
- [8] KUKA Deutschland GmbH. KMR iiwa — always spot-on safely. Katalog proizvoda, PBJ Portfolio (EN) 05/2024, 2024. <https://www.kuka.com>.
- [9] RobotShop. Andymark bb mecanum wheel. <https://www.robotshop.com/products/andymark-4in-bb-mecanum-wheel-05in-hex-bore-right>. pristupljeno: 07.09.2026.
- [10] Christoph Hennersperger, Salvatore Virga, et al. iiwa_stack: ROS integration for KUKA LBR IIWA robots. https://github.com/IFL-CAMP/iiwa_stack. Technische Universität München, IFL-CAMP.

- [11] NVIDIA. Isaac Lab: A unified framework for robot learning. <https://isaac-sim.github.io/IsaacLab/>, 2024.
- [12] Edwin Olson. AprilTag: A robust and flexible visual fiducial system. In *IEEE International Conference on Robotics and Automation (ICRA)*, pages 3400–3407, 2011.