

SVEUČILIŠTE U ZAGREBU
FAKULTET STROJARSTVA I BRODOGRADNJE

ZAVRŠNI RAD

David Mihić

ZAGREB, 2026.

SVEUČILIŠTE U ZAGREBU

FAKULTET STROJARSTVA I BRODOGRADNJE

ZAVRŠNI RAD

Mentor:

Student:

Doc. dr. sc. Bojan Šekoranja,
mag.ing.

David Mihić

ZAGREB, 2026.

Izjavljujem da sam ovaj rad izradio samostalno koristeći znanja stečena tijekom studija i navedenu literaturu.

Zahvaljujem se mentoru, doc. dr. sc. Bojanu Šekoranji na pomoći i prijedlozima, kao i kolegi Branimiru Čaranu na iznimnoj pomoći i podršci ne samo tijekom pisanja ovog rada, nego i tijekom studiranja.

Posebno hvala mojim roditeljima i sestri, kao i mojoj curi Eli na beskonačnom strpljenju i podršci tijekom godina studiranja. Hvala svim prijateljima i svima ostalima koji su me poticali i pomagali.

Također sam vrlo zahvalan kolegama i osoblju iz laboratorija CRTA na svim prilikama koje su mi pružili tijekom zadnjih godina.

David Mihić

Sveučilište u Zagrebu Fakultet strojarstva i brodogradnje	
Datum	Prilog
Klasa: 602-01/26-01/3	
Ur.broj: 15-31000-26-	

ZAVRŠNI ZADATAK

Student: David Mihić

JMBAG: 0035250443

Naslov rada na hrvatskom jeziku: **Razvoj i evaluacija metode upravljanja mobilnim manipulatorom u interakciji s okolinom**Naslov rada na engleskom jeziku: **Development and evaluation of a control method for a mobile manipulator in interaction with the environment**

Opis zadatka:

U ovom radu razmatra se problem autonomne interakcije mobilnog manipulatora s okolinom kroz zadatke koji uključuju uspostavu i održavanje kontakta s objektima te izvođenje koordiniranih manipulacijskih radnji. Naglasak je na integraciji percepcije, procjene stanja i upravljanja u jedinstveni sustav sposoban za izvršavanje višefaznih zadataka u nepoznatim ili djelomično poznatim uvjetima.

Cilj rada je razviti i eksperimentalno evaluirati metodologiju upravljanja koja omogućuje robotu donošenje odluka i generiranje gibanja na temelju više senzorskih podataka, uzimajući u obzir mehanička svojstva okoline i interakcijske sile.

U radu je potrebno:

- istražiti postojeće pristupe upravljanju mobilnim manipulatorima u zadacima koji uključuju fizičku interakciju s objektima
- razviti modul percepcije za detekciju relevantnih objekata te procjenu njihove pozicije i orijentacije korištenjem dostupnih senzora
- implementirati postupak procjene svojstava okoline (npr. krutost, ograničenja gibanja) na temelju mjerenja sile i momenta tijekom interakcije
- modelirati i implementirati dva različita pristupa upravljanju sustavom (klasični pristup temeljen na modelu i pristup temeljen na učenju)
- definirati i implementirati odgovarajuću reprezentaciju stanja, akcija i kriterija uspješnosti za odabrani pristup učenja
- analizirati i usporediti performanse implementiranih metoda s obzirom na učinkovitost i robusnost sustava

U radu je potrebno navesti korištenu literaturu i eventualno dobivenu pomoć.

Zadatak zadan:

22. 4. 2026.

Zadatak zadao:

doc. dr. sc. Bojan Šekoranja

Datum predaje rada:

2. rok: 15. i 16. 7. 2026.

3. rok: 16. i 17. 9. 2026.

Predviđeni datumi obrane:

2. rok: 21. - 23. 7. 2026.

3. rok: 22. - 24. 9. 2026.

Predsjednik Povjerenstva:

izv. prof. dr. sc. Petar Čurković

SADRŽAJ

SADRŽAJ	i
POPIS SLIKA	iv
POPIS TABLICA	v
POPIS OZNAKA	vi
POPIS KRATICA	viii
SAŽETAK	ix
SUMMARY	x
1. UVOD	1
1.1. Motivacija	1
1.2. Cilj i doprinos rada	2
1.3. Struktura rada	3
2. PREGLED DOSADAŠNJIH ISTRAŽIVANJA	4
2.1. Klasični pristupi upravljanju u kontaktu	4
2.2. Mobilna manipulacija	5
2.3. Interakcija s artikuliranim objektima	5
2.4. Pristupi temeljeni na učenju	6
2.5. Položaj ovog rada	6
3. ROBOTSKI SUSTAV I SIMULACIJSKO OKRUŽENJE	7
3.1. KMR iiwa — mobilna platforma i manipulator	7
3.1.1. Mobilna platforma	7
3.1.2. Manipulator LBR iiwa 7 R800	8
3.2. Prihvatnica	9
3.3. Kamera i njezin nosač	11
3.4. Lidar	12
3.5. Modeli vrata	12
3.5.1. Otpor gibanja i njegova randomizacija	14
3.6. Model robota i pretvorba u simulacijski format	15

3.6.1.	Gibanje mobilne platforme	17
3.7.	Simulacijsko okruženje	17
3.8.	Programska arhitektura	18
4.	MODUL PERCEPCIJE	21
4.1.	Odabir pristupa	21
4.2.	Raspored oznaka	21
4.3.	Detekcija oznaka	23
4.4.	Fuzija dviju oznaka na kvaki	23
4.5.	Sučelje modula i radni doseg	24
4.6.	Preciznost percepcijskog modula	24
4.7.	Ograničenja	25
5.	PROCJENA SVOJSTAVA OKOLINE	27
5.1.	Procjena sile i momenta na vrhu alata	27
5.1.1.	Svojstva i ograničenja procjene	27
5.2.	Procjena svojstava okoline iz odnosa sile i gibanja	28
5.3.	Uloga procjene u ovom radu	29
6.	KLASIČNI PRISTUP UPRAVLJANJU	30
6.1.	Struktura zadatka	30
6.2.	Faza prilaza i hvata	30
6.2.1.	Poravnanje platforme	30
6.2.2.	Prepoznavanje tipa kvake	30
6.2.3.	Hvat	31
6.2.4.	Sidrenje cilja na oznaku	31
6.3.	Faza otvaranja	32
6.3.1.	Klizna vrata	32
6.3.2.	Zakretna vrata	32
6.4.	Prolazak kroz vrata	34
6.5.	Rezultati	35
6.5.1.	Prilazak i hvat	35
6.5.2.	Zakretna vrata	35
6.5.3.	Klizna vrata	35
6.6.	Ograničenja	35
7.	PRISTUP TEMELJEN NA UČENJU	37
7.1.	Opseg	37
7.2.	Formulacija Markovljevog procesa odlučivanja	38

7.2.1.	Prostor opažanja	38
7.2.2.	Prostor akcija	38
7.2.3.	Koordinacija platforme i manipulatora	38
7.2.4.	Funkcija nagrade	39
7.2.5.	Terminacije	40
7.2.6.	Nasumičnost pri resetu i kurikulum otpora	40
7.3.	Postupak učenja	41
7.4.	Rezultati	42
7.5.	Ograničenja	43
8.	EKSPERIMENTALNI REZULTATI I RASPRAVA	44
8.1.	Protokol usporedbe	44
8.2.	Uspješnost otvaranja	44
8.3.	Kontaktne sile	45
8.4.	Načini otkazivanja	46
8.5.	Rasprava	46
8.5.1.	Različiti ulazi u isti problem	46
8.5.2.	Zašto se razlika pojavljuje samo na zakretnim vratima	46
8.6.	Ograničenja usporedbe	47
9.	ZAKLJUČAK	48
9.1.	Glavni nalazi	48
9.2.	Ograničenja	49
9.3.	Smjernice za daljnji rad	49
	LITERATURA	51
	PRILOZI	53

POPIS SLIKA

1	Mobilni manipulator KMR iiwa u simulacijskom okruženju	7
2	Građa Mecanum kotača	8
3	Prihvatnica s četiri prsta; otvorena (lijevo) i zatvorena (desno)	10
4	Položaj vrha alata (TCP)	10
5	Kamera i nosač kamere postavljeni na robotu	11
6	Modeli zakretnih i kliznih vrata s označenim stupnjem slobode gibanja . .	13
7	Postupak izrade simulacijskog modela iz opisa robota i vrata	16
8	Programska arhitektura klasičnog pristupa	19
9	Programska arhitektura pristupa temeljenog na učenju	20
10	AprilTagovi: sredina vrata (gore), kvaka (A dolje lijevo, B dolje desno) . .	22
11	Raspored vizualnih oznaka na zakretnim (lijevo) i kliznim (desno) vratima	23
12	Ovisnost pogreške položaja i smjera kvake o udaljenosti hvatišta od robota	25
13	Slijed faza klasičnog pristupa	30
14	Konstrukcija procjene osi šarke iz poze i lokalnih osi velike oznake, tlocrt .	34

POPIS TABLICA

2	Tehnički podaci mobilne platforme	8
3	Tehnički podaci manipulatora LBR iiwa 7 R800	9
4	Granični momenti zglobova manipulatora	9
5	Značajke prihvatnice	10
6	Geometrija i inercijska svojstva modela vrata	13
7	Rasponi randomizacije otpora vrata	14
8	Programska i sklopovska konfiguracija	18
9	Paketi radnog prostora ROS 2	18
10	Raspored vizualnih oznaka na vratima	22
11	Točnost procjene poze hvatišta, 30 mjernih točaka	25
12	Izmjerene vrijednosti pri otvaranju zakretnih vrata	35
13	Članovi funkcije nagrade	39
14	Hiperparametri učenja	42
15	Rezultati pristupa temeljenog na učenju, 1024 okruženja, 2400 iteracija . .	43
16	Stopa uspjeha po zajedničkim pragovima	45
17	Kontaktne sile klasičnog pristupa, prosjek deset pokušaja	45

POPIS OZNAKA

Oznaka	Jedinica	Opis
τ_{otpor}	N m, N	Ukupni otpor gibanja vrata (moment ili sila, ovisno o tipu)
τ_{tr}	N m, N	Coulombovo trenje u zglobu vrata
d	Nms/rad, Ns/m	Koeficijent viskoznog prigušenja zgloba vrata
q	rad, m	Koordinata stupnja slobode vrata (kut zakreta ili pomak krila)
$\dot{q}$	rad/s, m/s	Brzina stupnja slobode vrata
p	m	Položaj hvatišta kvake
p_A	m	Položaj oznake A na kvaki
p_B	m	Položaj oznake B na kvaki
z_A, z_B		Normale oznaka A i B
$\bar{z}$		Srednja vrijednost normala dviju oznaka
R		Matrica rotacije (hvatišta ili oznake, prema indeksu)
e_x, e_y, e_z		Vektori baze koordinatnog sustava hvatišta
τ	N m	Vektor momenata u zglobovima
q	rad	Vektor zglobnih koordinata
J		Jakobijan manipulatora
F	N	Vektor sile na vrhu alata
M	N m	Vektor momenta na vrhu alata
w		Vektor sila i momenata (engl. <i>wrench</i>)
ΔF	N	Prirast sile na vrhu alata
Δx	m	Prirast pomaka na vrhu alata
K	N/m, Nm/rad	Procijenjena krutost okoline
c	m	Procijenjeni položaj osi šarke zakretnih vrata
p_{tag}	m	Položaj velike oznake na sredini vrata
q_{tag}		Orijentacija (kvaternion) velike oznake
v_{hinge}	m	Vektor od oznake do osi šarke, u lokalnom okviru oznake
L	m	Širina krila vrata

Oznaka	Jedinica	Opis
δ	m	Odmak oznake od središnje ravnine debljine krila
w		Yoshikawin indeks manipulabilnosti
γ		Diskontni faktor
λ		Faktor generalizirane procjene prednosti
$(\cdot)^T$		Transponiranje matrice ili vektora
$(\cdot)^+$		Moore-Penroseov pseudoinverz matrice
$\ \cdot\ $		Norma vektora

POPIS KRATICA

Kratika	Opis
ELU	Ekponencijalna linearna jedinica (engl. <i>exponential linear unit</i>)
KMR	KUKA Mobile Robotics
LBR	Lagani robot (njem. <i>Leichtbauroboter</i>)
PhysX	Fizikalni pogon simulatora
PPO	Proksimalna optimizacija politike (engl. <i>proximal policy optimization</i>)
ROS	Robotski operacijski sustav (engl. <i>Robot Operating System</i>)
TCP	Vrh alata (engl. <i>tool center point</i>)
URDF	Objedinjeni opis robota (engl. <i>Unified Robot Description Format</i>)
USD	Univerzalni opis scene (engl. <i>Universal Scene Description</i>)

SAŽETAK

U radu se razmatra problem autonomne interakcije mobilnog manipulatora s okolinom, na primjeru otvaranja dvije vrste vrata, zakretnih i kliznih. Za mobilni manipulator KUKA KMR iiwa razvijen je u simulacijskom okruženju cjelovit sustav koji objedinjuje percepciju, procjenu sile i momenta te upravljanje u kontaktu. Modul percepcije iz slike određuje položaj i orijentaciju kvake pomoću vizualnih oznaka, a sila i moment na vrhu alata procjenjuju se iz momenata u zglobovima, bez zasebnog senzora sile. Tip vrata robot ne dobiva kao zadan podatak, nego ga prepoznaje iz geometrije kvake.

Zadatak upravljanja riješen je dvama pristupima. Klasični pristup temeljen na modelu izvodi cijeli lanac, od prilaska i hvata preko otvaranja do prolaska kroz vrata, oslanjajući se na geometriju ograničenja izračunatu iz percepcije. Pristup temeljen na podržanom učenju zadatak formulira kao Markovljev proces odlučivanja s varijabilnom impedancijom u prostoru akcije, pri čemu politika u svakom koraku bira krutost regulatora po svakoj osi, a geometriju ograničenja mora otkriti iz vlastitih opažanja sile i pomaka.

Oba su pristupa izmjerena na istom robotu, istoj sceni i istim mjerilima uspješnosti. Kod kliznih vrata oba dosežu puni cilj u svakom pokušaju. Kod zakretnih vrata klasični pristup pouzdano otvara vrata do 50° , ali preko otprilike 57° ne može jer kvaka klizne iz prihvatnice, dok naučena politika vrata otvara preko 90° u 96 % epizoda, uz bitno niže kontaktne sile. Zaključak je da je eksplicitno poznavanje geometrije dovoljno kad je geometrija jednostavna i dobro procijenjena, a gubi prednost čim zadatak zahtijeva prilagodbu krutosti tijekom same interakcije.

KLJUČNE RIJEČI: mobilni manipulator, fizička interakcija, procjena svojstava okoline, impedancijsko upravljanje, podržano učenje, simulacija.

SUMMARY

This thesis addresses the problem of autonomous interaction between a mobile manipulator and its environment, using the opening of two types of door, revolute and sliding, as the test case. A complete system integrating perception, force and torque estimation, and contact control was developed in simulation for the KUKA KMR iiwa mobile manipulator. The perception module determines the position and orientation of the door handle from camera images using visual markers, while the force and torque at the tool tip are estimated from joint torques, without a dedicated force sensor. The door type is not supplied to the robot as a parameter, but inferred from the geometry of the handle.

The control problem is solved by two approaches. The classical, model-based approach performs the entire task chain, from approach and grasp through opening to passing through the doorway, relying on the constraint geometry computed from perception. The learning-based approach formulates the task as a Markov decision process with variable impedance as the action space, so that the policy selects the controller stiffness along each axis at every step, and must infer the constraint geometry from its own force and displacement observations.

Both approaches were evaluated on the same robot, the same scene and the same success criteria. For sliding doors, both reach the full target in every trial. For revolute doors, the classical approach reliably opens the door to 50° but cannot exceed approximately 57° , as the handle slips out of the gripper, whereas the learned policy opens the door beyond 90° in 96 % of episodes, with substantially lower contact forces. The conclusion is that explicit knowledge of the constraint geometry is sufficient when that geometry is simple and well estimated, but loses its advantage as soon as the task requires the stiffness to be adapted during the interaction itself.

Key words: mobile manipulator, physical interaction, environment property estimation, impedance control, reinforcement learning, simulation.

1. UVOD

1.1. Motivacija

Industrijska robotika od svog početka počiva na pretpostavci strukturirane okoline. Robot je ograden zaštitnom ogradom, radni komadi nalaze se na predodređenom mjestu, a zadatak se svodi na ponavljanje prethodno naučene i isprogramirane radnje. U takvim uvjetima pozicijsko upravljanje visoke krutosti daje izvrsne rezultate, robot vrlo ponovljivo i bez većih odstupanja slijedi zadanu putanju bez obzira na smetnje.

Ta se pretpostavka ruši čim robot izađe iz kaveza. Industrijska okruženja puna su ljudi koji istovremeno obavljaju svoje poslove, servise, logističke zadatke i okolnosti koje se mijenjaju između dva izvođenja istog zadatka. Odgovor na takve probleme su mobilni manipulatori — sustavi koji integriraju svestranost mobilne platforme s artikuliranošću robotske ruke i time uklanjaju ograničenje dosega koje veže nepokretni manipulator za jedno radno mjesto.

Najčešća primjena industrijskih robota je za tzv. *pick-and-place* radnje, ali postoji i veliki broj operacija za koje je potrebna uspostava i održavanje fizičkog kontakta, primjerice otvaranje vrata i ladica, umetanje predmeta, posluživanje stroja ili pomicanje objekata. Postojanje kontakta uvelike mijenja problem upravljanja. Dok se robot giba u slobodnom prostoru, greška položaja je relativno mala i nema brige da će robot oštetiti okolinu. U kontaktu s krutom okolinom ista greška položaja proizvodi silu koja raste s krutošću regulatora i može oštetiti predmet, okolinu ili samog robota. Zbog toga upravljanje u kontaktu ne može biti čisto pozicijsko, već mora regulirati odnos između položaja i sile [1].

Otvaranje vrata reprezentativan je predstavnik te klase zadataka i zbog toga se u literaturi često koristi kao referentni problem [2]. Vrata su artikulirani objekt čije je gibanje ograničeno na jedan stupanj slobode, ali robot taj stupanj slobode ne poznaje unaprijed. Drugim riječima, robot ne zna gdje je os šarke, u kojem smjeru se krilo otvara ili koliki je otpor u zglobu. Sve to mora zaključiti iz vlastitih mjerenja tijekom interakcije [3]. Uz to, hod krila redovito premašuje doseg ruke pri nepomičnoj bazi, pa zadatak traži i koordinaciju platforme i manipulatora. Zadatak time istovremeno obuhvaća percepciju, procjenu svojstava okoline i upravljanje u kontaktu, što ga čini prikladnim ispitnim slučajem za cjelovit sustav.

Postoje dva prevladavajuća pristupa takvim zadacima. Klasični pristup temeljen na modelu oslanja se na eksplicitan opis zadatka: procijeni se geometrija ograničenja, iz nje se generira referentna putanja, a impedancijski ili hibridni silno-pozicijski regulator izvodi gibanje uz propisanu popustljivost [4]. Prednost je razumljivost i predvidljivost, svaki je

korak moguće analizirati i obrazložiti. Slabost je osjetljivost na kvalitetu procjene: pogreška u procijenjenoj geometriji ograničenja izravno se pretvara u kontaktnu silu. Pristup temeljen na učenju ne zahtijeva eksplicitan model, već strategiju upravljanja stječe kroz interakciju sa simuliranom okolinom. Novije formulacije akcijskim prostorom politike čine samu krutost regulatora, pa politika uči ne samo kamo se gibati nego i koliko biti popustljiva u pojedinom trenutku [5]. Cijena je gubitak uvida u razloge odluke i ovisnost o vjernosti simulacije.

Usporedba tih dvaju pristupa ima smisla samo ako se provodi na istom zadatku, istom robotu i istoj fizici okoline. Ovaj rad zato oba pristupa razvija za isti sustav (mobilni manipulator KUKA KMR iiwa u simulacijskom okruženju), i uspoređuje ih na istim mjerilima uspješnosti.

1.2. Cilj i doprinos rada

Cilj rada je razviti i eksperimentalno vrednovati sustav koji mobilnom manipulatoru omogućuje autonomnu interakciju s okolinom, te na tom sustavu usporediti dva pristupa upravljanju. Zadatak je konkretiziran otvaranjem vrata dvaju tipova, zakretnih i kliznih, pri čemu robot tip vrata ne dobiva kao zadan podatak nego ga prepoznaje sam.

U sklopu rada razvijen je modul percepcije koji iz slike određuje položaj i orijentaciju kvake, postupak procjene sile i momenta na vrhu alata iz momenata u zglobovima, bez zasebnog senzora sile, te dva međusobno neovisna rješenja zadatka upravljanja. Klasično rješenje izvodi cijeli lanac, od prilaska i hvata preko otvaranja do prolaska kroz vrata, oslanjajući se na geometriju ograničenja izračunatu iz percepcije. Rješenje temeljeno na učenju zadatak formulira kao Markovljev proces odlučivanja s varijabilnom impedancijom u prostoru akcije, pa politika u svakom koraku bira koliko će regulator biti krut po svakoj osi, a geometriju ograničenja mora otkriti iz vlastitih opažanja sile i pomaka.

Usporedba je pokazala da se prednost jednog pristupa nad drugim ne može izreći općenito, nego ovisi o tipu vrata. Kod kliznih vrata, gdje je ograničenje pravac, a smjer sile poklapa se sa smjerom gibanja, oba pristupa dosežu puni cilj u svakom pokušaju. Kod zakretnih vrata klasični pristup pouzdano otvara vrata do 50° , ali preko otprilike 57° ne može, jer kvaka klizne iz prihvatnice, dok naučena politika vrata otvara preko 90° u 96 % epizoda, uz niže kontaktne sile. Eksplicitno poznavanje geometrije time je dovoljno kad je geometrija jednostavna i dobro procijenjena, a gubi prednost čim zadatak zahtijeva prilagodbu krutosti tijekom same interakcije.

Doprinos rada nije novi postupak upravljanja, nego izravna usporedba dvaju pristupa izvedenih za istog robota, istu scenu i ista mjerila uspješnosti, uz dva tipa vrata koja isti zadatak čine različito teškim. Cjelokupan je rad proveden u simulaciji, pa se zaključci odnose na model, a ograničenja koja iz toga slijede navedena su uz pojedine dijelove

sustava i sažeta u poglavlju 9..

1.3. Struktura rada

Poglavlje 2. daje pregled dosadašnjih istraživanja, od klasičnih zakona upravljanja u kontaktu preko procjene kinematičkih modela artikuliranih objekata do novijih pristupa temeljenih na podržanom učenju. Poglavlje 3. opisuje robotski sustav i simulacijsko okruženje: mobilni manipulator KMR iiwa, prihvatnicu izrađenu za ovaj zadatak, modele vrata te programsku arhitekturu koja povezuje simulator i upravljački kod.

Poglavlja 4. i 5. obrađuju ulazne module sustava. Prvo opisuje određivanje položaja i orijentacije kvake iz slike, a drugo procjenu sile i momenta na vrhu alata te postupak kojim sustav iz izmjerenog odziva zaključuje o ograničenju gibanja i krutosti okoline.

Poglavlja 6. i 7. predstavljaju dva uspoređivana pristupa upravljanju. Prvo opisuje rješenje temeljeno na modelu, organizirano kao slijed faza s eksplicitnom procjenom geometrije ograničenja. Drugo opisuje formulaciju zadatka kao Markovljevog procesa odlučivanja, prostor stanja i akcija s promjenjivom impedancijom, oblikovanje funkcije nagrade, te postupak učenja.

Poglavlje 8. donosi usporedbu dvaju pristupa na istoj sceni i istim mjerilima, uz raspravu o tome što razlike znače i o ograničenjima provedene usporedbe. Poglavlje 9. sažima postignuto i navodi smjernice za daljnji rad.

2. PREGLED DOSADAŠNJIH ISTRAŽIVANJA

Zadatak iz ovog rada dodiruje tri područja koja se u literaturi razvijaju odvojeno: upravljanje u kontaktu, koje se bavi time kako robot smije djelovati na okolinu; mobilnu manipulaciju, koja se bavi koordinacijom platforme i manipulatora; te interakciju s artikuliranim objektima, koja se bavi time kako robot doznaje kako se objekt uopće giba. Pregled slijedi tu podjelu, a završava pristupima temeljenima na učenju, koji zadnjih godina povezuju sva tri.

2.1. Klasični pristupi upravljanju u kontaktu

Upravljanje robotom u kontaktu s okolinom ne može biti čisto pozicijsko. Čim je vrh alata krut, a okolina također kruta, mala pogreška položaja proizvodi veliku silu, pa se regulator mora odnositi i prema odnosu položaja i sile.

Dva su rana odgovora na taj problem oblikovala područje. Hibridno silno-pozicijsko upravljanje prostor zadatka dijeli na smjerove u kojima se regulira položaj i smjerove u kojima se regulira sila, prema unaprijed poznatoj matrici izbora izvedenoj iz geometrije zadatka [1]. Impedancijsko upravljanje ne razdvaja te smjerove, nego propisuje željeni dinamički odnos između pomaka i sile, pa se robot prema okolini ponaša kao opruga zadane krutosti i prigušenja.

Formalni okvir koji povezuje oba pristupa dao je Khatib upravljanjem u operacijskom prostoru [4]. Jednadžbe gibanja manipulatora ondje se izražavaju izravno u prostoru zadatka, pa se sila na vrhu alata preslikava u momente zglobova preko transponiranog Jakobijana. Isti taj odnos se u ovom radu koristi za procjenu sile iz mjerenja momenata (poglavlje 5.). Kod redundantnih manipulatora taj okvir omogućuje i upravljanje u nul-prostoru, dakle promjenu konfiguracije zglobova bez pomicanja vrha alata.

Primjenu kartezijskog impedancijskog upravljanja upravo na otvaranje vrata mobilnim manipulatorom prikazali su Ott i suradnici [2]. Njihov je rad blizak zadatku iz ovog rada, s tom razlikom što se oslanja na unaprijed poznat model vrata.

Zajednička slabost svih tih pristupa jest osjetljivost na kvalitetu modela. Ako procijenjena geometrija ograničenja odstupa od stvarne, regulator tu razliku pretvara u kontaktnu silu, i to tim izraženije što je krutost veća. Upravo se ta osjetljivost u ovom radu pokazala kao granica klasičnog pristupa na zakretnim vratima (poglavlje 6.).

2.2. Mobilna manipulacija

Spajanjem manipulatora s mobilnom platformom uklanja se ograničenje dosega, ali se uvodi problem koordinacije: platforma i manipulator dijele isti zadatak, a imaju vrlo različitu dinamiku i točnost. Sustavan pregled pristupa planiranju gibanja za mobilne manipulatore daju Sandakalum i Ang [6].

Postoje dvije osnovne strategije. Hijerarhijski pristup platformu i manipulator rješava odvojeno, najčešće tako da se platforma najprije dovede na povoljan položaj, a zatim manipulator izvede zadatak iz mirovanja. Prednost je jednostavnost, a slabost to što se gibanja ne preklapaju i što loš izbor položaja platforme zadatak može učiniti neizvedivim. Cjelovito upravljanje platformu i manipulator promatra kao jedan sustav s velikim brojem stupnjeva slobode, čime dobiva na svestranosti, ali uz znatno složenije upravljanje.

Predstavnik cjelovitog pristupa je perceptivno prediktivno upravljanje temeljeno na modelu, u kojem se gibanje platforme i manipulatora optimira zajedno, uz model okoline izgrađen iz senzorskih podataka [7]. Takvi pristupi daju glatko i usklađeno gibanje, ali zahtijevaju model zadatka i računalno su zahtjevni.

Klasični pristup u ovom radu je dijelom cjeloviti, dijelom hijerarhijski, dok pristup temeljen na učenju koordinaciju rješava jednom naučenom strategijom.

2.3. Interakcija s artikuliranim objektima

Vrata, ladice i slični objekti dijele svojstvo da im je gibanje ograničeno na jedan ili nekoliko stupnjeva slobode, koje robot unaprijed ne poznaje. Prije nego takav objekt pomakne, robot mora utvrditi kako se on uopće smije gibati.

Sturm i suradnici formulirali su taj problem kao učenje kinematičkih modela artikuliranih objekata iz opažanja gibanja [3]. Njihov okvir iz zabilježene putanje odabire model koji ju najbolje objašnjava (rotacijski, prizmatični ili krut) i time istovremeno prepoznaje tip zgloba i procjenjuje njegove parametre. Isto načelo, prilagodba više modela istoj putanji, stoji iza postupka procjene ograničenja opisanog u poglavlju 5..

Noviji radovi taj problem rješavaju tijekom samog izvođenja, bez prethodne faze promatranja. Rizzi i suradnici predstavili su upravljanje mobilnim manipulatorom temeljeno na uzorkovanju, otporno na nepoznate parametre artikuliranog objekta [8].

Za ovaj je rad posebno blizak rad Stuedea i suradnika [9], u kojem mobilni manipulator istog tipa kao u ovom radu otvara vrata i prolazi kroz njih uz kartezijsko impedancijsko upravljanje, bez poznatog modela vrata, pri čemu se kvaka detektira konvolucijskom neuronskom mrežom. Taj rad pokazuje i put kojim bi se moglo ukloniti najizraženije pojednostavljenje ovog rada, a to je oslanjanje na vizualne oznake (potpoglavlje 4.7.).

2.4. pristupi temeljeni na učenju

Podržano učenje na zadatke mobilne manipulacije primjenjuje se jer ne zahtijeva eksplicitan model zadatka: politika strategiju stječe kroz interakciju s okolinom. Cijena je gubitak uvida u razloge pojedine odluke i ovisnost o vjernosti simulacije u kojoj se uči.

Za zadatke s kontaktom presudan je odabir prostora akcije. Martín-Martín i suradnici pokazali su da politika koja izravno zadaje momente ili položaje slabo uči zadatke bogate kontaktom, dok politika kojoj je akcijski prostor varijabilna impedancija (referentni pomak zajedno s krutošću regulatora) uči znatno uspješnije [5]. Politika tada ne uči samo kamo se gibati, nego i koliko biti popustljiva u pojedinom trenutku. Taj je akcijski prostor izravna osnova formulacije u poglavlju 7..

Drugi smjer istraživanja bavi se time kako naučiti gibanje platforme koje manipulatoru održava kinematičku izvedivost. Honerkamp i suradnici najprije su pokazali da se politika platforme može naučiti tako da prati zadanu putanju vrha alata i drži je unutar dosega [10], a zatim taj pristup proširili na proizvoljna gibanja u nepoznatoj i promjenjivoj okolini [11].

Osim samog upravljanja, učenje se koristi i za oblikovanje sustava. Schneider i suradnici optimiraju parametre montaže manipulatora na platformu, koristeći naučenu politiku u unutarnjoj petlji, i pokazuju da izbor montaže sam po sebi bitno mijenja uspješnost otvaranja vrata [12]. Nalaz je vrijedan i za ovaj rad, jer je manipulator i ovdje montiran izvan osi platforme, što zakretom platforme proširuje radni prostor (potpoglavlje 7.2.3.).

Algoritam korišten u ovom radu je proksimalna optimizacija politike (PPO) [13], odabrana zbog stabilnosti pri velikom broju paralelnih okruženja.

2.5. Položaj ovog rada

Navedeni radovi pojedine dijelove zadatka rješavaju bolje nego ovaj rad, ali ga uglavnom promatraju odvojeno: ili razvijaju upravljanje uz poznat model objekta, ili uče politiku bez usporedbe s klasičnom alternativom. Doprinos ovog rada nije novi postupak upravljanja, nego *izravna usporedba* dvaju pristupa izvedenih za istog robota, istu scenu i ista mjerila uspješnosti, uključujući dva tipa vrata koja isti zadatak čine različito teškim. Time se pokušava odgovoriti na pitanje pod kojim uvjetima eksplicitno poznavanje geometrije donosi prednost, a pod kojima je gubi.

3. ROBOTSKI SUSTAV I SIMULACIJSKO OKRUŽENJE

Ovo poglavlje opisuje robotski sustav na kojem su razvijena i ispitana oba pristupa upravljanju, modele vrata koji čine radnu okolinu, postupak izrade simulacijskog modela te programsku arhitekturu koja povezuje simulator i upravljački kod. Cijeli je rad proveden u simulaciji; razlozi i posljedice tog izbora navedeni su u potpoglavljju 3.7..

3.1. KMR iiwa — mobilna platforma i manipulator

KUKA KMR iiwa (slika 1) mobilni je manipulator sastavljen od dviju serijskih komponenti: omnidirekcijske mobilne platforme KMP 200 omniMove i laganog robota LBR iiwa. Na prirubnicu manipulatora dodana je prihvatnica opisana u potpoglavljju 3.2.. Kombinacija pokretljive platforme i osjetljivog manipulatora namijenjena je radu bez zaštitne ograde, u okolini u kojoj se robot kreće između radnih mjesta [14].



Slika 1. Mobilni manipulator KMR iiwa u simulacijskom okruženju

3.1.1. Mobilna platforma

Platforma se giba pomoću četiriju Mecanum kotača (slika 2). Svaki se kotač sastoji od niza valjaka postavljenih pod kutom od 45° u odnosu na os kotača, čime se postiže omnidirekcijsko gibanje — platforma se može gibati u proizvoljnom smjeru u ravnini i

istovremeno se zakretati, bez potrebe za promjenom orijentacije prije translacije. Ta je osobina bitna za zadatak otvaranja vrata, jer omogućuje da baza slijedi luk krila bez manevriranja. Tehnički podaci mobilne platforme nalaze se u tablici 2.



Slika 2. Građa Mecanum kotača [15]

Tablica 2. Tehnički podaci mobilne platforme

Veličina	Vrijednost
Dimenzije ($V \times \check{S} \times D$)	$700 \times 1080 \times 630$ mm
Masa	390 kg
Najveća nosivost	170 kg (200 kg bez manipulatora)
Brzina u uzdužnom smjeru	najviše 3.6 km/h
Brzina u poprečnom smjeru	najviše 2.0 km/h
Promjer kotača	250 mm
Klasa čistoće	ISO 5

3.1.2. Manipulator LBR iiwa 7 R800

Korišten je manipulator LBR iiwa 7 R800, redundantna kinematička struktura sa sedam rotacijskih osi. Za ovaj je rad ključno da manipulator ima senzor momenta u svakoj osi, što omogućuje procjenu sile i momenta na vrhu alata bez zasebnog senzora sile na zapešću. Postupak te procjene opisan je u poglavlju 5.. Sedma os čini strukturu redundantnom u odnosu na šest stupnjeva slobode zadatka, pa isti položaj i orijentaciju vrha alata ostvaruje kontinuum konfiguracija — svojstvo koje se u poglavlju 8. pokazalo dosta važnim. Tehnički podaci manipulatora nalaze se u tablici 3.

Tablica 3. Tehnički podaci manipulatora LBR iiwa 7 R800

Veličina	Vrijednost
Nazivna nosivost	7 kg
Broj osi	7
Doseg	800 mm
Izvedba zapešća	u liniji
Prirubnica na osi 7	DIN ISO 9409-1-A50
Ponovljivost pozicioniranja	± 0.1 mm
Točnost momenta po osi	± 2 %
Masa	23.9 kg
Stupanj zaštite	IP54
Položaj ugradnje	pod, strop, zid

Granični momenti pojedinih zglobova navedeni su u tablici 4.

Tablica 4. Granični momenti zglobova manipulatora


Zglob	1	2	3	4	5	6	7
Granični moment, Nm	176	176	110	110	110	40	40

3.2. Prihvatnica


Za hvatanje kvake izrađena je prilagođena prihvatnica (slika 3). Budući da se rad provodi isključivo u simulaciji, a stvarni prihvatni uređaj nije bio zadan, prihvatnica je oblikovana kao zamjenjiva komponenta, tj. upravljanje njome potpuno je odvojeno od ostatka softvera (potpoglavlje 3.8.), pa se može zamijeniti bez izmjena u ostatku sustava.

Prihvatnica ima četiri prsta raspoređena u dva para koja se zatvaraju duž osi x baze, dok uhvaćena šipka leži duž osi y . Svaki prst na sebi ima utor čiji je unutarnji luk prilagođen šipki kvake promjera 28 mm. Pri potpuno zatvorenom hvatu otvor između prstiju uži je od šipke, pa hvat ne počiva na geometrijskom dosjedanju nego na sili pogona i popustljivosti prstiju. Time se izbjegava zazor koji bi pri vučenju vrata dopustio da se kvaka pomiče unutar hvata. Položaj vrha alata (*TCP*, engl. *tool center point*) može se vidjeti na slici 4. Značajke prihvatnice nalaze se u tablici 5.

Parovi prstiju ne gibaju se savršeno simetrično, pa se predmet ne centrira sam od sebe. Ta se asimetrija ne pokušava ukloniti, nego se mjeri: tijekom prilaza kvaki uspoređuju se položaji suprotnih prstiju i iz razlike se izračunava bočna korekcija kojom se prihvatnica poravna nad kvakom prije nego što se hvat zatvori. Postupak je opisan u potpoglavlju 6.2..



Slika 3. Prihvatnica s četiri prsta; otvorena (lijevo) i zatvorena (desno)



Slika 4. Položaj vrha alata (*TCP*)

Tablica 5. Značajke prihvatnice

Značajka	Vrijednost
Promjer prirubnice	63 mm
Dimenzije nosive ploče	85 × 85 mm
Duljina prsta	66.5 mm
Unutarnji polumjer utora	16 mm
Hod po prstu	0–25 mm
Masa nosivog dijela	442 g
Masa prsta	30.6 g
Ukupna masa	564 g
Položaj vrha alata iznad prirubnice	74.85 mm
Statički koeficijent trenja prstiju	1.2
Dinamički koeficijent trenja prstiju	1.0

Vrh alata leži na osi alata, na visini od 74.85 mm iznad prirubnice manipulatora. Ta visina odgovara središtu unutarnjeg luka kuka pri zatvorenom hvatu, dakle visini na kojoj se nalazi os uhvaćene šipke. Vrh alata time nije materijalna točka na prihvatnici, nego sjecište osi alata i osi predmeta u hvatu, čime regulator momente računa oko stvarnog hvatišta.

Prsti su u simulacijskom modelu upravljani pozicijski, s krutošću pogona 20 000 N/m, prigušenjem 200 Ns/m i graničnom silom 600 N. Pri vučenju vrata silu prenose djelotvorno samo dva od četiriju prstiju, jer jedan par radi protiv vlastitog pogona, pa je djelotvorna krutost hvata polovica nominalne. Ta je pojedinost bitna za tumačenje rezultata u poglavlju 8..

3.3. Kamera i njezin nosač

Za detekciju kvake robot je opremljen kamerom Intel RealSense D435, postavljenom na mobilnu platformu pomoću vlastito izrađenog nosača (slika 5). Sam postupak detekcije i procjene poze opisan je u poglavlju 4.; ovdje je opisana samo montaža i pripadni koordinatni sustavi.

Nosač kamere oblikovan je tako da iskoristi postojeće provrte na platformi. Manipulator se na platformu pričvršćuje preko četiri provrta promjera 13.3 mm raspoređena po kružnici polumjera 108 mm. Ta je kružnica na platformi izvedena zrcalno s obje strane, a strana suprotna manipulatoru ostaje slobodna, pa je nosač kamere postavljen upravo na nju. Time montaža ne zahtijeva nikakvu izmjenu platforme.



Slika 5. Kamera i nosač kamere postavljeni na robotu

Kamera je smještena na visini gornje plohe platforme, bočno pomaknuta u odnosu na manipulator. Time je kvaka u vidnom polju i tijekom prilaza i tijekom hvata, a kamera ne ulazi u radni prostor manipulatora. Nosač je zamišljen kao izradak aditivnom pro-

izvodnjom; masa od 193 g izračunata je iz obujma modela uz gustoću materijala PETG od 1270 kg/m^3 .

Kamera u modelu ima dva koordinatna sustava. Prvi je vezan uz kućište i služi za montažu, a drugi je optički koordinatni sustav u kojem se izražavaju rezultati detekcije. Optički je zaokrenut u odnosu na kućište prema uobičajenoj konvenciji, pri čemu os z gleda u smjeru promatranja, a osi x i y leže u ravnini slike. Ta konvencija nije proizvoljna nego je očekuju biblioteke za obradu slike, pa je zadržana kako procjena poze ne bi zahtijevala dodatnu pretvorbu.

Kamera podržava i dubinsku sliku, no ona u ovom radu nije korištena. Detekcija vrata i kvake odvija se isključivo iz slike u boji, pomoću oznaka AprilTag, a postignuta točnost pokazala se dovoljnom i bez dubinske informacije.


3.4. Lidar

Uz kameru, robot je opremljen i dvodimenzijskim laserskim skenerom (lidarom), postavljenim na prednjoj strani mobilne platforme. Za razliku od kamere, koja služi isključivo detekciji kvake (poglavlje 4.), lidar se koristi za dvije zadaće vezane uz neposrednu okolinu robota: otkrivanje prepreka ispred platforme tijekom otvaranja vrata i pronalaženje otvora u zidu radi prolaska kroz vrata. Obje su zadaće opisane u poglavlju 6., u opsegu klasičnog pristupa; pristup temeljen na učenju ne koristi lidar direktno, već očitava pozicije zidova izravno iz simulatora.

Senzor ima i minimalni domet ispod kojeg mjerenja nisu pouzdana. Budući da je kvaka nakon hvata na udaljenosti od tek oko 0.65 m od senzora, unutar tog dometa krilo vrata ostaje nevidljivo, pa je vrijednost minimalnog dometa u konfiguraciji senzora spuštena na 0.05 m.

3.5. Modeli vrata

Radnu okolinu čine dva modela vrata, zakretna i klizna (slika 6). Oba su izgrađena od osnovnih geometrijskih tijela, s istim krilom, a razlikuju se stupnjem slobode gibanja i oblikom kvake. Zajednička geometrija je namjerna: razlika u ponašanju dvaju pristupa time se ne može pripisati razlici u dimenzijama ili masi krila. Geometrijska i inercijska svojstva vrata mogu se vidjeti u tablici 6.



Slika 6. Modeli zakretnih i kliznih vrata s označenim stupnjem slobode gibanja

Tablica 6. Geometrija i inercijska svojstva modela vrata

Veličina	Zakretna vrata	Klizna vrata
Krilo, dimenzije	$40 \times 850 \times 2000$ mm	$40 \times 850 \times 2000$ mm
Krilo, masa	15 kg	15 kg
Nepomični dio	stup $60 \times 60 \times 2000$ mm	vodilica $60 \times 2000 \times 60$ mm
Stupanj slobode	rotacija oko osi z	translacija duž osi y
Raspon gibanja	$0\text{--}135^\circ$	$0\text{--}1.0$ m
Kvaka, oblik	poluga, duljina 160 mm	šipka, duljina 250 mm
Kvaka, promjer šipke	28 mm	28 mm
Kvaka, masa	0.35 kg	0.35 kg
Visina hvatišta	1000 mm	1000 mm

Kod zakretnih vrata kvaka je izvedena kao poluga usmjerena prema osi šarke, kako je uobičajeno kod stvarnih vrata. Zglob brave, koji bi omogućio zakretanje kvake, zavaren je u nepomični zglob u oba pristupa, pa je jedini pokretni stupanj slobode zakretnih vrata os šarke. Okretanje kvake time je izvan opsega rada; razlog i posljedice te odluke navedeni su u potpoglavlju 6.6.. Posljedica koju treba imati na umu jest da se cijeli moment šarke prenosi trenjem prstiju na šipki kvake.

Kod kliznih vrata kvaka je okomita šipka pričvršćena dvama odstojećima, pa je hvatište

dostupno s prednje strane krila po cijeloj visini šipke.

Vrata su s obje strane omeđena zidom, izvedenim kao dva zasebna, nepomična elementa, svaki dimenzija $0.06 \times 2.5 \times 2.0$ m i mase 15 kg. Zidovi su postavljeni tako da između njih ostaje slobodan prolaz od 0.85 m, jednak širini krila vrata, čime nastaje realistična okolina vrata umjesto izoliranog objekta u praznom prostoru. Ta je okolina preduvjet za dvije zadaće opisane u poglavlju 6.. Lidar treba stvarnu prepreku da bi u njoj prepoznao otvor, a MoveIt treba stvarnu geometriju zida da bi je uzeo u obzir pri planiranju gibanja manipulatora.

3.5.1. Otpor gibanja i njegova randomizacija

Otpor vrata nije zapisan u geometrijskom modelu, nego se postavlja pri svakom pokretanju epizode iz zadanog raspona. Time politika nije vezana uz jednu vrijednost otpora, nego uči raditi na rasponu vrata. Otpor je razdvojen na dva fizikalno različita člana:

$$\tau_{\text{otpor}} = \tau_{\text{tr}} + d\dot{q}, \quad (1)$$

gdje je q koordinata jedinog stupnja slobode vrata, dakle kut zakreta krila kod zakretnih odnosno pomak krila kod kliznih vrata, a $\dot{q}$ njegova derivacija po vremenu, to jest brzina otvaranja. Član τ_{tr} Coulombovo je trenje, konstantno po iznosu i neovisno o brzini, dok je d koeficijent viskoznog prigušenja, koji daje otpor razmjern brzini. Izraz je zapisan općenito za oba tipa vrata: kod zakretnih su τ_{otpor} i τ_{tr} momenti, a kod kliznih sile.

Parametri se zadaju u apsolutnim jedinicama, dakle u njutnima za prizmatični i njutnmetrima za revolutni zglobov, a ne kao bezdimenzijski koeficijenti. Da bi se to potvrdilo, provedeno je mjerenje u simulaciji. Vratima je zadana poznata vrijednost trenja, a zatim je polagano rastućom silom određena sila pri kojoj se vrata pokrenu. Omjer izmjerene sile pokretanja i zadanog trenja kretao se između 1.00 i 1.03 za zadane vrijednosti trenja u rasponu od 5 do 60 N, čime je potvrđeno da zadana vrijednost izravno odgovara sili potrebnoj za pokretanje vrata.

U tablici 7 mogu se vidjeti rasponi iz kojih su birane vrijednosti otpora vrata:

Tablica 7. Rasponi randomizacije otpora vrata

Tip vrata	Trenje	Prigušenje
Klizna	5–60 N	5–50 Ns/m
Zakretna	0.5–5 Nm	0.5–5 Nms/rad

Rasponi nisu određeni mjerenjem na stvarnim vratima, nego su usvojeni kao inženjerska procjena, sa širinom raspona odabranom tako da obuhvati i lagana i teška vrata. Svrha

im nije vjerno preslikati određena vrata, već spriječiti da naučena politika ovisi o jednoj vrijednosti otpora.

3.6. Model robota i pretvorba u simulacijski format

Geometrijski i kinematički model robota opisan je u formatu *Unified Robot Description Format* (URDF). Model manipulatora preuzet je iz javno dostupnog paketa `iiwa_stack` [16], a model mobilne platforme iz proizvođačeve dokumentacije [14]. Prihvatnica, nosač kamere i oba modela vrata izrađeni su u sklopu ovog rada. Model je organiziran pomoću `xacro` predložaka, tako da se prihvatnica u model uključuje jednim pozivom makronaredbe.

Isaac Sim ne koristi URDF izravno, nego format *Universal Scene Description* (USD). Pretvorba nije jedan korak nego niz skripti, jer sama pretvorba ne prenosi sve što je za rad potrebno.


Osnovnu pretvorbu obavlja `convert_urdf_usd.py`, proširena inačica alata iz Isaac Laba. Dvije su postavke pritom bitne:

- **Vrsta kolidera** (engl. *collider type*). Prsti prihvatnice moraju se pretvarati postupkom konveksne dekompozicije. Zamotavanje u konveksnu ovojnici zatvorilo bi utore na prstima i prihvatnica ne bi mogla obuhvatiti šipku.
- **Sažimanje nepomičnih zglobova**. Ne smije se primijeniti na model robota, jer bi uklonilo zglob na kojem se očitavaju sile i momenti (potpoglavlje 3.2.).

Na dobiveni model zatim se primjenjuju tri naknadne skripte:

- `apply_gripper_friction.py` pridružuje materijal trenja ploham prstiju i kvaka. Pridruživanje se ne može izvesti izravno na složenoj sceni, jer se geometrija prsta, referencirana četiri puta iz iste datoteke, pojavljuje kao instancirani sloj u koji nije dopušteno upisivati; skripta zato pronalazi stvarni sloj u kojemu se geometrija nalazi i materijal upisuje u njega.
- `add_arm_ros_control_graph.py` umeće graf koji povezuje zglobove manipulatora s temama ROS-a 2, čime se model može voditi izvana. Graf mora biti ugniježđen unutar stabla osnovnog elementa modela, jer se inače pri referenciranju modela u scenu tiho izgubi.
- `add_camera_ros_graph.py` dodaje kameru s izmjerenim unutarnjim parametrima i položajem te objavljuje sliku i stabla koordinatnih sustava.

Na slici 7 može se vidjeti dijagram toka pretvorbe datoteka iz URDF formata u simulatoru koriste datoteke u USD formatu.



Slika 7. Postupak izrade simulacijskog modela iz opisa robota i vrata

Za učenje se koristi zasebna inačica modela. Iz modela vrata uklonjeni su nosivi elementi oznaka za percepciju, jer tijela mase 0.001 kg uz krilo mase 15 kg loše uvjetuju numerički postupak rješavanja. Nazivi članaka i zglobova ujednačeni su između obaju tipova vrata, čime jedna programska implementacija okruženja posluži oba tipa bez grananja po tipu vrata.

3.6.1. Gibanje mobilne platforme

Mecanum kotači nisu simulirani kao tijela u kontaktu s podlogom. Umjesto toga, gibanje platforme zadaje se kinematički: naredba brzine iz poruke `/cmd_vel` pretvara se u pomake platforme po osima x i y te zakret oko osi z . U okruženju za učenje isti je mehanizam ostvaren trima pomoćnim zglobovima umetnutima između nepomičnog ishodišta i članka platforme, pa se platforma giba kao dio iste kinematičke strukture kao i manipulator.

Korijen kinematičke strukture pritom ostaje nepomičan. To je nužno jer regulator u operacijskom prostoru, opisan u poglavlju 7., računa jakobijan i matricu inercije uz pretpostavku nepomičnog korijena; uz slobodan korijen kompenzacija gravitacije ispada neispravna.

Zanemarivanje dinamike kotača pojednostavljenje je koje uklanja proklizavanje, elastičnost valjaka i ograničenja pogona kotača. Za zadatak u kojem se platforma giba malim brzinama i u kojem su zanimljive sile na vrhu alata, a ne na kotačima, to je prihvatljivo, ali ograničava prenosivost rezultata na stvarnog robota. Ograničenje je navedeno u poglavlju 9..

3.7. Simulacijsko okruženje

Simulacija se izvodi u okruženju NVIDIA Isaac Sim, uz biblioteku Isaac Lab [17] za paralelno učenje. Fizika se rješava pogonom PhysX. Cijeli je rad proveden u simulaciji jer stvarni robot nije bio dostupan, a zadatak zahtijeva velik broj ponavljanja interakcije s kontaktom, što na stvarnom robotu nije izvedivo u opsegu završnog rada.

Bitna je značajka postava razdvajanje odgovornosti: geometrijski model nosi topologiju i geometriju, a sva pojačanja pogona i svojstva otpora zadaju se u konfiguraciji okruženja. Time se izbjegava da se naučena politika veže uz jednu konkretnu datoteku modela umjesto uz raspon uvjeta.

Pogoni osi manipulatora postavljeni su na nultu krutost i prigušenje. Momente računa regulator u operacijskom prostoru i zadaje ih izravno; da je zadržana krutost iz pretvorbe, pogon i regulator djelovali bi jedan protiv drugoga i krutost koju politika zada ne bi imala učinka. Pogon platforme brzinski je, s prigušenjem 10^4 , a pogon prstiju pozicijski, s vrijednostima navedenima u potpoglavlju 3.2..

Programska i sklopovska konfiguracija može se vidjeti u tablici 8.

Tablica 8. Programska i sklopovska konfiguracija

Stavka	Vrijednost
Operacijski sustav	Ubuntu 22.04 LTS
Simulator	NVIDIA Isaac Sim 5.1.0
Biblioteka za učenje	Isaac Lab 2.3.2
Robotski operacijski sustav	ROS 2 Humble
Python (Isaac Lab)	3.11.15
Python (ROS 2)	3.10.12
Procesor	AMD Ryzen 7 260
Grafička kartica	NVIDIA GeForce RTX 5050, 8 GB VRAM
Radna memorija	32 GB DDR5

3.8. Programska arhitektura


Softver je podijeljen u pakete unutar radnog prostora ROS 2, navedene u tablici 9. Podjela slijedi funkcionalne cjeline rada: opis robota, percepcija, veza sa simulatorom, izvođenje zadatka, konfiguracija i pokretanje sustava.

Tablica 9. Paketi radnog prostora ROS 2

Paket	Sadržaj
<code>kmr_iiwa_description</code>	modeli robota, prihvatnice, kamere i vrata
<code>kmr_iiwa_perception</code>	detekcija oznaka, fuzija poze, procjena sile i momenta
<code>kmr_iiwa_sim_bridge</code>	veza sa simulatorom: platforma, prihvatnica, kamera
<code>kmr_iiwa_task</code>	izvođenje zadatka i procjena ograničenja gibanja
<code>kmr_iiwa_moveit_config</code>	konfiguracija planiranja gibanja manipulatora
<code>kmr_iiwa_bringup</code>	pokretanje cjelokupnog sustava


Isaac Sim nema izvornu podršku za sučelje `ros2_control`, pa je veza sa simulatorom ostvarena vlastito izrađenim čvorovima koji prevode poruke ROS 2 u naredbe simulatoru. Upravljanje prihvatnicom namjerno je izvedeno kao potpuno odvojena cjelina: jedini čvor koji zna da prihvatnica ima četiri prizmatična zgloba i hod od 25 mm jest njezin upravljački čvor, dok ostatak sustava prihvatnicu vidi kroz jedan broj u rasponu od nula do jedan, uz povratnu informaciju o trenutnom položaju i o tome je li zaustavljena prije dolaska u zadani položaj. Time je zadovoljen zahtjev iz potpoglavlja 3.2. da se prihvatnica može zamijeniti bez izmjena u ostatku sustava.

Na slici 8 može se vidjeti dijagram arhitekture za klasično učenje.



Slika 8. Programska arhitektura klasičnog pristupa

Pristup temeljen na učenju koristi bitno jednostavniju arhitekturu (slika 9). Tijekom učenja ROS 2 nije u regulacijskoj petlji: okruženje, regulator i politika izvode se unutar Isaac Laba, izravno nad tenzorima na grafičkoj kartici. Razlog je paralelizacija — učenje se izvodi u više stotina istovremenih okruženja, a posredovanje kroz ROS 2 bilo bi usko grlo. Veza s ROS-om potrebna je tek pri izvođenju naučene politike izvan simulacije, što nije bilo u opsegu ovog rada i opisano je u poglavlju 8.



Slika 9. Programska arhitektura pristupa temeljenog na učenju

4. MODUL PERCEPCIJE

Zadatak modula percepcije jest odrediti položaj i orijentaciju hvatišta kvake iz slike, u koordinatnom sustavu vezanom uz robota, kako bi se manipulator mogao voditi prema hvatištu bez unaprijed poznatog položaja vrata. Fizička izvedba kamere i njezina montaža opisane su u potpoglavlju 3.3.; ovdje je opisan postupak obrade slike i izlaz koji modul daje ostatku sustava.

4.1. Odabir pristupa


Procjena poze provodi se pomoću vizualnih oznaka postavljenih na vrata i kvaku. Oznake su odabrane jer daju potpunu procjenu poze s poznatom mjernom nesigurnošću iz jedne slike, bez prethodnog učenja i bez skupa označenih primjera. To je u ovom radu bitno, jer je fokus zadatka na upravljanju u kontaktu, a ne na prepoznavanju objekata; oznake omogućuju da modul percepcije bude pouzdan ulaz za ostatak sustava, umjesto da sam postane predmet istraživanja.

Uporaba oznaka istovremeno je i najveće pojednostavljenje u radu. Stvarna vrata nemaju oznake, pa robot s ovakvim modulom ne bi radio izvan pripremljene okoline. Postupci koji ne zahtijevaju oznake postoje — Stuede i suradnici za isti zadatak i isti tip robota kvaku detektiraju konvolucijskom neuronskom mrežom [9] — ali traže skup podataka i vrijeme učenja koji nisu bili u opsegu ovog rada. Posljedice su navedene u potpoglavlju 4.7..

Od dviju uobičajenih familija oznaka odabran je AprilTag [18], i to zbog zrelijih detekcijskih biblioteka u sustavu ROS 2 te točnije procjene orijentacije pri malim oznakama nego što je daju usporedive alternative.

4.2. Raspored oznaka

Na svakim vratima nalaze se tri oznake (slika 10), raspoređene prema tablici 10. Podjela na jednu veliku i dvije male oznake slijedi iz toga što prilaz i hvat imaju različite zahtjeve. Velika oznaka na sredini krila služi fazi prilaza. Njezina veličina omogućuje pouzdanu detekciju s udaljenosti od dva do tri metra, dakle iz položaja u kojem robot započinje zadatak. U toj fazi nije potrebna velika točnost, nego samo dovoljno dobra procjena smjera i udaljenosti da se platforma dovede pred vrata.




Slika 10. AprilTagovi: sredina vrata (gore), kvaka (A dolje lijevo, B dolje desno)

Dvije male oznake na krajevima kvake služe fazi hvata, na radnoj udaljenosti od otprilike jednog do jednog i pol metra. Njihova je veličina ograničena promjerom šipke kvake, koji iznosi 28 mm, pa je za njih odabrana familija s mrežom 4×4 umjesto 6×6 : pri istoj duljini stranice takva oznaka ima krupnija polja i ostaje čitljiva na većoj udaljenosti. Cijena je manja Hammingova udaljenost među kodovima, dakle veća sklonost lažnim detekcijama, što je ublaženo time da modul očekuje unaprijed poznate identifikatore i provjerava je li izmjereni razmak dviju oznaka u očekivanom rasponu.

Tablica 10. Raspored vizualnih oznaka na vratima

Oznaka	Vrata	Nosivi članak	Veličina	Familija
središnja	oba	krilo	80 mm	tag36h11
kvaka, <i>A</i>	zakretna	poluga kvake	25 mm	tag16h5
kvaka, <i>B</i>	zakretna	poluga kvake	25 mm	tag16h5
kvaka, <i>A</i>	klizna	šipka kvake	25 mm	tag16h5
kvaka, <i>B</i>	klizna	šipka kvake	25 mm	tag16h5

Razmak dviju malih oznaka razlikuje se po tipu vrata i iznosi 130 mm na zakretnim te 220 mm na kliznim vratima, jer je kod zakretnih vrata poluga kvake vodoravna i kraća, a kod kliznih je šipka okomita i dulja. Raspored je prikazan na slici 11.



Slika 11. Raspored vizualnih oznaka na zakretnim (lijevo) i kliznim (desno) vratima

4.3. Detekcija oznaka

Detekcija se provodi gotovim paketom `apriltag_ros` za sustav ROS 2, koji iz slike u boji i unutarnjih parametara kamere daje potpunu pozu svake prepoznate oznake u optičkom koordinatnom sustavu kamere. Kako jedan primjerak čvora obrađuje samo jednu familiju oznaka, pokreću se dva primjerka, po jedan za veliku i za male oznake.

Slika i unutarnji parametri kamere dolaze izravno iz simulatora, kao i cijelo stablo koordinatnih sustava robota. Objavljivanje stabla nije samorazumljivo: uvoz modela ne stvara ga sam od sebe, nego ga je trebalo dodati zasebno pri izradi simulacijskog modela (potpoglavlje 3.6.).

4.4. Fuzija dviju oznaka na kvaki

Poza kvake ne uzima se od pojedine oznake, nego se računa iz obiju. Razlog je osjetljivost procjene orijentacije na veličinu oznake: pri stranici od 25 mm i udaljenosti od preko jednog metra procjena orijentacije pojedine oznake znatno je nesigurnija od procjene položaja. Dvije oznake razmaknute 130 odnosno 220 mm daju mjernu bazu red veličine dulju od stranice same oznake, pa se smjer duž kvake iz njihovih položaja procjenjuje bitno pouzdanije nego iz orijentacije bilo koje pojedine oznake.

Neka su $\mathbf{p}_A$ i $\mathbf{p}_B$ položaji dviju oznaka, a $\mathbf{z}_A$ i $\mathbf{z}_B$ njihove normale, sve izraženo u koordinatnom sustavu robota. Položaj hvatišta uzima se kao polovište

$$\mathbf{p} = \frac{1}{2} (\mathbf{p}_A + \mathbf{p}_B). \quad (2)$$

Os y hvatišta postavlja se duž kvake, iz razlike položaja dviju oznaka:

$$\mathbf{e}_y = \frac{\mathbf{p}_B - \mathbf{p}_A}{\|\mathbf{p}_B - \mathbf{p}_A\|}. \quad (3)$$

Preostale dvije osi izvode se iz normala oznaka. Njihova srednja vrijednost $\bar{\mathbf{z}} = \frac{1}{2}(\mathbf{z}_A + \mathbf{z}_B)$ općenito nije okomita na $\mathbf{e}_y$, pa se ortogonalizira Gram-Schmidtovim postupkom:

$$\mathbf{e}_z = \frac{\bar{\mathbf{z}} - (\bar{\mathbf{z}} \cdot \mathbf{e}_y) \mathbf{e}_y}{\|\bar{\mathbf{z}} - (\bar{\mathbf{z}} \cdot \mathbf{e}_y) \mathbf{e}_y\|}, \quad \mathbf{e}_x = \mathbf{e}_y \times \mathbf{e}_z. \quad (4)$$

Matrica rotacije hvatišta jest $\mathbf{R} = [\mathbf{e}_x \ \mathbf{e}_y \ \mathbf{e}_z]$. Ovakav postupak nije usrednjavanje dviju poza, nego prilagodba krutog tijela dvjema izmjerenim točkama, pri čemu se od pojedinih oznaka preuzima samo ono što one dobro mjere: položaj u cijelosti, a od orijentacije samo normala.

Prije računanja provode se dvije provjere. Uspoređuju se vremenske oznake dviju detekcija, da se ne spoje mjerenja iz različitih trenutaka, i provjerava se je li njihov razmak unutar raspona od 50 do 400 mm, čime se odbacuju lažne detekcije. Usporedba vremenskih oznaka provodi se međusobno, između dviju detekcija, a ne u odnosu na sat računala, jer simulator ne objavljuje vlastito vrijeme, pa bi takva usporedba spajala dvije nepovezane vremenske domene.

4.5. Sučelje modula i radni doseg

Modul objavljuje pozu hvatišta na jednoj temi, s frekvencijom od 10 Hz, izraženu u koordinatnom sustavu platforme. Time je sučelje prema ostatku sustava svedeno na jednu poruku, neovisno o tome koliko je oznaka i kojih familija upotrijebljeno, pa se postupak detekcije može zamijeniti bez izmjena u kodu koji izvodi zadatak.

Dvije skupine oznaka imaju bitno različit radni doseg. Središnja oznaka pouzdano se detektira s udaljenosti od dva do tri metra, pa pokriva cijelu fazu prilaza. Male oznake na kvaki traže udaljenost manju od otprilike 1.2 m, i to ne zbog razlučivosti nego zbog vidnog polja: bliže od te udaljenosti gornja oznaka izlazi iz kadra, a procjena smjera duž kvake gubi jednu od dviju mjernih točaka i orijentacija hvatišta se raspada.

Ta udaljenost istovremeno je veća od dosega manipulatora pri nepomičnoj platformi, pa se poza kvake očita s ruba radnog dosega, a platforma se tek nakon toga primakne. Kako platforma nema odometriju, poza kvake pritom se rekonstruira iz njezina nepromjenjivog odnosa prema središnjoj oznaci. Postupak je opisan u potpoglavlju 6.2..


4.6. Preciznost percepcijskog modula

Provedeno je testiranje točnosti i preciznosti percepcijskog modula, čiji se rezultati mogu vidjeti u tablici 11 te na slici 12. Testiranje je provedeno tako da se robot dovodio

na nasumične pozicije ispred vrata tako da kamera vidi oznake na kvaki. Zatim se uz pomoć vlastito izrađene skripte `perception_accuracy_logger.py` očitala poza hvatišta koju daje percepcijski modul i uspoređivala sa stvarnom pozom dobivenom iz simulatora. Postupak je ponovljen 15 puta za obje vrste vrata.

Tablica 11. Točnost procjene poze hvatišta, 30 mjernih točaka

Veličina	Jedinica	Srednja vrijednost	Std. devijacija	Najveća
Pogreška položaja	mm	17.07	9.01	44.82
okomito na kvaku	mm	15.59	9.47	44.81
duž kvake	mm	5.74	2.70	11.95
Pogreška smjera kvake	°	2.13	2.82	11.48
Pogreška orijentacije	°	4.88	5.76	23.97
Rasip procjene položaja	mm	1.29	0.75	3.90



Slika 12. Ovisnost pogreške položaja i smjera kvake o udaljenosti hvatišta od robota

Može se primijetiti da je odstupanje položaja i smjera kvake veće pri većim udaljenostima, a pri manjim udaljenostima je pogreška svega desetak milimetara, odnosno par stupnjeva. Kako se poza hvatišta traži tek kad je robot dovoljno blizu vratima (oko 1.2 m), pogreška percepcije je dovoljno mala da ne igra veliku ulogu. Pogreška se kasnije kompenzira prilikom faze hvata, kako je opisano u 3.2. i 6.2..

4.7. Ograničenja

Oznake na vratima. Modul pretpostavlja pripremljenu okolinu i na stvarnim vratima ne bi radio bez prethodnog postavljanja oznaka. To je najizraženije pojednostavljeno u radu. Prijelaz na detekciju bez oznaka mijenja modul percepcije, ali ne i ostatak sustava, jer je sučelje prema izvođenju zadatka svedeno na pozu hvatišta.

Percepcija se ne koristi pri učenju. Pristup temeljen na učenju u fazi učenja uzima pozu kvake izravno iz simulacije, kao povlaštenu informaciju. Razlog je paralelizacija: postupak detekcije radi nad jednim tokom slike i na procesoru, pa bi njegovo provođenje kroz stotine istovremenih okruženja onemogućilo učenje u razumnom vremenu. Modul percepcije time je alat za provjeru i izvođenje, a ne dio petlje učenja. Posljedica je razlika između uvjeta učenja i uvjeta izvođenja, o kojoj se raspravlja u poglavlju 8..

Dubinska slika nije korištena. Sve procjene proizlaze iz slike u boji i poznate veličine oznaka. Dubinski kanal kamere ostaje neiskorišten, pa bi se pri prijelazu na detekciju bez oznaka mogao iskoristiti kao dodatni izvor podataka.

Model kamere. Položaj optičkog središta u modelu kamere određen je iz geometrije kućišta, uz pretpostavku da je poprečni pomak zanemariv. Očekivana je pogreška reda nekoliko milimetara, što je na radnoj udaljenosti od preko jednog metra zanemarivo, ali bi pri radu na manjim udaljenostima trebalo biti izmjereno.

Slika iz simulatora nije izobličena. Simulator daje sliku iz idealnog modela kamere, bez izobličenja leće, pa se koristi izravno. Stvarna kamera zahtijevala bi prethodno ispravljanje slike, što je dodatan korak koji u ovom postavu nije bio potreban.

5. PROCJENA SVOJSTAVA OKOLINE

Zadatak traži da robot svojstva okoline procjenjuje iz mjerenja sile i momenta tijekom interakcije, a ne da mu se ona zadaju unaprijed. Ovo poglavlje opisuje kako se iz veličina dostupnih na robotu dolazi do sile i momenta na vrhu alata, te kako se iz njihova odnosa prema gibanju u načelu procjenjuju svojstva okoline poput krutosti i ograničenja gibanja. Naglasak je na tome da su sve procjene izvedene isključivo iz veličina koje bi imao i stvarni robot (poze vrha alata i procijenjene sile) a nikada iz stanja zglobova vrata, koje simulator doduše zna, ali stvarni robot ne bi. Stanje zgloba vrata koristi se samo kao referentna vrijednost pri provjeri procjenitelja, nikada u upravljačkoj petlji.

5.1. Procjena sile i momenta na vrhu alata

Manipulator nema zaseban senzor sile na zapešću, nego se sila i moment na vrhu alata procjenjuju iz momenata u zglobovima. Veza je posljedica načela virtualnog rada: za manipulator u ravnoteži, moment u zglobovima koji uravnotežuje vanjsku silu i moment na vrhu alata dan je izrazom

$$\boldsymbol{\tau} = \mathbf{J}^T(\mathbf{q}) \mathbf{w}, \quad (5)$$

gdje je $\boldsymbol{\tau}$ vektor momenata u zglobovima, $\mathbf{q}$ vektor zglobnih koordinata, $\mathbf{J}(\mathbf{q})$ Jakobijan manipulatora, a $\mathbf{w} = [\mathbf{F}^T \ \mathbf{M}^T]^T$ vektor sile i momenta na vrhu alata (engl. *wrench*). Procjena sile i momenta dobiva se rješavanjem tog sustava po $\mathbf{w}$.

Za manipulator sa sedam zglobova i šesterodimenzijским vektorom sile i momenta sustav (5) je preodređen, pa se rješava u smislu najmanjih kvadrata pomoću Moore-Penroseova pseudoinverza transponiranog Jakobijana:

$$\hat{\mathbf{w}} = (\mathbf{J}^T)^+ \boldsymbol{\tau}. \quad (6)$$

Jakobijan se računa iz trenutne konfiguracije manipulatora, dobivene iz stabla koordinatnih sustava, pa procjena ne zahtijeva nikakav dodatan senzor osim već postojećih mjerila momenta u zglobovima.

5.1.1. Svojstva i ograničenja procjene

Izraz (6) pretpostavlja da je izmjereni moment u zglobovima posljedica isključivo sile i momenta na vrhu alata. U stvarnosti mjereni moment sadrži i doprinos vlastite težine manipulatora i prihvatnice, koji o kontaktu ništa ne govori. `tcp_wrench_estimator` tu

težinu ne kompenzira proračunom, nego je uklanja umjerivanjem: neposredno prije zanimljivog dijela zadatka, dok manipulator miruje u konfiguraciji bliskoj onoj u kojoj će se odvijati kontakt i dok kontakta još nema, očitani se moment pohrani kao poravnanje na nulu (*tare*) i oduzima od svih narednih očitavanja. Umjeravanje je stoga vezano uz konfiguraciju: ono uklanja gravitacijski doprinos onoj pozi u kojoj je izvedeno, a odstupanje raste kako manipulator odmiče od te poze u sljedećim koracima gibanja.

Ni nakon umjeravanja procjena nije bez pogreške. U slobodnom gibanju, bez kontakta, procjena sile pokazuje šum reda pola njutna, što je razina ispod koje se kontakt ne može pouzdano razlučiti od mjerne nesigurnosti. Procjena momenta uz to zadržava sustavni rezidual reda desetak njutnmetara, koji potječe od preostale, nepotpuno uklonjene dinamike manipulatora, ponajviše iz odstupanja stvarne poze od one u kojoj je umjeravanje provedeno. Na tipičnom kraku hvata taj rezidual odgovara sili reda dvadesetak njutna.

Posljedica je da procjena dobro razlučuje smjer i prisutnost kontaktne sile, ali njezin apsolutni iznos treba uzimati s obzirom na navedeni rezidual, a umjeravanje treba ponoviti kad god se manipulator znatnije udalji od poze u kojoj je posljednje umjeravanje provedeno. Ponovno umjeravanje tijekom zadatka provodi se uvjetno, samo kad je trenutno očitana sila već niska. U suprotnom bi se u nulu upisala stvarna kontaktna sila, umjesto samo preostalog gravitacijskog doprinosa. Za upravljanje u ovom radu to je dovoljno, jer se sila koristi za otkrivanje kontakta i za ograničavanje njezina iznosa, a ne kao precizno mjerilo.

5.2. Procjena svojstava okoline iz odnosa sile i gibanja

Iz procijenjene sile i istovremeno mjerene poze vrha alata u načelu se mogu procijeniti dva svojstva okoline: krutost u smjeru gibanja i geometrija ograničenja kojim je gibanje vrata određeno.

Krutost se procjenjuje iz odnosa prirasta sile i prirasta pomaka u smjeru gibanja,

$$K \approx \frac{\Delta F}{\Delta x}, \quad (7)$$

što je uporabljivo i za otkrivanje zaustavljanja: ako sila raste, a pomak izostaje, vrata su ili potpuno otvorena ili blokirana. Ta procjena ima načelno ograničenje o kojem treba voditi računa pri tumačenju: krutost izmjerena na vrhu alata jest krutost najmekšeg člana cijelog lanca, a ne nužno krutost samih vrata. Kad je popustljivost hvata ili prihvatnice usporediva s krutošću vrata, izmjerena vrijednost prvenstveno odražava taj najmekši član. Za mjerenje krutosti samih vrata trebalo bi ili upravljati impedancijom vrha alata, ili zasebno izmjeriti i oduzeti popustljivost vlastitog lanca. Za procjenu krutosti odgovorna je skripta `door_probe.py`.

Geometrija ograničenja razlikuje dva tipa vrata prema obliku putanje vrha alata pri otva-

ranju. Kod zakretnih vrata vrh alata opisuje kružni luk oko osi šarke, pa se iz niza zabilježenih položaja može prilagoditi kružnica čije je središte procjena položaja osi, a polumjer udaljenost hvatišta od nje. Kod kliznih vrata putanja je pravac, pa prilagodba kružnice ne konvergira, već polumjer raste bez granice, što je samo po sebi znak da je gibanje translacijsko. Načelo je time jedinstveno za oba tipa: isti se postupak prilagodbe primjenjuje na oba, a tip vrata proizlazi iz toga koji model bolje pristaje izmjerenoj putanji, a ne iz unaprijed zadanog grananja po tipu vrata. Za određivanje vrste vrata analizom gibanja napravljena je skripta `door_open.py`.

5.3. Uloga procjene u ovom radu

Dva se pristupa upravljanju bitno razlikuju po tome koliko se od gore opisane procjene stvarno koriste, i to je jedna od glavnih razlika koja se razmatra u poglavlju 8..

Klasični pristup, opisan u poglavlju 6., geometriju ograničenja ne procjenjuje iz gibanja, nego je uzima iz poze kvake dobivene percepcijom: os šarke i smjer otvaranja poznati su iz položaja i orijentacije hvatišta. Procjena sile i momenta ipak mu je nužna, i to za otkrivanje uspješnog hvata te za ograničavanje kontaktne sile tijekom otvaranja. Procjena krutosti i geometrije ograničenja iz gibanja u tom pristupu nije bila potrebna.


Pristup temeljen na učenju, opisan u poglavlju 7., geometriju ograničenja ne dobiva ni iz percepcije ni iz eksplicitnog procjenitelja, nego je mora otkriti sam, iz procijenjene sile i ostvarenog pomaka, i na temelju toga prilagoditi svoje djelovanje. Time procjena sile i momenta u tom pristupu nije pomoćni signal, nego jedini put kojim politika uopće doznaje o mehaničkim svojstvima okoline.

6. KLASIČNI PRISTUP UPRAVLJANJU

Klasični pristup rješava zadatak otvaranja vrata i prolaska kroz njih kao slijed jasno odvojenih faza, od kojih svaka koristi eksplicitno poznavanje geometrije zadatka: poze kvake iz percepcije, poznatog oblika prihvatnice i, za zakretna vrata, geometrijski izračunate osi šarke. To je bitna razlika prema pristupu iz poglavlja 7.

6.1. Struktura zadatka

Zadatak je organiziran u četiri faze: prilaz, hvat, otvaranje i prolazak. Tip vrata robot prepoznaje sam, iz geometrije kvake, tijekom faze hvata (potpoglavlje 6.2.). Ta odluka određuje koja se grana faze otvaranja pokreće. Prolazak kroz vrata izveden je i potvrđen samo za klizna vrata; kod zakretnih vrata zadatak završava otvaranjem, iz razloga navedenog u potpoglavlju 6.6.. Slijed je prikazan na slici 13.



Slika 13. Slijed faza klasičnog pristupa

6.2. Faza prilaza i hvata

6.2.1. Poravnanje platforme

Platforma se dovodi na određenu udaljenost od vrata (potpoglavlje 4.5.) regulacijom položaja prema velikoj oznaci na sredini vrata. Cilj regulacije nije samo udaljenost, nego potpuna poza u ravnini, tj. bočni i uzdužni položaj te zakret, sve do zadanih tolerancija. Ciljna točka i ciljni zakret određeni su duž normale vrata, izvedene iz orijentacije oznake, a ne samo iz smjera pogleda prema njoj. Regulacija koja nastoji držati oznaku na sredini pogleda kamere ne jamči da će platforma stati okomito na vrata. Ako orijentacija oznake iz nekog razloga nije dostupna, sustav se vraća na regulaciju smjera pogleda, čime se izbjegava da robot potpuno stane, po cijenu manje pouzdanog poravnanja.

6.2.2. Prepoznavanje tipa kvake

Kad je platforma na ciljanoj udaljenosti, sustav sam prepoznaje tip vrata iz geometrije kvake, umjesto da mu se tip zadaje pri pokretanju. Kvaka nosi dvije male oznake (pot-

poglavlje 4.2.); vektor između njihovih položaja jednoznačno razlikuje tipove, jer je kod zakretnih vrata poluga kvake vodoravna, a kod kliznih šipka okomita. Kriterij je jednostavan prag na okomitoj komponenti tog vektora: ako ona prelazi 70 % duljine vektora, kvaka je okomita i vrata su klizna, inače su zakretna. Prepoznati tip određuje koja se od dviju unaprijed zadanih početnih poza manipulatora koristi u nastavku, a poslije i koja se grana faze otvaranja pokreće (potpoglavlje 6.3.).

6.2.3. *Hvat*

1. **Ponovno čitanje poze.** Na početnoj udaljenosti kvaka je izvan dosega manipulatora pri nepomičnoj platformi, pa se platforma nakon prvog očitavanja poze dodatno primakne. Kako platforma nema odometriju, poza kvake se pritom ne prati nego se rekonstruira iz njezina nepromjenjivog odnosa prema velikoj oznaci, koja ostaje u vidnom polju tijekom cijelog primicanja.
2. **Prilaz.** Manipulator se dovodi u pozu prilaska ispred kvake te se zatim približava do konačne poze hvata.
3. **Bočna korekcija.** Parovi prstiju prihvatnice ne gibaju se savršeno simetrično, pa se хват sam od sebe ne centririra nad predmetom. Umjesto da se ta asimetrija ukloni, ona se mjeri: uspoređuju se položaji suprotnih prstiju tijekom zatvaranja, a iz njihove razlike izračunava se bočna korekcija kojom se prihvatnica poravna nad kvakom prije konačnog zatvaranja.
4. **Korekcija dubine (engl. *hill-climbing*).** Prihvatnica postupno prilagođava svoju dubinu duž osi prilaza kako bi šipka kvake u potpunosti sjela u utor prstiju. Pri svakom pokušaju prsti se zatvaraju do zaustavljanja i mjeri se ostvareni stupanj zatvorenosti; ako se mjera pogorša u odnosu na prethodni pokušaj, algoritam mijenja smjer pomaka i vraća se na dotad najbolju poziciju, sve dok se ne postigne željena dubina hvata ili se ne obavi najveći dopušteni broj pokušaja.

6.2.4. *Sidrenje cilja na oznaku*

Neposredno nakon potvrđenog hvata mjeri se i pohranjuje fiksni prostorni odnos između vrha alata i velike oznake, tj. pomak i zakret koji vrijede u tom trenutku. Taj se odnos u nastavku zadatka koristi za određivanje cilja gibanja: umjesto da se cilj izvodi iz posljednje poznate poze vrha alata, on se u svakom koraku iznova računa iz trenutne poze oznake i pohranjenog odnosa. Razlika je bitna kad kvaka unutar hvata blago klizne, što se pokazalo mjerljivim pri otvaranju zakretnih vrata (potpoglavlje 6.3.2.): bez sidrenja na oznaku, cilj bi klizio zajedno s kvakom, klizanje se ne bi moglo ni izmjeriti, a manipulator nikad ne bi dobio naredbu da nadoknadi razliku. Isti se mehanizam koristi i za neovisno mjerenje samog klizanja, kao razlike između očekivane i stvarno postignute poze vrha alata.

6.3. Faza otvaranja

Nakon uspješnog hvata, kreće faza otvaranja vrata.

Nakon uspješnog hvata, manipulator do kraja faze otvaranja ostaje u dostignutoj konfiguraciji ili joj se vraća između malih koraka gibanja, a cjelokupno napredovanje izvodi platforma, uz iznimku opisanu u potpoglavlju 6.3.2.. Ta je odluka namjerna i vezana je uz procjenu sile opisanu u poglavlju 5.: postupak umjeravanja procjenitelja momenta vrijedi za konfiguraciju u kojoj je proveden (potpoglavlje 5.1.1.), pa svaki veći pomak manipulatora tu procjenu čini nevaljanom, osim ako se umjeravanje ponovi.

6.3.1. Klizna vrata

Kod kliznih vrata smjer gibanja poznat je unaprijed — vodoravna translacija duž zgloba klizanja — pa se platformi zadaje trapezni profil brzine u tom smjeru, s ubrzanjem, ravnomjernom fazom i usporavanjem. Sam taj smjer izvodi se iz orijentacije prihvatnice, i to iz njezine lokalne osi x , duž koje se prsti zatvaraju (potpoglavlje 3.2.), projicirane na vodoravnu ravninu. Smjer se ne računa jednom na početku, nego se osvježava u svakom koraku iz trenutne orijentacije prihvatnice. Kad bi ostao fiksiran, a platforma se u međuvremenu neznatno zakrenula, počela bi se stvarati komponenta sile koja stoji okomito na vrata umjesto duž njih, a rasla bi s nakupljenim zakretom. Regulacija brzine prema izmjerenoj sili namjerno nije korištena: sila uvijek naraste u trenutku kretanja platforme iz mirovanja, pa bi svaki takav povratni regulator uveo zastajkivanje umjesto glatkog gibanja. Sila se koristi isključivo kao sigurnosni prekid.

Hod kliznih vrata premašuje ono što platforma stigne prijeći unutar jednog trapeznog profila, pa se vožnja prema potrebi ponavlja u više prolaza, bez ponovnog hvata. Prihvatnica drži kvaku neprekidno, platforma se samo zaustavi na kraju jednog profila i ponovno krene s početka sljedećeg. Napredak nakon svakog prolaza provjerava se prema stvarnom pomaku zgloba vrata, očitano izravno u simulatoru; razlog za to odstupanje od uobičajenog pravila naveden je u potpoglavlju 6.6..

6.3.2. Zakretna vrata

Kod zakretnih vrata gibanje platforme nije jednostavna translacija, pa način na koji je otvaranje ostvareno bitno odstupa od kliznih vrata: umjesto da precizno praćenje luka izvodi platforma, tu je zadaću preuzeo manipulator, dok platforma ima samo pomoćnu ulogu.

Otvaranje ne teče tako da platforma i manipulator rade istovremeno kroz cijelu fazu, nego u naizmjeničnim koracima. U jednom koraku platforma miruje, a manipulator zakreće vrh alata za jedan mali, unaprijed zadani kut duž procijenjene kružnice, inverznom ki-

nematikom. U sljedećem koraku manipulator samo drži kvaku u dosegnutoj pozi, dok platforma vozi naprijed konstantnom brzinom. Ideja iza tog pristupa je da primicanje platforme manipulatoru vrati doseg koji je prethodnim zakretanjem potrošio.


Precizno vođenje po luku time je u cijelosti prepušteno manipulatoru, a platformi ostaje samo jednostavna translacija. Cilj se pritom sidri na oznaku, na način opisan u potpoglavlju 6.2.4., čime se u svakom koraku nadovezuje na stvarno postignuto stanje kvake, a ne na vlastitu prethodnu naredbu. Ovakva podjela uloga posljedica je ograničenog kapaciteta platforme da precizno prati zadanu brzinu (potpoglavlje 6.6.).

Budući da vrh alata inverznom kinematikom vodi MoveIt, prije početka povlačenja iz njegove planerske scene uklanjaju se kolizijski objekti vrata i zidova (potpoglavlje 3.5.). U suprotnom bi planer odbijao upravo ono gibanje koje je namjerno usmjereno prema kvaki i kroz prostor koji zid inače zatvara. Kolizijski objekti zida u planersku scenu ne ulaze kao dva unaprijed poznata tijela, nego se sastavljaju iz skena lidara, pa njihov broj nije unaprijed određen. Kad su vrata zatvorena, krilo i oba zida optički čine jednu neprekinutu plohu, dok se otvaranjem krilo odmakne i pojave se dva razdvojena segmenta. Za razliku od procjene ograničenja iz poglavlja 5., os šarke se ovdje ne procjenjuje iz gibanja, nego se izravno izračunava iz geometrije poznate percepciji, i to iz jednog, fiksnog vektora izraženog u koordinatnom sustavu same oznake. Neka je $\mathbf{p}_{\text{tag}}$ položaj velike oznake, a $\mathbf{R}(\mathbf{q}_{\text{tag}})$ matrica rotacije koja opisuje njezinu orijentaciju. Os šarke procjenjuje se kao

$$\mathbf{c} = \mathbf{p}_{\text{tag}} + \mathbf{R}(\mathbf{q}_{\text{tag}}) \mathbf{v}_{\text{hinge}}, \quad \mathbf{v}_{\text{hinge}} = \begin{pmatrix} 0 \\ -L/2 \\ -\delta \end{pmatrix}, \quad (8)$$

gdje je $\mathbf{c}$ procijenjeni položaj osi šarke. Računa se kao položaj velike oznake, pomaknut vektorom $\mathbf{v}_{\text{hinge}}$ koji je prethodno zaokrenut u svjetski koordinatni sustav istom rotacijom kao i sama oznaka. Druga i treća komponenta tog vektora izražene su u lokalnim osima oznake: L je širina krila (tablica 6), a $\delta = 21$ mm odmak oznake od središnje ravnine debljine krila. Slika 14 prikazuje konstrukciju u tlocrtu.

Vektor $\mathbf{v}_{\text{hinge}}$ ima jednostavno geometrijsko značenje: oznaka je postavljena točno na sredinu krila, pa je udaljenost do osi šarke, mjerena duž krila, jednaka točno polovici njegove širine. Krilo je debelo 40 mm, a os šarke, kao i kod stvarnih vrata, prolazi kroz sredinu te debljine, ne kroz plohu na kojoj je oznaka zalijepljena. Time nastaje razmak od 20 mm (polovica debljine krila) kojemu se pridodaje i sitan odmak same naljepnice od plohe od svega 1 mm, pa je ukupni δ 21 mm.



Slika 14. Konstrukcija procjene osi šarke iz poze i lokalnih osi velike oznake, tlocrt

Os se preračunava iz svježe poze oznake u svakom koraku upravljanja. Budući da je odmak $\mathbf{v}_{\text{hinge}}$ izražen u koordinatnom sustavu same oznake, koja je kruto vezana uz krilo, procjena ostaje ispravna i dok se vrata otvaraju: kako oznaka rotira zajedno s krilom oko prave, nepomične osi šarke u svijetu, umnožak $\mathbf{R}(\mathbf{q}_{\text{tag}}) \mathbf{v}_{\text{hinge}}$ rotira s njom na jednak način, pa zbroj (8) u svakom trenutku ponovno pogađa istu, stvarnu točku u prostoru. Procjena tako ne zahtijeva praćenje kuta vrata kroz vrijeme, nego je ispravna iz jednog, trenutnog očitavanja poze oznake.

6.4. Prolazak kroz vrata

Nakon otvaranja slijedi prolazak, izveden i potvrđen za klizna vrata. Zadatak se ovdje ne oslanja na kameru, nego na lidar (potpoglavlje 3.4.): budući da sken lidara zadržava poredak točaka onako kako ih senzor redom očitava, praznina u tom nizu odgovara praznini u prostoru gledano sa senzora, a otvor u zidu prepoznaje se kao praznina čija širina odgovara poznatoj širini dovratnika.

Postupak ima četiri koraka:

1. **Otpuštanje.** Prihvatnica otvara prste i pušta kvaku.
2. **Parkiranje ruke.** Manipulator odlazi u unaprijed zadanu poziciju za parkiranje kako se ne bi zabio u zidove dok robot prolazi kroz vrata.
3. **Poravnanje.** Platforma se bočno pomiče, isključivo holonomnim gibanjem u poprečnom smjeru, dok se otvor pronađen u skenu ne dovede u sredinu vidnog polja senzora ili dok sken ne javi prepreku preblizu.
4. **Prolazak.** Platforma se giba naprijed kroz otvor, uz stalno praćenje skena radi pravovremenog zaustavljanja pred neočekivanom preprekom.

6.5. Rezultati

6.5.1. Prilazak i hvat

Pogreška poravnanja platforme iznosi 1.2 do 1.4°. Odstupanje postignute pred-hvatne poze od cilja iznosi 8 do 11 mm u položaju te 0.1 do 0.2° u orijentaciji, a odstupanje same poze hvata 6 do 8 mm i oko 0.5°. Prepoznavanje tipa kvake iz geometrije (potpoglavlje 6.2.2.) pokazalo se pouzdanim na objema scenama vrata.

6.5.2. Zakretna vrata

Kriterij zaustavljanja postavljen je na kut od 50°. Vrijednost proizlazi iz dvaju međusobno suprotstavljenih zahtjeva: prolaz kroz djelomično otvorena vrata mora biti dovoljno širok za platformu, a kut mora ostati ispod granice na kojoj hvat popušta (potpoglavlje 6.6.).

Izmjerene vrijednosti pri otvaranju do tog kuta navedene su u tablici 12.

Tablica 12. Izmjerene vrijednosti pri otvaranju zakretnih vrata

Veličina	Vrijednost
Pouzdan kut otvaranja	50°
Najveći postignuti kut	oko 57°
Sila povlačenja, prosječna	348 N
Sila povlačenja, najveća	625 N
Klizanje hvata	3–5 mm
Pogreška praćenja položaja	ispod 2 mm
Pogreška procjene osi šarke	5–8 mm
Pogreška kuta vrata iz oznake	1.3–2.0°

6.5.3. Klizna vrata

Ostvareno je potpuno otvaranje od 900 mm, u dva prolaza. Sila povlačenja iznosila je u prosjeku 258 N, s vrhom do 661 N, a klizanje hvata ostalo je ispod 4 mm kroz cijeli manevar, u skladu s time da se kod kliznih vrata smjer sile poklapa sa smjerom gibanja hvata, dok kod zakretnih vrata hvat prati zakrivljenu putanju.

6.6. Ograničenja

- Mjerenja bez kontakta pokazuju da platforma ostvaruje tek oko 45 % naređene brzine u uzdužnom smjeru i oko 11 % u poprečnom, dosljedno kroz čitav ispitani raspon brzina od 0.05 do 0.22 m/s; brzina očitana u samom simulatoru pritom odgovara na-

ređenoj, pa je uzrok negdje u prijenosu naredbe do fizike platforme. Manji poprečni omjer u skladu je s odnosom nazivnih brzina platforme u katalogu (potpoglavlje 3.1.1.), ali sam taj odnos ne objašnjava ni približno toliko nizak uzdužni omjer. Provjereno je i isključeno više mogućih uzroka: pogon zgloba vrata, trenje u tom zglobu, viskozno prigušenje platforme, brzina same simulacije te trajanje prijelazne faze na početku gibanja. Izravna posljedica jest da se prijedeni put platforme, gdje god se koristi, ne smije uzimati kao pouzdana mjera stvarnog gibanja, jer integracija naređene brzine ostvareni pomak precjenjuje dvostruko do peterostruko.

- Zbog prethodnog ograničenja, provjera napretka između prolaza pri otvaranju kliznih vrata čita stvarni pomak zgloba vrata izravno iz simulatora, a ne iz veličine dostupne i na stvarnom robotu, što odstupa od načela iz poglavlja 5.. Testiran je alternativni pristup gdje se procjenjuje pomak pomoću lidara, ali nije se pokazao dovoljno pouzdanim.
- Kako je navedeno u potpoglavlju 3.5., zglob koji bi omogućio zakretanje kvake u konačnom je modelu nepomičan. Ta je odluka svjesno smanjenje opsega rada, ne nedostatak: zakretanje kvake bilo je u ranijoj fazi razvoja najproblematičniji dio zadatka, jer je kruto pozicijsko upravljanje tim dodatnim stupnjem slobode davalo velike kontaktne sile na svako odstupanje procjene. Uklanjanjem tog stupnja slobode zadatak je sveden na jedan stupanj slobode po tipu vrata. Ista je odluka primijenjena i u pristupu temeljenom na učenju, opisanom u poglavlju 7., čime ostaje osnova za usporedbu dvaju pristupa.
- Zakretna se vrata ne mogu otvoriti preko otprilike 57° . Provjerena je metoda radialne kompenzacije klizanja, no hvat i dalje popusti. Prihvatnica je vlastito izrađena za ovaj rad, a ne model postojećeg uređaja, pa se problem ne može rješavati jednostavnim povećanjem stiska bez gubitka fizikalne vjerodostojnosti. Mogući zaobilazak ove granice je prepozicioniranje hvata, tj. manipulator pusti kvaku, platforma se premjesti, a kvaka se ponovno uhvati iz povoljnije konfiguracije. Ovakav pristup nije izveden u opsegu ovog rada.
- Sustav sadrži zaseban postupak procjene geometrije ograničenja iz odnosa sile i gibanja, opisan u poglavlju 5., ali on u klasičnom pristupu nije povezan s izvođenjem: os šarke u fazi otvaranja izračunava se geometrijski iz percepcije, a procjena iz gibanja postoji u zasebnim, samostalno pokretanim skriptama, izvan glavnog tijeka zadatka. Sustav zna i procijeniti ograničenje iz gibanja i otvoriti vrata, ali te dvije sposobnosti nisu spojene u jedan tijek izvođenja.
- Lidar tijekom otvaranja i prolaska prati postoji li prepreka neposredno ispred platforme i zaustavlja zadatak ako je udaljenost premala, ali ne raspolaže planiranjem puta niti izbjegavanjem prepreke.

7. PRISTUP TEMELJEN NA UČENJU

Pristup temeljen na učenju rješava isti zadatak kao poglavlje 6., ali bitno drugačijim sredstvima. Klasični pristup vrh alata vodi krutim pozicijskim upravljanjem po una-prijed izračunatoj putanji, uz geometriju ograničenja poznatu iz percepcije. Ovdje se, umjesto toga, uvodi varijabilna impedancija: politika u svakom koraku sama bira koliko će regulator biti krut po svakoj osi, a geometriju ograničenja ne dobiva ni iz percepcije ni iz eksplicitnog procjenitelja, nego je mora otkriti iz vlastitih opažanja sile i gibanja. To je izravan odgovor na nalaz iz poglavlja 6.: kruto pozicijsko praćenje luka davalo je velike kontaktne sile na svako odstupanje procjene, pa varijabilna impedancija postoji upravo zato da politika tu krutost regulira sama.

7.1. Opseg

Politika ne uči prilaz ni hvat kvake. Epizoda počinje od stanja u kojem prihvatnica već drži kvaku, a klasični postupak prilaza i hvata (potpoglavlje 6.2.) smatra se zajedničkim za oba pristupa. Razlog je dvostruk: prilaz i hvat rješavaju problem navigacije i planiranja gibanja, a ne problem interakcije koji je predmet ovog rada, i njihovo bi dupliciranje otežalo poštenu usporedbu, jer bi mjerena razlika između pristupa uključivala i razliku u tome tko je bolji u navigaciji, ne samo u interakciji. Iz istog je razloga izostavljen i prolazak kroz vrata: i on je navigacija kroz poznatu geometriju, ista kategorija kao prilaz. Ta odluka o opsegu izravno oblikuje ono što se u poglavlju 8. smije uspoređivati. Usporedba se odnosi isključivo na fazu otvaranja, ne na cijeli zadatak, dok klasični pristup taj cijeli zadatak stvarno izvodi od početka do kraja.

Sam postupak prolaska kroz vrata je implementiran i radi, uključivo za slučaj naučene politike, ali je namjerno isključen iz rezultata radi dosljednosti opsega. Vrijedan je kao potvrda da se naučena politika može ugraditi u isti izvršni sloj kao klasični pristup.

Trening se u cijelosti odvija unutar simulacijskog okruženja Isaac Lab, bez sustava ROS 2 u regulacijskoj petlji. Razlog je paralelizacija: trening istovremeno pokreće više stotina okruženja, a posredovanje kroz ROS 2 bilo bi usko grlo. Epizoda traje 10 sekundi, uz korak upravljanja od 60 Hz (fizika 120 Hz, decimacija 2), što daje 600 koraka po epizodi.

Uspješnost politike pri determinističkom izvođenju, koje se razlikuje od učenja, mjerena je zasebno i uspoređena s klasičnim pristupom u poglavlju 8..

7.2. Formulacija Markovljevog procesa odlučivanja

7.2.1. *Prostor opažanja*

Vrijedi isto načelo kao u klasičnom pristupu: kut ili pomak zgloba vrata, dakle stvarno stanje zadatka, nikada nije dio opažanja politike, nego se koristi isključivo u nagradi i terminaciji, gdje je legitiman jer se računa izvan regulacijske petlje. Opažanje sadrži:

- pozu vrha alata u koordinatnom sustavu platforme (položaj i orijentacija);
- linearnu i kutnu brzinu vrha alata, u istom koordinatnom sustavu;
- brzinu platforme, (linearna brzina po x i y , kutna brzina oko z);
- procijenjenu silu i moment na vrhu alata, uz Gaussov šum standardne devijacije 0.5 N, koji odgovara šumu stvarnog procjenitelja iz poglavlja 5.;
- vektore od platforme do najbližih točaka susjednih prepreka (zid, dovratnik), uz Gaussov šum standardne devijacije 1 cm, koji odgovara izmjerenoj stabilnosti sredine otvora iz skena lidara u klasičnom pristupu (potpoglavlje 6.4.);
- posljednju akciju.

7.2.2. *Prostor akcija*

Ruka se upravlja regulatorom u operacijskom prostoru s varijabilnom impedancijom. Akcija zadaje pomak reference vrha alata u odnosu na trenutnu pozu, za svih šest stupnjeva slobode, i šest pripadnih krutosti, po jedna za svaku os. Time politika izravno bira, u svakom koraku i za svaku os zasebno, koliko će regulator biti krut, točno ono što je poglavlje 6. pokazalo da kruto pozicijsko upravljanje ne može samo po sebi ostvariti.

Sam pomak reference po koraku ograničen je na 15 mm. Pri većoj vrijednosti, istraživačko ponašanje na početku učenja trgalo je hvat sa šipke prije nego što bi politika uopće stigla nešto naučiti.

Uz šest stupnjeva slobode ruke, akcija sadrži i tri komponente brzine platforme (uzdužnu, poprečnu i kutnu) pa politika sama koordinira ruku i platformu.

7.2.3. *Koordinacija platforme i manipulatora*

Uvedena je dodatna kazna na odstupanja platforme od okomice na ravninu vrata, s težinom razmjernom tome koliko takvo odstupanje kod danog tipa vrata stvarno šteti: znatno većom kod zakretnih, gdje dijagonalan položaj platforme kasnije ne prolazi kroz suženi otvor, nego kod kliznih, gdje platforma svejedno mora pratiti krilo poprečno pa okomitost

manje košta. Kazna je uz to zatvorena ovisno o ostvarenom napretku, tako da ne djeluje u ranoj fazi zadatka, kada bi se sukobila s potrebom da politika zakrene platformu radi dosega. Ruka je montirana izvan osi platforme, pa zakret platforme proširuje radni prostor ruke na legitiman način.

7.2.4. Funkcija nagrade

Tablica 13 navodi sve članove nagrade. Sve su težine kalibrirane mjerenjem, ne pogodene: cilj je bio da svaki član, u konvergiranom pokretanju, iznosi između 3 i 10 % udjela glavnog člana napretka, a postupak je bio pustiti probno pokretanje, očitati udjele i skalirati težinu razmjerno odstupanju od tog cilja.

Tablica 13. Članovi funkcije nagrade

Član	Težina	Svrha
napredak	+10,0	glavni član, normiran na prag uspjeha
okomita sila	−0,02	kazni silu okomitu na stvarni smjer gibanja vrata
zasićenje zglobova	−2,0 (klizna), −6,0 (zakretna)	kazni rad blizu granice raspona zglobova ruke
singularitet	−20,0	kazni pad manipulabilnosti ispod praga
ubrzanje ruke	-5×10^{-4}	kazni ubrzanje zglobova ruke
trzaj ruke	-1×10^{-7}	kazni trzaj (drugu derivaciju brzine) zglobova ruke
prekomjerna sila	−0,05	kazni ukupnu silu iznad referentne granice
poravnanje hvata	−3,0	kazni odstupanje prilazne osi hvata od okomice na krilo
poravnanje platforme	−6,0 (zakretna), −0,1 (klizna)	kazni odstupanje platforme od okomice na ravninu vrata
prodor u krilo	−20,0	kazni približavanje ruba platforme krilu ispod sigurnog razmaka
prodor u zid	−20,0	kazni približavanje ruba platforme zidu ili dovratniku ispod sigurnog razmaka
promjena akcije	−0,002	kazni razliku uzastopnih akcija
uspjeh	+2,0	bonus po koraku dok je pomak vrata iznad praga uspjeha

Napredak se ne normira na puni hod zgloba vrata, već na puno manju referentnu vrijednost 0.6 m kod kliznih i 0.5 rad (28.6 °) kod zakretnih vrata. Uz normiranje na puni hod, manji pomak nosio bi premalu nagradu da nadjača kazne, pa bi politika naučila dovesti vrata na određeni pomak i ne pomicati ih dalje. Time napredak nije ograničen

odozgo, već smije prijeći jedinicu, što znači da nagrada za napredak raste što su vrata više otvorena.

Prag uspjeha, koji određuje kada se dodjeljuje bonus iz zadnjeg retka tablice 13, zasebna je veličina. Kod kliznih vrata poklapa se s referentnom vrijednošću normalizacije i iznosi 0.6 m. Kod zakretnih vrata je namjerno odvojen i postavljen na 1.57 rad (90 °). Razlog je taj što je 0.5 rad dovoljno da se vrata mjerljivo pomaknu, ali nije dovoljno da robot kroz njih prođe. Normalizacija je pritom ostala nepromijenjena kako bi kalibracija svih ostalih veličina ostala valjana. Bonus za uspjeh dodjeljuje se po koraku dok je pomak iznad praga, a ne kao jednokratna nagrada uz prekid epizode.

Kazna na singularitet koristi Yoshikawin indeks manipulabilnosti [19]:

$$w(\mathbf{q}) = \sqrt{\det(\mathbf{J}(\mathbf{q})\mathbf{J}(\mathbf{q})^T)}, \quad (9)$$

koji je jednak nuli točno na kinematičkom singularitetu i nigdje drugdje. Kazna je normirana na raspon od nule do jedan.

7.2.5. Terminacije

Epizoda prekida prije isteka vremena u četiri slučaja

- sila je prešla sigurnosnu granicu,
- hvat je izgubljen jer se vrh alata previše udaljio od šipke kvače,
- rub platforme je dotaknuo krilo vrata,
- rub platforme dotaknuo zid ili dovratnik.

7.2.6. Nasumičnost pri resetu i kurikulum otpora

Pri svakom resetu, kut prilaska platforme vrtnji se nasumično zakreće unutar $\pm 20^\circ$ oko nazivne vrijednosti. Otpor vrata randomizira se u rasponima navedenima u poglavlju 3. (tablica 7).

Kod kliznih vrata otpor se uz to uvodi postupno, kurikulumom koji tijekom prvih 1500 iteracija učenja linearno širi gornju granicu trenja i prigušenja s vrijednosti koja odgovara laganim vratima do pune vrijednosti iz tablice 7, nakon čega ostaje na punoj vrijednosti do kraja treninga. Kurikulum politici omogućuje da najprije nauči na lakšim vratima, gdje se povratna informacija o napretku redovito javlja, prije nego što se suoči s punim rasponom. Zakretna vrata kurikulum nemaju, jer je njihov otpor za red veličine manji i politika na njemu uči bez poteškoća; različit režim treninga po tipu vrata posljedica je te razlike u težini zadatka, ne proizvoljne odluke.

7.3. Postupak učenja

Učenje se provodi algoritmom proksimalne optimizacije politike (PPO) [13], s hiperparametrima u tablici 14.

PPO pripada familiji postupaka s aktorom i kritikom, koji uče dvije odvojene neuronske mreže. Aktor je sama politika, ona iz opažanja daje srednje vrijednosti normalne razdiobe iz koje se potom uzorkuje akcija, po jednu za svaku dimenziju akcijskog prostora. Kritičar ničim ne upravlja, nego iz opažanja procjenjuje očekivani ukupni diskontirani povrat iz zatečenog stanja, dakle mjeru toga koliko je stanje samo po sebi povoljno. Kritičar je potreban jer ostvarena nagrada sama po sebi ne govori je li akcija bila dobra: visoka nagrada može biti posljedica povoljnog stanja, a ne odabrane akcije. Razlika između stvarno ostvarenog povrata i kritikove procjene, tzv. prednost, ono je što ulazi u ažuriranje aktora. Pozitivna prednost pojačava vjerojatnost odabrane akcije, negativna je smanjuje. Diskontni faktor γ i faktor generalizirane procjene prednosti λ iz tablice 14 upravljaju upravo izračunom te prednosti.

Obje su mreže potpuno povezane i međusobno neovisne, bez zajedničkih slojeva, s trima skrivenim slojevima širine 256, 128 i 64. Aktor preslikava 41 ulaznu veličinu, koliko ih ima opažanje iz potpoglavlja 7.2.1., u 15 izlaznih, koliko ih ima akcija iz potpoglavlja 7.2.2.. Kritičar ima isti ulaz, ali jedan jedini izlaz. Postupno suženje slojeva uobičajen je obrazac: široki prvi sloj izdvaja značajke iz sirovog opažanja, a svaki ih sljedeći sažima prema odluci. Ukupno je riječ o svega stotinjak tisuća parametara po obje mreže, što je za mjerila neuronskih mreža malo, ali uobičajeno kada je opažanje vektor izmjerenih veličina, a ne primjerice slika.

Kao aktivacijska funkcija skrivenih slojeva koristi se ELU (engl. *exponential linear unit*),

$$\text{ELU}(x) = \begin{cases} x, & x > 0 \\ e^x - 1, & x \leq 0 \end{cases} \quad (10)$$

koja unosi nelinearnost, bez koje bi tri uzastopna linearna sloja bila jednakovrijedna jednomu. Pozitivne ulaze ne mijenja, dok za negativne daje glatku negativnu vrijednost umjesto nule. Time se, prvo, izbjegava da neuron s negativnim izlazom ostane trajno neaktivan, jer mu gradijent ne pada na nulu, i drugo, srednja vrijednost aktivacija ostaje bliža nuli, što ubrzava konvergenciju. Potonje je ovdje osobito prikladno, jer su ulazne veličine (sile, brzine i pomaci) predznačene i prirodno raspoređene oko nule, pa bi funkcija koja negativne vrijednosti postavlja na nulu odbacila polovicu njihova raspona.

Tablica 14. Hiperparametri učenja

Hiperparametar	Vrijednost
Broj koraka po okruženju prije ažuriranja	24
Broj epoha učenja po ažuriranju	5
Broj mini-grupa	4
Stopa učenja	10^{-3} , prilagodljiva prema odstupanju KL
Diskontni faktor γ	0.99
Faktor generalizirane procjene prednosti λ	0.95
Koeficijent obrezivanja	0.2
Koeficijent entropije	0.001
Početna standardna devijacija politike	0.5

Broj paralelnih okruženja postavljen je na 1024, kao kompromis između propusnosti i broja dostupnih pokretanja. Svako je pokretanje trajalo 2400 iteracija, a sve brojke u nastavku očitane su kao prosjek zadnjih 100 iteracija, zato što pojedinačna iteracija nosi previše šuma da bi sama predstavljala izvedbu politike.

7.4. Rezultati

Tablica 15 navodi rezultate na sceni sa zidovima i s graničnim vrijednostima zgloba vrata usklađenima s klasičnim pristupom. Radi usporedivosti, obje su politike trenirane s istim brojem okruženja i istim brojem iteracija, a sve su vrijednosti prosjek zadnjih 100 iteracija. Prva dva retka tablice vrijednosti su pripadnih članova nagrade, a ne veličine koje izravno opisuju ishod. Okruženje ih prije zapisivanja dijeli duljinom epizode, pa su ispod svakog člana navedene veličine izvedene iz njega: član napretka razmjeran je prosječnom otvoru vrata kroz epizodu, a član uspjeha udjelu epizode tijekom kojeg su vrata iznad praga uspjeha. Udjeli terminacija u nastavku tablice jesu udjeli epizoda i zbrajaju se na jedinicu.

Tablica 15. Rezultati pristupa temeljenog na učenju, 1024 okruženja, 2400 iteracija

Veličina	Zakretna vrata	Klizna vrata
Član napretka	18.93	9.87
prosječni otvor kroz epizodu	0.947 rad	0.592 m
Član uspjeha	0.743	0.831
udio epizode iznad praga	0.371	0.416
Udio: izgubljen hvat	0.072	0.000
Udio: dodir krila	0.061	0.003
Udio: dodir zida	0.002	0.000
Udio: prekomjerna sila	0.006	0.028
Udio: istek vremena	0.860	0.969
Duljina epizode, koraci	561.8	587.4

Te vrijednosti opisuju ponašanje politike tijekom učenja, uz šum istraživanja. Stopa uspjeha pri determinističkom izvođenju mjerena je zasebno i navedena je u poglavlju 8..

7.5. Ograničenja

- Naučena politika koristi srednju vrijednost razdiobe akcije, bez šuma istraživanja, pa se izvedba pri izvođenju ne mora poklapati s brojkama iz treninga, koje su mjerene uz šum.
- Kazna za odstupanje platforme od okomice na vrata pogoršava se u zadnjoj četvrtini treninga, jer okomit položaj platforme stvarno smanjuje doseg ruke montirane izvan njezine osi, pa politika pred kraj treninga taj kompromis rješava nešto drugačije nego ranije.
- Politika, za razliku od klasičnog pristupa, ne raspolaže nikakvim posredovanim signalom o tipu ili smjeru ograničenja: geometriju mora otkriti iz iste sile i pomaka kojima i djeluje.

8. EKSPERIMENTALNI REZULTATI I RASPRAVA

Poglavlja 6. i 7. iznose rezultate svakog pristupa na njegovim vlastitim uvjetima. Ovdje se ta dva pristupa međusobno uspoređuju. Najprije se utvrđuje što se uopće smije uspoređivati, zatim izlaže usporedba po zajedničkom kriteriju uspjeha, kontaktnim silama i načinima otkazivanja, i naposljetku raspravlja o tome što razlike znače.

8.1. Protokol usporedbe

Oba su pristupa mjerena na sceni sa zidovima, uz otpor vrata izvučen iz istog raspona (tablica 7), ali postupci mjerenja razlikuju se u trima pogledima koji određuju koje su tvrdnje opravdane.

Klasični pristup izvodi cijeli lanac, od prilaska i hvata preko otvaranja do prolaska kroz vrata. Pristup temeljen na učenju rješava isključivo fazu otvaranja i kreće od stanja u kojem prihvatnica već drži kvaku (potpoglavlje 7.1.). Usporedba se zato odnosi na otvaranje.

Klasični je pristup mjeran u deset zasebnih pokušaja po tipu vrata, naučena politika u nekoliko stotina epizoda.

Pragovi se razlikuju: klasični pristup cilja 50° odnosno 0.90 m, a naučena politika 90° odnosno 0.60 m. Mjerenja obaju pristupa zato bilježe ostvareni otvor kao kontinuiranu veličinu, pa se stopa uspjeha računa za bilo koji prag naknadno, upravo zato da usporedba ne ovisi o tome čiji je kriterij odabran.

Pri determinističkom izvođenju naučene politike dio epizoda ne ostvaruje gibanje platforme, pa manipulator doseže granicu vlastitog radnog prostora i otvaranje staje na oko 0.45 m odnosno 12° . Takve su epizode izdvojene iz statistike, pa analiza obuhvaća 305 od 562 epizode na zakretnim te 286 od 581 na kliznim vratima; uzrok je opisan u potpoglavlju 7.5.. Navedene brojke time opisuju sposobnost upravljanja, a ne pouzdanost izvođenja u cjelini.

8.2. Uspješnost otvaranja

Tablica 16 uspoređuje oba pristupa po pragu koji koristi klasični pristup i po pragu koji koristi naučena politika.

Tablica 16. Stopa uspjeha po zajedničkim pragovima

Vrata	Prag	Klasični pristup	Pristup učenjem
zakretna	50°	0.80	1.00
zakretna	90°	0.00	0.96
klizna	0.60 m	1.00	1.00
klizna	0.90 m	1.00	1.00

Kod kliznih vrata oba pristupa dosežu puni cilj od 0.90 m u svakom pokušaju. Zadatak je za oba rješiv: ograničenje je pravac poznat iz percepcije kod klasičnog pristupa, odnosno pravac koji politika otkriva iz sile i pomaka, a smjer sile poklapa se sa smjerom gibanja. Razlika među pristupima ondje se ne očituje u uspješnosti.

Kod zakretnih vrata razlika je najizraženija u cijelom radu. Naučena politika otvara vrata preko 90° u 96 % epizoda, dok klasični pristup taj kut ne doseže nijednom, ne zato što ga ne cilja, nego zato što mu je fizička granica oko 57°, iznad koje kvaka klizne iz prihvatnice (potpoglavlje 6.6.).

Razlika nije samo u dosegnutom pragu nego i u obliku raspodjele. Klasični pristup staje na $52.12^\circ \pm 0.42^\circ$, dakle vrlo ponovljivo i skoro točno ondje gdje mu je cilj postavljen. Naučena politika ima medijan otvora na 122°, a gornji kvartil na 134.1°, praktički na mehaničkoj granici zgloba od 135°. Politika vrata redovito otvara do kraja hoda. Ista se slika ponavlja i kod kliznih vrata, gdje medijan otvora leži na punom hodu od 1.00 m.

8.3. Kontaktne sile

Izmjerene sile klasičnog pristupa navedene su u tablici 17. Naučena politika prosječnu silu ne izvještava izravno, ali je njezina raspodjela ograničena sigurnosnim prekidom na 400 N: udio epizoda prekinutih prekoračenjem sile iznosi 0.6 % kod zakretnih i 2.8 % kod kliznih vrata (tablica 15). Politika dakle u više od 97 % epizoda ostaje ispod te granice.

Tablica 17. Kontaktne sile klasičnog pristupa, prosjek deset pokušaja

Vrata	Sila, prosječna	Sila, najveća
zakretna	348 N	625 N
klizna	258 N	661 N

Klasični pristup redovito prelazi 400 N, s vršnom silom od 625 N, dok naučena politika tu granicu prekoračuje u manje od 1 % posto epizoda. Kod kliznih vrata klasični pristup generalno ostaje ispod granice, ali za otići i preko (vrh 661 N), pa je naučena politika i tu bolja.

Taj je nalaz izravna potvrda teze koju rad gradi od poglavlja 6.. Klasični pristup vodi vrh alata krutim pozicijskim upravljanjem, pa svako odstupanje između procijenjene i stvarne geometrije luka postaje sila. Naučena politika krutost regulatora bira po osi i u svakom koraku, pa silu smanjuje popuštanjem u smjeru u kojem se bori s ograničenjem.

8.4. Načini otkazivanja

Kod klasičnog pristupa oba neuspjeha na zakretnim vratima dogodila su se u fazi hvata, prije nego je otvaranje uopće počelo. Kad otvaranje jednom krene, uspije svaki put i s vrlo malim rasipanjem. Slabija karika klasičnog pristupa kod zakretnih vrata time nije upravljanje nego percepcija i hvat.

Naučena politika otkazuje tijekom same interakcije: gubi hvat u 7.2 % epizoda na zakretnim vratima i dodiruje krilo u 6.1 %. Kod kliznih su vrata oba gotovo nula. Dodir zida je u oba slučaja zanemariv, što pokazuje da je politika naučila pouzdano izbjegavati prepreke.

8.5. Rasprava

8.5.1. *Različiti ulazi u isti problem*

Razlika u uspješnosti ne smije se čitati kao razlika u kvaliteti upravljanja, jer dva pristupa ne rješavaju problem s istim informacijama.

Klasični pristup zna gdje je os šarke. Izračunava je iz poze oznake i poznate širine krila, kao fiksni vektor u koordinatnom sustavu oznake (izraz (8)), uz izmjerenu pogrešku od 5 do 8 mm. Naučena politika taj podatak nema ni u kojem obliku: geometriju ograničenja mora otkriti iz vlastitih opažanja sile i pomaka, a kut vrata nikada ne ulazi u njezino opažanje. Ista asimetrija vrijedi i za smjer klizanja kod kliznih vrata.

Asimetrija ide i u drugom smjeru. Naučena politika koordinira platformu i manipulator jednom, naučenom strategijom (potpoglavlje 7.2.3.), dok klasični pristup taj problem rješava unaprijed propisanim slijedom naizmjeničnih faza. Kod zakretnih vrata upravo ta propisana shema postaje ograničenje: izmjereno je da primicanje platforme manipulatoru ne vraća doseg, jer kvaka putuje zajedno s platformom, pa doseg kroz cijelo pokretanje ostaje između 0.78 i 0.87 m. Politika koja koordinaciju uči nije vezana tom pretpostavkom i pronalazi obrazac gibanja koji propisani slijed ne sadrži.

8.5.2. *Zašto se razlika pojavljuje samo na zakretnim vratima*

Izostanak razlike na kliznim i velika razlika na zakretnim vratima nisu slučajni, nego slijede iz toga koliko svaki zadatak traži prilagodbu krutosti tijekom interakcije.

Klizna su vrata geometrijski jednostavna: ograničenje je pravac, smjer sile poklapa se sa smjerom gibanja, a jedina poteškoća je duljina hoda, koju klasični pristup rješava ponavljanjem prolaza. Ondje eksplicitno poznavanje geometrije daje sve što treba, pa dodatna sloboda u odabiru krutosti ne donosi mjerljivu prednost.

Zakretna vrata traže gibanje po luku, uz stalno mijenjanje odnosa između platforme, manipulatora i kvake. Ondje kruto praćenje unaprijed izračunate putanje stvara silu na svako odstupanje, a uhvaćena kvaka pritom klizne. Naučena politika, koja krutost mijenja po osi i koordinaciju uči, prolazi kroz područje na koje klasični pristup nailazi kao na tvrdi granicu.

Zaključak je time uvjetovan, a ne općenit: eksplicitno poznavanje geometrije dostatno je kad je geometrija jednostavna i dobro procijenjena, a gubi prednost čim zadatak zahtijeva prilagodbu krutosti tijekom same interakcije.

8.6. Ograničenja usporedbe

- Usporedba obuhvaća isključivo fazu otvaranja. Prilazak, hvat i prolazak kroz vrata klasični pristup izvodi, a naučena politika ne, pa se njihova ukupna sposobnost rješavanja zadatka ovim mjerenjima ne uspoređuje.
- Navedene stope uspjeha naučene politike uvjetne su na način opisan u potpoglavlju [8.1.](#) i opisuju sposobnost upravljanja, a ne pouzdanost izvođenja u cjelini.
- Stopa uspjeha nije istovrsna veličina na dvjema stranama. Kod klasičnog pristupa riječ je o binarnom ishodu po pokušaju, nad deset pokušaja; kod naučene politike o udjelu nad nekoliko stotina epizoda. Razlika između 0.80 i 1.00 na uzorku od deset pokušaja nije pouzdana; razlika između 0.00 i 0.96 jest.
- Naučena politika mjerena je uz nasumičan kut prilaska, kojega u klasičnim pokušajima nema, pa raspon uvjeta nije posve izjednačen.
- Trajanje izvođenja nije uspoređivano. Epizoda naučene politike traje najviše deset sekundi i najčešće istječe bez prekida, jer uspjeh ne prekida epizodu, dok klasični pristup traje dok zadatak ne dovrši, prosječno 40 s na zakretnim i 28 s na kliznim vratima. Te dvije veličine ne mjere isto.
- Obje su izvedbe mjerene isključivo u simulaciji. Zaključci se odnose na model, a prenosivost na stvarni robot ograničena je pojednostavljenjima navedenima u poglavljima [3.](#) i [4.](#).

9. ZAKLJUČAK

U radu je razvijen i eksperimentalno vrednovan sustav za autonomnu interakciju mobilnog manipulatora s okolinom, na primjeru otvaranja dvaju vrsti vrata. Sustav objedinjuje percepciju, procjenu sile i momenta te upravljanje u kontaktu, a zadatak upravljanja riješen je dvama pristupima: klasičnim, temeljenim na modelu, i pristupom temeljenim na podržanom učenju. pristupi su potom uspoređeni na istom robotu, istoj sceni i istim mjerilima.

Modul percepcije određuje položaj i orijentaciju kvake iz slike, pomoću vizualnih oznaka. Postupak procjene sile i momenta na vrhu alata izveden je iz momenata u zglobovima, bez zasebnog senzora sile, a iz odnosa procijenjene sile i ostvarenog pomaka pokazano je kako se procjenjuju krutost okoline i geometrija ograničenja gibanja.

Klasični pristup rješava cijeli zadatak, od prilaska i hvata preko otvaranja do prolaska kroz vrata, pri čemu tip vrata prepoznaje sam, iz geometrije kvake. Pristup temeljen na učenju formuliran je kao Markovljev proces odlučivanja s varijabilnom impedancijom u prostoru akcije, čime politika u svakom koraku bira koliko će regulator biti krut po svakoj osi.

9.1. Glavni nalazi

Usporedba dvaju pristupa dala je rezultat koji se ne svodi na prednost jednoga nad drugim, nego ovisi o tipu vrata, i upravo je ta ovisnost najvrjedniji nalaz rada.

Kod kliznih vrata oba pristupa dosežu puni cilj u svakom pokušaju. Ograničenje je ondje pravac, smjer sile poklapa se sa smjerom gibanja, i eksplicitno poznavanje geometrije daje sve što je potrebno, pa dodatna sloboda u odabiru krutosti ne donosi mjerljivu prednost.

Kod zakretnih vrata razlika je velika. Klasični pristup pouzdano otvara vrata do 50° , ali preko otprilike 57° ne može, jer kvaka klizne iz prihvatnice. Naučena politika vrata otvara preko 90° u 96 % epizoda, s medijanom otvora na 122° i gornjim kvartilom praktički na mehaničkoj granici zgloba. Uz to, klasični pristup pri otvaranju zakretnih vrata redovito prelazi 400 N, s vršnom silom od 625 N, dok naučena politika tu granicu prekoračuje u manje od 1 % epizoda.

Zaključak je time uvjetovan, a ne općenit: eksplicitno poznavanje geometrije dovoljno je kad je geometrija jednostavna i dobro procijenjena, a gubi prednost čim zadatak zahtijeva prilagodbu krutosti tijekom same interakcije.

Dva pristupa razlikuju se i po tome što o zadatku znaju. Klasični pristup položaj osi šarke izračunava iz poze oznake i poznate širine krila, uz pogrešku od 5 do 8 mm, dok naučena politika tu geometriju nema ni u kojem obliku i mora je otkriti iz vlastitih opažanja sile

i pomaka. S druge strane, naučena politika koordinaciju platforme i manipulatora uči, dok je klasični pristup rješava unaprijed propisanim slijedom faza. Upravo ta propisana shema kod zakretnih vrata postaje ograničenje.

9.2. Ograničenja

Cjelokupan je rad proveden u simulaciji, pa se zaključci odnose na model, a ne izravno na stvarni robot. Uz to, sustav sadrži nekoliko svjesnih pojednostavljenja i nekoliko neriješenih pitanja.

Zglob koji bi omogućio zakretanje kvake zavaren je u oba pristupa, čime je zadatak sveden na jedan stupanj slobode po tipu vrata. Percepcija se oslanja na vizualne oznake postavljene na vrata, pa sustav u nepripremljenoj okolini ne bi radio. Mecanum kotači nisu simulirani kao tijela u kontaktu s podlogom, nego je gibanje platforme zadano kinematički.

Platforma ostvaruje tek dio naređene brzine, a uzrok tome nije utvrđen unatoč tome što je više mogućih objašnjenja provjereno i isključeno. Posljedica je da se prijedeni put platforme ne smije uzimati kao pouzdana mjera gibanja, zbog čega provjera napretka pri otvaranju kliznih vrata čita stanje zgloba izravno iz simulatora. Ovo ograničenje vrlo je vjerojatno posljedica simulatora, i vjerojatno ne bi bila problem na stvarnom robotu.

Naposljetku, sustav sadrži postupak procjene geometrije ograničenja iz odnosa sile i gibanja, ali on nije povezan s izvođenjem: u klasičnom se pristupu os šarke izračunava iz percepcije, a procjena iz gibanja postoji kao zaseban, samostalno provjeren postupak.

9.3. Smjernice za daljnji rad

- **Prepozicioniranje hvata.** Jedini put preko granice od 57° kod zakretnih vrata koji ne traži bočni prostor kojega u sceni nema jest da manipulator pusti kvaku, platforma se premjesti, a kvaka se ponovno uhvati iz povoljnije konfiguracije.
- **Povezivanje procjene ograničenja s izvođenjem.** Pokretanje procjene odmah nakon hvata i odabir načina otvaranja na temelju njezina ishoda uklonilo bi oslanjanje na tip kvake prepoznat iz percepcije i učinilo sustav neovisnim o poznatoj geometriji.
- **Odometrija platforme iz percepcije.** Riješila bi oslanjanje na stanje zgloba očitano iz simulatora i omogućila mjerenje prijednog puta veličinama dostupnima i na stvarnom robotu.
- **Prolazak kroz zakretna vrata.** Kod kliznih vrata platforma ostaje uz istu stranu zida, pa je otvor dostupan bočnim gibanjem; kod zakretnih vrata robot samim otvaranjem prolazi kroz vrata.

- **Zakretanje kvake.** Vraćanje tog stupnja slobode proširilo bi zadatak na vrata sa stvarnom bravom, ali bi tražilo upravljanje koje kut zakreta kvake ne prati kruto.
- **Detekcija bez oznaka.** Zamjena vizualnih oznaka postupkom koji kvaku prepoznaje izravno iz slike uklonila bi najizraženije pojednostavljenje u radu, pri čemu ostatak sustava ne bi trebalo mijenjati, jer je sučelje prema izvođenju zadatka svedeno na pozu hvatišta.
- **Prijenos na stvarni robot.** Konačna provjera svih zaključaka traži izvođenje izvan simulacije, pri čemu su procjena sile bez zasebnog senzora i pojednostavljeni model gibanja platforme najizgledniji izvori odstupanja.

LITERATURA

- [1] Marc H. Raibert and John J. Craig. Hybrid position/force control of manipulators. *Journal of Dynamic Systems, Measurement, and Control*, 103(2):126–133, 1981.
- [2] Christian Ott, Berthold Bäuml, Christoph Borst, and Gerd Hirzinger. Employing cartesian impedance control for the opening of a door: A case study in mobile manipulation. In *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), Workshop on Mobile Manipulators*, 2005.
- [3] Jürgen Sturm, Cyrill Stachniss, and Wolfram Burgard. A probabilistic framework for learning kinematic models of articulated objects. *Journal of Artificial Intelligence Research*, 41:477–526, 2011.
- [4] Oussama Khatib. A unified approach for motion and force control of robot manipulators: The operational space formulation. *IEEE Journal of Robotics and Automation*, 3(1):43–53, 1987.
- [5] Roberto Martín-Martín, Michelle A. Lee, Rachel Gardner, Silvio Savarese, Jeannette Bohg, and Animesh Garg. Variable impedance control in end-effector space: An action space for reinforcement learning in contact-rich tasks. In *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 1010–1017, 2019.
- [6] Thushara Sandakalum and Marcelo H. Ang. Motion planning for mobile manipulators — a systematic review. *Machines*, 10(2), 2022.
- [7] Johannes Pankert and Marco Hutter. Perceptive model predictive control for continuous mobile manipulation. *IEEE Robotics and Automation Letters*, 5(4):6177–6184, 2020.
- [8] Giuseppe Rizzi, Jen Jen Chung, Abel Gawel, Lionel Ott, Marco Tognon, and Roland Siegwart. Robust sampling-based control of mobile manipulators for interaction with articulated objects. *IEEE Transactions on Robotics*, 39(3), 2023.
- [9] Marvin Stuede, Kathrin Nuelle, Svenja Tappe, and Tobias Ortmaier. Door opening and traversal with an industrial cartesian impedance controlled mobile robot. In *IEEE International Conference on Robotics and Automation (ICRA)*, 2019.
- [10] Daniel Honerkamp, Tim Welschhold, and Abhinav Valada. Learning kinematic feasibility for mobile manipulation through deep reinforcement learning. *IEEE Robotics and Automation Letters*, 6(4):6289–6296, 2021.

- [11] Daniel Honerkamp, Tim Welschhold, and Abhinav Valada. N²M²: Learning navigation for arbitrary mobile manipulation motions in unseen and dynamic environments. *IEEE Transactions on Robotics*, 2023.
- [12] Raphael Schneider, Daniel Honerkamp, Tim Welschhold, and Abhinav Valada. Task-driven co-design of mobile manipulators. *arXiv preprint arXiv:2412.16635*, 2024.
- [13] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017.
- [14] KUKA Deutschland GmbH. KMR iiwa — always spot-on safely. Katalog proizvoda, PBJ Portfolio (EN) 05/2024, 2024. <https://www.kuka.com>.
- [15] RobotShop. Andymark bb mecanum wheel. <https://www.robotshop.com/products/andymark-4in-bb-mecanum-wheel-05in-hex-bore-right>. pristupljeno: 07.09.2026.
- [16] Christoph Hennesperger, Salvatore Virga, et al. iiwa_stack: ROS integration for KUKA LBR IIWA robots. https://github.com/IFL-CAMP/iiwa_stack. Technische Universität München, IFL-CAMP.
- [17] NVIDIA. Isaac Lab: A unified framework for robot learning. <https://isaac-sim.github.io/IsaacLab/>, 2024.
- [18] Edwin Olson. AprilTag: A robust and flexible visual fiducial system. In *IEEE International Conference on Robotics and Automation (ICRA)*, pages 3400–3407, 2011.
- [19] Yoshikawa. Manipulability of robotic mechanisms. *The International Journal of Robotics Research*, 4(2), 1985.

PRILOZI

Poveznica na repozitorij sa svim programskim kodom korištenim u ovom radu:

<https://github.com/DavidMihic/bachelors-thesis>